

Sistema Fuzzy Takagi-Sugeno para Aproximação de Funções Não Lineares

*Trabalho prático de Inteligência Computacional

1st Fabrício Silva

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
fabriciosilva1992@hotmail.com

2nd Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
leonardovieiraxy@gmail.com

Resumo—Este trabalho apresenta a implementação, análise e comparação de diferentes algoritmos de agrupamento aplicados aos conjuntos de dados Adult e Dry Bean. Foram avaliados os métodos KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, com o objetivo de investigar sua capacidade de identificar padrões e separar grupos em dados reais e multivariados. A metodologia envolveu o pré-processamento dos dados, aplicação dos algoritmos, avaliação dos resultados por métricas quantitativas (acurácia, precisão, revocação, especificidade, F1-score e matriz de confusão) e visualização dos agrupamentos por meio de PCA em duas dimensões. Os resultados obtidos evidenciam as características, vantagens e limitações de cada abordagem, destacando a importância da escolha do método de agrupamento conforme a natureza dos dados e o objetivo da análise. O estudo contribui de forma didática para a compreensão dos principais algoritmos de clustering e suas aplicações práticas em ciência de dados.

Palavras-chave—Lógica fuzzy, Mamdani, controle de ventilação, sistemas inteligentes, funções de pertinência.

I. INTRODUÇÃO

A análise e classificação de dados complexos são desafios centrais em Inteligência Computacional, especialmente diante de conjuntos de dados reais que apresentam alta dimensionalidade, múltiplas classes e estruturas não triviais. Métodos de agrupamento (clustering) desempenham papel fundamental na descoberta de padrões, segmentação e análise exploratória em diversas áreas, como ciência de dados, engenharia, saúde e ciências sociais.

Neste trabalho, diferentes algoritmos de agrupamento, incluindo KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, são implementados, documentados e comparados utilizando os conjuntos de dados Adult e Dry Bean. Cada método é explorado em notebooks didáticos, com etapas

bem definidas: importação de bibliotecas, carregamento e pré-processamento dos dados, implementação dos modelos, aplicação, visualização dos resultados e análise crítica.

A comparação entre os algoritmos é realizada a partir de métricas como acurácia, precisão, revocação, especificidade, F1-score e análise da matriz de confusão, permitindo avaliar o desempenho de cada abordagem frente aos desafios impostos pelos dados. Para facilitar a interpretação dos agrupamentos e dos centros dos clusters, utiliza-se a técnica de Análise de Componentes Principais (PCA) para projeção dos dados em duas dimensões, possibilitando uma visualização clara da separação entre os grupos encontrados.

A abordagem adotada busca não apenas comparar o desempenho dos algoritmos, mas também fornecer uma base didática sólida para compreensão dos conceitos envolvidos, destacando as vantagens e limitações de cada método no contexto dos dados analisados. Como discutido em [?], sistemas fuzzy são eficazes para aproximação de funções não lineares.

II. METODOLOGIA

A metodologia adotada neste trabalho consiste na aplicação e comparação de diferentes algoritmos de agrupamento sobre os conjuntos de dados Adult e Dry Bean, utilizando métricas quantitativas e visualização para análise dos resultados. O objetivo é avaliar, de forma didática e acessível, o comportamento de cada método frente a dados reais e variados.

A. Bases de Dados

Adult: O conjunto de dados Adult contém informações demográficas e socioeconômicas de indivíduos, como idade, escolaridade, ocupação, sexo, raça, horas trabalhadas por semana, entre outros. As principais variáveis de entrada incluem:

- **Idade** (numérica, coluna: age)

- **Escolaridade** (categórica, coluna: `education`, codificada numericamente)
- **Ocupação** (categórica, coluna: `occupation`, codificada numericamente)
- **Sexo** (categórica, coluna: `sex`, codificada numericamente)
- **Raça** (categórica, coluna: `race`, codificada numericamente)
- **Horas por semana** (numérica, coluna: `hours-per-week`)
- **País de origem** (categórica, coluna: `native-country`, codificada numericamente)

As variáveis categóricas foram convertidas para valores numéricos por meio de codificação (Label Encoding), e os dados foram normalizados. O agrupamento é realizado sem utilizar a variável de saída (`income`), que é usada apenas para avaliação das métricas.

Dry Bean: O conjunto Dry Bean reúne características físicas extraídas de imagens de diferentes tipos de feijões. As variáveis de entrada são todas numéricas e descrevem propriedades morfológicas dos grãos, tais como:

- **Área** (número de pixels, coluna: `Area`)
- **Perímetro** (comprimento do contorno, coluna: `Perimeter`)
- **Comprimento principal** (maior eixo, coluna: `MajorAxisLength`)
- **Largura principal** (menor eixo, coluna: `MinorAxisLength`)
- **Coefficiente de assimetria** (coluna: `AsymmetryCoeff`)
- **Comprimento do retângulo delimitador** (coluna: `BoundingRectLength`)
- **Largura do retângulo delimitador** (coluna: `BoundingRectWidth`)
- **Raio equivalente** (coluna: `EquivDiameter`), **Excentricidade** (coluna: `Eccentricity`), **Solidez** (coluna: `Solidity`), entre outros.

A variável de saída (`Class`) indica o tipo de feijão, mas é utilizada apenas para avaliação dos agrupamentos. Todas as variáveis foram normalizadas.

B. Balanceamento das Classes

Em muitos problemas reais, os conjuntos de dados apresentam distribuição desbalanceada entre as classes, ou seja, algumas categorias possuem muito mais exemplos do que outras. Esse desbalanceamento pode prejudicar algoritmos de agrupamento e classificação, pois os métodos tendem a favorecer as classes majoritárias, resultando em baixa sensibilidade para as classes minoritárias.

Para mitigar esse problema, foi aplicado o **balanceamento por oversampling** nos conjuntos de dados utilizados neste trabalho. O oversampling consiste em aumentar artificialmente o número de exemplos das classes minoritárias, por meio da replicação aleatória de amostras dessas classes, até igualar a quantidade de exemplos da classe majoritária. Dessa forma, garante-se que todas as classes tenham o mesmo peso durante o treinamento e avaliação dos algoritmos.

No caso do conjunto Adult, a variável de saída (renda) apresenta forte desbalanceamento entre as classes “ $\leq 50K$ ” e “ $> 50K$ ”. Para o conjunto Dry Bean, algumas variedades de feijão são muito menos frequentes que outras. O balanceamento foi realizado antes da divisão dos dados em treino e teste, assegurando que a avaliação dos métodos reflita um cenário mais justo e comparável entre as classes.

O balanceamento é fundamental para evitar vies nos resultados e garantir que as métricas de avaliação representem de forma adequada o desempenho dos algoritmos em todas as classes presentes nos dados.

C. Descrição e Pseudocódigo dos Algoritmos de Agrupamento

Foram avaliados quatro algoritmos principais, descritos a seguir juntamente com seus respectivos pseudocódigos para facilitar a compreensão didática do funcionamento de cada método:

KMeans: Algoritmo que particiona os dados em k grupos, alternando entre atribuir cada ponto ao centro mais próximo e recalculando os centros como a média dos pontos atribuídos. É eficiente para clusters esféricos e de tamanho semelhante.

- 1: Escolha o número de clusters k e inicialize aleatoriamente os centros dos clusters.
- 2: **while** os centros mudarem e não atingir o número máximo de iterações **do**
- 3: Atribua cada ponto de dado ao centro mais próximo (menor distância Euclidiana).
- 4: Atualize os centros dos clusters calculando a média dos pontos atribuídos a cada cluster.
- 5: **end while**

Fuzzy C-Means: Extensão do KMeans que permite que cada ponto pertença a múltiplos clusters, com diferentes graus de pertinência. Útil quando há sobreposição entre os grupos ou incerteza na separação dos dados.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingir o número máximo de iterações **do**
- 3: Atualize os centros dos clusters considerando os graus de pertinência de cada ponto.
- 4: Atualize a matriz de pertinência U com base nas distâncias dos pontos aos centros.
- 5: **end while**

Gustafson-Kessel: Generalização do Fuzzy C-Means que permite que cada cluster tenha sua própria matriz de covariância, adaptando-se a diferentes formas e orientações. Utiliza distâncias Mahalanobis adaptadas.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingir o número máximo de iterações **do**
- 3: Para cada cluster, calcule o centro e a matriz de covariância adaptativa.

- 4: Atualize a matriz de pertinência U considerando as distâncias Mahalanobis adaptadas.
- 5: **end while**

Agglomerativo: Método hierárquico que começa considerando cada ponto como um cluster individual e une os clusters mais próximos em cada etapa, formando uma árvore de agrupamentos (dendrograma).

- 1: Considere cada ponto como um cluster individual.
- 2: **while** houver mais de um cluster **do**
- 3: Calcule as distâncias entre todos os pares de clusters.
- 4: Una os dois clusters mais próximos em um novo cluster.
- 5: **end while**

Esses pseudocódigos resumem o funcionamento básico de cada método, facilitando a compreensão dos passos principais de cada algoritmo de agrupamento.

D. Métricas de Avaliação

A avaliação dos agrupamentos foi realizada por meio de métricas clássicas de comparação entre os rótulos verdadeiros e os grupos encontrados:

- **Acurácia:** Proporção de exemplos corretamente agrupados em relação ao total.

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

- **Precisão:** Proporção de exemplos classificados como pertencentes a um grupo que realmente pertencem a esse grupo.

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (2)$$

- **Revocação (Recall):** Proporção de exemplos de um grupo real que foram corretamente identificados pelo algoritmo.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

- **Especificidade:** Proporção de exemplos negativos corretamente identificados como não pertencentes a um grupo.

$$\text{Especificidade} = \frac{TN}{TN + FP} \quad (4)$$

- **F1-score:** Média harmônica entre precisão e revocação, útil para avaliar o equilíbrio entre as duas métricas.

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (5)$$

- **Matriz de Confusão:** Tabela que resume os acertos e erros de classificação para cada grupo, permitindo análise detalhada dos padrões de agrupamento.

E. Visualização dos Resultados

Para facilitar a interpretação dos agrupamentos, foi utilizada a Análise de Componentes Principais (PCA) para projetar os dados em duas dimensões. Os resultados foram apresentados em gráficos de dispersão, nos quais cada ponto representa uma amostra e as cores indicam o cluster atribuído pelo algoritmo. Os centros dos clusters também foram destacados, permitindo observar a separação e a compactação dos grupos.

F. Seleção do Número de Clusters: Método do Cotovelo

Para determinar o número ideal de clusters a ser utilizado nos algoritmos de agrupamento, foi empregado o **método do cotovelo**. Essa técnica consiste em executar o algoritmo KMeans para diferentes valores de k (número de clusters) e calcular, para cada valor, a soma das distâncias quadráticas (inércia) entre os pontos e seus respectivos centros de cluster. O valor de k ideal é identificado no ponto em que a redução da inércia passa a ser menos significativa, formando um "cotovelo" na curva. Esse ponto indica um equilíbrio entre a compactação dos clusters e a complexidade do modelo, evitando tanto o subajuste quanto o sobreajuste.

No contexto deste trabalho, o método do cotovelo foi aplicado separadamente para os conjuntos de dados Adult e Dry Bean, guiando a escolha do número de clusters para cada algoritmo testado. As curvas geradas e a análise visual do cotovelo permitiram definir, de forma objetiva, o valor de k mais apropriado para cada cenário.

A metodologia apresentada neste trabalho foi cuidadosamente estruturada para garantir uma análise comparativa clara, didática e reprodutível dos principais algoritmos de agrupamento aplicados a bases de dados reais. A escolha dos métodos, das métricas e das técnicas de visualização permite não apenas avaliar o desempenho quantitativo dos algoritmos, mas também compreender suas características, limitações e adequação a diferentes tipos de dados. Essa abordagem fornece uma base sólida para a discussão dos resultados e para a escolha do método mais apropriado em aplicações práticas de agrupamento.

III. RESULTADOS E DISCUSSÃO

Nesta seção, apresentamos e discutimos os resultados obtidos com a aplicação dos quatro algoritmos de agrupamento (KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo) nos conjuntos de dados Adult e Dry Bean. São analisadas as métricas quantitativas, as visualizações e as principais observações para cada cenário, destacando as vantagens, limitações e particularidades de cada abordagem em contextos binário e multiclasse.

A. Bases de Dados e Pré-processamento

Neste trabalho, utilizamos os conjuntos de dados **Adult** (Census Income) e **Dry Bean**, ambos amplamente empregados em tarefas de classificação e agrupamento. Para garantir a comparabilidade entre os métodos, em ambos os casos foi realizado o seguinte pré-processamento: todas as variáveis categóricas foram transformadas em representações numéricas,

os atributos foram normalizados e os dados foram divididos de forma estratificada em 70% para treinamento e 30% para teste. No caso do conjunto Adult, devido ao desbalanceamento entre as classes, aplicou-se também uma técnica de balanceamento (como oversampling) para garantir uma distribuição mais equitativa entre as categorias de renda.

Adult: O conjunto Adult contém aproximadamente 48 mil amostras de indivíduos adultos dos Estados Unidos, com atributos demográficos e socioeconômicos, distribuídos em duas classes principais (renda $\leq 50K$ e $> 50K$). Os atributos incluem variáveis numéricas e categóricas, exigindo codificação e normalização cuidadosas. O balanceamento foi fundamental para evitar viés nos resultados devido à predominância de uma das classes.




Fig. 1. Distribuição das classes no dataset Adult antes do balanceamento.




Fig. 2. Distribuição das classes no dataset Adult após o balanceamento por oversampling.

Dry Bean: O conjunto Dry Bean é composto por mais de 13 mil amostras de feijões secos de sete diferentes cultivares, com atributos morfológicos extraídos de imagens. Todos os atributos são numéricos, facilitando a aplicação direta das técnicas de normalização. Apesar de apresentar uma distribuição de classes mais equilibrada que o Adult, algumas cultivares são minoritárias. Por isso, também foi realizado balanceamento por oversampling para igualar o número de amostras de cada classe antes da divisão em treino e teste. Essa preparação garante que os métodos de agrupamento possam explorar de

forma justa as relações entre as amostras e as classes reais.

Tamanho do dataset original: 13611 amostras, 17 colunas

Tamanho do dataset balanceado: 24822 amostras, 17 colunas




Fig. 3. Distribuição das classes no dataset Dry Bean antes do balanceamento.



Fig. 4. Distribuição das classes no dataset Dry Bean após o balanceamento por oversampling.

B. Seleção do Número de Clusters: Método do Cotovelo

Antes de aplicar os algoritmos de agrupamento, foi utilizado o método do cotovelo para determinar o número ideal de clusters em cada conjunto de dados. O método consiste em executar o KMeans para diferentes valores de k e calcular a soma dos erros quadráticos dentro dos clusters (inertia). O ponto em que a redução do erro começa a diminuir significativamente indica o número adequado de clusters, conhecido como "cotovelo" da curva. Esse valor de k foi então utilizado como referência para todos os algoritmos testados, garantindo uma comparação justa entre os métodos.

No dataset Adult, o método do cotovelo sugeriu a utilização de 2 clusters, alinhando-se ao número de classes reais (renda $\leq 50K$ e $> 50K$). Já no Dry Bean, o cotovelo foi observado em

$k = 7$, correspondente ao número de cultivares presentes no conjunto.

As Figuras ?? e ?? ilustram as curvas do método do cotovelo para os dois datasets.



Fig. 5. Curva do método do cotovelo para o dataset Adult.



Fig. 6. Curva do método do cotovelo para o dataset Dry Bean.

Setup de Teste:

- **Divisão dos dados:** 70% para treinamento e 30% para teste, com estratificação das classes.
- **Pré-processamento:** Codificação numérica das variáveis categóricas (quando presentes) e normalização dos atributos.
- **Balanceamento:** No Adult, foi realizado oversampling para igualar as classes; no Dry Bean, também foi realizado balanceamento por oversampling devido à presença de classes minoritárias.

- **Seleção do número de clusters:** Adult: 2 clusters (duas classes); Dry Bean: 7 clusters (sete classes), conforme sugerido pelo método do cotovelo.
- **Execuções:** 30 repetições com diferentes sementes para garantir robustez estatística dos resultados.
- **Parâmetros do algoritmo:** (Descreva aqui os parâmetros específicos do algoritmo, como grau de fuzzificação para Fuzzy C-Means, matriz de covariância para Gustafson-Kessel, etc.)

C. KMeans

O algoritmo KMeans foi aplicado de forma supervisionada tanto ao conjunto de dados Adult (balanceado) quanto ao Dry Bean, permitindo comparar o desempenho do método em cenários binário e multiclasse.

Resultados:

Adult (balanceado):

- **Acurácia média:** (preencher valor)
- **Precisão média:** (preencher valor)
- **Recall médio:** (preencher valor)
- **Especificidade média:** (preencher valor)
- **F1-score médio:** (preencher valor)

As Figuras ??, ?? e ?? ilustram a estabilidade da acurácia, o erro médio quadrático e a matriz de confusão média, respectivamente.




Fig. 7. Acurácia por repetição do KMeans no Adult balanceado.




Fig. 8. Erro médio quadrático (MSE) por repetição no Adult balanceado.

Dry Bean:

- **Acurácia média:** (preencher valor)




Fig. 9. Matriz de confusão média das execuções no Adult balanceado.

- **Precisão média:** (preencher valor)
- **Recall médio:** (preencher valor)
- **Especificidade média:** (preencher valor)
- **F1-score médio:** (preencher valor)

As Figuras ??, ?? e ?? ilustram a estabilidade da acurácia, o erro médio quadrático e a matriz de confusão média, respectivamente.



Fig. 10. Acurácia por repetição do KMeans no Dry Bean.

Discussão:

Os resultados mostram que o KMeans supervisionado é capaz de identificar padrões relevantes tanto em problemas binários (Adult) quanto multiclasse (Dry Bean), desde que o pré-processamento e a escolha do número de clusters sejam adequados. No Adult, o balanceamento das classes foi fundamental para evitar viés, enquanto no Dry Bean a distribuição natural das classes já era satisfatória. A análise das métricas e das matrizes de confusão revela que o desempenho do KMeans



Fig. 11. Erro médio quadrático (MSE) por repetição no Dry Bean.



Fig. 12. Matriz de confusão média das execuções no Dry Bean.

é consistente ao longo das execuções, mas pode ser impactado pela sobreposição entre classes e pela escolha dos parâmetros iniciais. Recomenda-se, para trabalhos futuros, comparar com outros métodos e explorar técnicas de inicialização e ajuste fino dos hiperparâmetros.

D. Fuzzy C-Means

E. Gustafson-Kessel

IV. CONCLUSÃO

O sistema fuzzy Mamdani desenvolvido mostrou-se robusto, flexível e interpretável, sendo capaz de fornecer

recomendações qualitativas de ventilação adequadas ao contexto de conforto térmico e eficiência energética. O método foi fundamentado teoricamente, detalhado em suas etapas e validado por meio de resultados gráficos e quantitativos, demonstrando sua eficácia para tomada de decisão sob incerteza em ambientes reais.

Por exemplo, no cenário 1 (temperatura de 28°C, umidade de 80% e 15 pessoas), o sistema recomendou ventilação **FORTE**, com valor centroide de 62,44, refletindo corretamente a necessidade de maior renovação do ar em ambientes quentes, úmidos e cheios.

A abordagem fuzzy permite fácil adaptação a diferentes contextos e requisitos, além de lidar bem com incertezas e variações das condições ambientais. O estudo reforça a importância da escolha adequada das funções de pertinência, operadores e técnicas de defuzzificação para o desempenho do sistema.