

Classificação Supervisionada com Algoritmos de Agrupamento

*Trabalho prático de Inteligência Computacional

2nd Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
leonardovieiraxy@gmail.com

CONTENTS

I	Introdução	1
II	Metodologia	2
II-A	Bases de Dados	2
II-B	Balanceamento das Classes	2
II-C	Algoritmos de Agrupamento	2
II-D	Métricas de Avaliação	3
II-E	Visualização dos Resultados	3
II-F	Seleção do Número de Clusters: Método do Cotovelo	3
III	Resultados e Discussão	3
III-A	Bases de Dados e Pré-processamento	3
III-B	Seleção do Número de Clusters: Método do Cotovelo	4
III-C	Setup 1 - KMeans: Resultados nos Datasets Adult e Dry Bean	5
III-C1	Adult (Balanceado)	5
III-C2	Dry Bean (Balanceado)	5
III-D	Setup 2 - Fuzzy C-Means: Resultados nos Datasets Adult e Dry Bean	6
III-D1	Adult (Balanceado)	6
III-D2	Dry Bean (Balanceado)	6
III-E	Setup 3 - Agglomerative: Resultados nos Datasets Adult e Dry Bean	7
III-E1	Adult (Balanceado)	7
III-E2	Dry Bean (Balanceado)	7
IV	Conclusão	8
	Referências	8

Resumo—Este trabalho apresenta a implementação, análise e comparação padronizada de diferentes algoritmos de agrupamento aplicados aos conjuntos de dados Adult e Dry Bean. Foram avaliados os métodos KMeans, Fuzzy C-Means e Agglomerativo, seguindo um pipeline didático com etapas de balanceamento das classes, pré-processamento, definição do número de clusters, repetição dos experimentos e visualização dos resultados.

Trabalho desenvolvido para a disciplina de Inteligência Computacional, Programa de Pós-Graduação, CEFET-MG.

A avaliação quantitativa foi realizada por meio de métricas padronizadas, como acurácia média, desvio padrão e matriz de confusão média em porcentagem, além de visualizações dos agrupamentos e centros dos clusters via PCA. Os resultados destacam as características, vantagens e limitações de cada abordagem, evidenciando a importância da escolha do método conforme a natureza dos dados e o objetivo da análise. O estudo contribui de forma didática para a compreensão e comparação dos principais algoritmos de clustering e suas aplicações práticas em ciência de dados.

Palavras-chave—Agrupamento, clustering, KMeans, Fuzzy C-Means, Agglomerativo, balanceamento de classes, análise quantitativa, matriz de confusão, PCA, Adult, Dry Bean, ciência de dados.

I. INTRODUÇÃO

A análise e classificação de dados complexos são desafios centrais em Inteligência Computacional, especialmente diante de conjuntos de dados reais que apresentam alta dimensionalidade, múltiplas classes e estruturas não triviais. Métodos de agrupamento (clustering) desempenham papel fundamental na descoberta de padrões, segmentação e análise exploratória em diversas áreas, como ciência de dados, engenharia, saúde e ciências sociais.

Neste trabalho, diferentes algoritmos de agrupamento — KMeans, Fuzzy C-Means e Agglomerativo — são implementados, documentados e comparados de forma padronizada, utilizando os conjuntos de dados Adult e Dry Bean. Cada método é explorado em notebooks didáticos, seguindo um pipeline estruturado e numerado: importação de bibliotecas, carregamento, balanceamento das classes, pré-processamento, definição do número de clusters, implementação dos modelos, repetição dos experimentos, visualização dos resultados e análise crítica.

A avaliação dos algoritmos é realizada a partir de métricas quantitativas padronizadas, como acurácia média, desvio padrão e matriz de confusão média em porcentagem, além de visualizações detalhadas dos agrupamentos e centros dos clusters por meio de Análise de Componentes Principais (PCA). Todas as etapas são documentadas e comentadas, visando facilitar a compreensão didática dos conceitos e procedimentos.

A comparação entre os métodos é apresentada de forma crítica e visual, destacando vantagens, limitações e comportamentos frente aos desafios impostos pelos dados, com ênfase na robustez dos resultados e na interpretação dos agrupamentos. O trabalho busca, assim, fornecer uma base sólida e comparativa para o estudo de técnicas de agrupamento.

II. METODOLOGIA

A metodologia adotada neste trabalho consiste na aplicação e comparação de diferentes algoritmos de agrupamento sobre os conjuntos de dados Adult e Dry Bean, utilizando métricas quantitativas e visualização para análise dos resultados. O objetivo é avaliar, de forma didática e acessível, o comportamento de cada método frente a dados reais e variados.

A. Bases de Dados

Adult: O conjunto de dados Adult contém informações demográficas e socioeconômicas de indivíduos, como idade, escolaridade, ocupação, sexo, raça, horas trabalhadas por semana, entre outros. As principais variáveis de entrada incluem:

- **Idade** (numérica, coluna: `age`)
- **Escolaridade** (categórica, coluna: `education`, codificada numericamente)
- **Ocupação** (categórica, coluna: `occupation`, codificada numericamente)
- **Sexo** (categórica, coluna: `sex`, codificada numericamente)
- **Raça** (categórica, coluna: `race`, codificada numericamente)
- **Horas por semana** (numérica, coluna: `hours-per-week`)
- **País de origem** (categórica, coluna: `native-country`, codificada numericamente)

As variáveis categóricas foram convertidas para valores numéricos por meio de codificação (Label Encoding), e os dados foram normalizados. O agrupamento é realizado sem utilizar a variável de saída (`income`), que é usada apenas para avaliação das métricas.

Dry Bean: O conjunto Dry Bean reúne características físicas extraídas de imagens de diferentes tipos de feijões. As variáveis de entrada são todas numéricas e descrevem propriedades morfológicas dos grãos, tais como:

- **Área** (número de pixels, coluna: `Area`)
- **Perímetro** (comprimento do contorno, coluna: `Perimeter`)
- **Comprimento principal** (maior eixo, coluna: `MajorAxisLength`)
- **Largura principal** (menor eixo, coluna: `MinorAxisLength`)
- **Coefficiente de assimetria** (coluna: `AsymmetryCoeff`)
- **Comprimento do retângulo delimitador** (coluna: `BoundingRectLength`)
- **Largura do retângulo delimitador** (coluna: `BoundingRectWidth`)

- **Raio equivalente** (coluna: `EquivDiameter`), **Excêntridade** (coluna: `Eccentricity`), **Solidez** (coluna: `Solidity`), entre outros.

A variável de saída (`Class`) indica o tipo de feijão, mas é utilizada apenas para avaliação dos agrupamentos. Todas as variáveis foram normalizadas.

B. Balanceamento das Classes

Em muitos problemas reais, os conjuntos de dados apresentam distribuição desbalanceada entre as classes, ou seja, algumas categorias possuem muito mais exemplos do que outras. Esse desbalanceamento pode prejudicar algoritmos de agrupamento e classificação, pois os métodos tendem a favorecer as classes majoritárias, resultando em baixa sensibilidade para as classes minoritárias.

Para mitigar esse problema, foi aplicado o **balanceamento por oversampling** nos conjuntos de dados utilizados neste trabalho. O oversampling consiste em aumentar artificialmente o número de exemplos das classes minoritárias, por meio da replicação aleatória de amostras dessas classes, até igualar a quantidade de exemplos da classe majoritária. Dessa forma, garante-se que todas as classes tenham o mesmo peso durante o treinamento e avaliação dos algoritmos.

No caso do conjunto Adult, a variável de saída (renda) apresenta forte desbalanceamento entre as classes $y = 1$ (renda > 50 K) e $y = 0$ (renda ≤ 50 K):

Para o conjunto Dry Bean, algumas variedades de feijão são muito menos frequentes que outras. O balanceamento foi realizado antes da divisão dos dados em treino e teste, assegurando que a avaliação dos métodos reflita um cenário mais justo e comparável entre as classes.

O balanceamento é fundamental para evitar vies nos resultados e garantir que as métricas de avaliação representem de forma adequada o desempenho dos algoritmos em todas as classes presentes nos dados [1], [2].

C. Algoritmos de Agrupamento

Foram avaliados três algoritmos principais: KMeans, Fuzzy C-Means e Agglomerativo. Todos foram implementados e aplicados de forma padronizada, seguindo um pipeline didático que inclui: balanceamento das classes, pré-processamento, definição do número de clusters, repetição dos experimentos com diferentes seeds, avaliação quantitativa e visualização dos resultados. O método Gustafson-Kessel foi considerado, mas não incluído na comparação final devido à instabilidade dos resultados em alguns cenários.

- **KMeans:** Algoritmo particional clássico que agrupa os dados em k clusters, atribuindo cada ponto ao centro mais próximo. É eficiente para grandes volumes de dados, mas sensível à escolha inicial dos centróides e ao formato dos grupos [3].
- **Fuzzy C-Means:** Extensão fuzzy do KMeans, permite que cada ponto pertença a múltiplos clusters com diferentes graus de pertinência, refletindo incertezas e sobreposições naturais nos dados. Proporciona uma segmentação mais flexível e interpretável [4].

- **Agglomerativo:** Método hierárquico que une iterativamente os clusters mais próximos, formando uma estrutura em árvore (dendrograma) e revelando relações hierárquicas nos dados. Não exige a definição prévia do número de clusters e é útil para explorar estruturas hierárquicas, mas pode ser mais custoso computacionalmente [5].

Todos os métodos foram avaliados sem acesso à variável de saída durante o agrupamento, utilizando-a apenas para avaliação das métricas.

D. Métricas de Avaliação

A avaliação dos agrupamentos foi realizada por meio das seguintes métricas padronizadas:

- **Acurácia média:** Proporção média de exemplos corretamente agrupados em relação ao total, calculada sobre múltiplas repetições do experimento.
- **Desvio padrão:** Medida da dispersão das acurácias obtidas nas repetições, indicando a estabilidade do método.
- **Matriz de confusão:** Tabela que resume a quantidade de exemplos de cada classe real atribuídos a cada grupo pelo algoritmo. A matriz de confusão média em porcentagem é obtida normalizando as linhas, permitindo análise detalhada do desempenho em cada classe. Em problemas binários, a matriz pode ser representada como:

	Predito: 1	Predito: 0
Real: 1	VP	FN
Real: 0	FP	VN

- VP = verdadeiro positivo (exemplos da classe 1 corretamente identificados)
- FP = falso positivo (exemplos de outras classes incorretamente atribuídos à classe 1)
- VN = verdadeiro negativo (exemplos das demais classes corretamente não atribuídos à classe 1)
- FN = falso negativo (exemplos da classe 1 incorretamente agrupados em outra classe)

Em problemas multiclasse, cada linha e coluna da matriz representa uma classe diferente: a diagonal principal mostra os acertos (exemplos corretamente agrupados), enquanto os elementos fora da diagonal indicam confusões entre as classes. Assim, a matriz permite identificar quais classes são mais confundidas pelo algoritmo e avaliar detalhadamente o desempenho do agrupamento para cada grupo.

E. Visualização dos Resultados

Para facilitar a interpretação dos agrupamentos, foi utilizada a Análise de Componentes Principais (PCA) para projetar os dados em duas dimensões. Os resultados foram apresentados em gráficos de dispersão, nos quais cada ponto representa uma amostra e as cores indicam o cluster atribuído pelo algoritmo. Os centros dos clusters também foram destacados, permitindo observar a separação e a compactação dos grupos. As matrizes de confusão médias foram apresentadas em formato percentual, padronizando a análise visual entre todos os métodos.

F. Seleção do Número de Clusters: Método do Cotovelo

Para definir o número ideal de clusters, utilizou-se o **método do cotovelo** [6], [7], que avalia uma métrica de qualidade (como o índice silhouette [7]) para diferentes valores de k . O ponto de inflexão da curva indica o valor mais adequado de clusters, equilibrando qualidade e simplicidade do modelo. Esse procedimento foi aplicado separadamente para os conjuntos Adult e Dry Bean, orientando a escolha de k em cada caso.

A metodologia apresentada neste trabalho foi cuidadosamente estruturada para garantir uma análise comparativa clara, didática e reproduzível dos principais algoritmos de agrupamento aplicados a bases de dados reais. A escolha dos métodos, das métricas e das técnicas de visualização permite não apenas avaliar o desempenho quantitativo dos algoritmos, mas também compreender suas características, limitações e adequação a diferentes tipos de dados. Essa abordagem fornece uma base sólida para a discussão dos resultados e para a escolha do método mais apropriado em aplicações práticas de agrupamento.

III. RESULTADOS E DISCUSSÃO

Nesta seção, apresentamos e discutimos os resultados obtidos com a aplicação dos quatro algoritmos de agrupamento (KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo) nos conjuntos de dados Adult e Dry Bean. São analisadas as métricas quantitativas, as visualizações e as principais observações para cada cenário, destacando as vantagens, limitações e particularidades de cada abordagem em contextos binário e multiclasse.

A. Bases de Dados e Pré-processamento

Neste trabalho, utilizamos os conjuntos **Adult** (Census Income) e **Dry Bean**, ambos amplamente empregados em tarefas de classificação e agrupamento. Para garantir comparabilidade, aplicou-se um pré-processamento padronizado: variáveis categóricas foram convertidas em numéricas, atributos normalizados e os dados divididos estratificadamente em 70% para treino e 30% para teste. Também foi realizado balanceamento por oversampling, igualando o número de exemplos em cada classe antes da divisão.

Adult: Aproximadamente 48 mil amostras de adultos dos EUA, com atributos demográficos e socioeconômicos, distribuídas em duas classes principais (renda $>50K$ e $\leq 50K$). O balanceamento foi essencial para evitar predominância de uma classe e garantir avaliações justas.

A Figura 1 apresenta a distribuição das classes no dataset Adult antes do balanceamento. Após o balanceamento, a nova distribuição pode ser observada na Figura 2.

Dry Bean: O conjunto Dry Bean possui 13.611 amostras de feijões secos, distribuídas em sete classes principais (cultivares): Seker, Barbunya, Bombay, Cali, Horoz, Sira e Derma-son, com atributos morfológicos extraídos de imagens. Apesar de uma distribuição mais equilibrada que o Adult, algumas cultivares eram minoritárias, tornando o balanceamento importante para análises imparciais.




Fig. 1. Distribuição das classes no dataset Adult antes do balanceamento ($n \approx 48.842$ amostras).




Fig. 2. Distribuição das classes no dataset Adult após o balanceamento por oversampling ($n = 73.842$ amostras).

A Figura 3 mostra a distribuição das classes no dataset Dry Bean antes do balanceamento. A distribuição das classes após o balanceamento está ilustrada na Figura 4.




Fig. 3. Distribuição das classes no dataset Dry Bean antes do balanceamento ($n = 13.611$ amostras).




Fig. 4. Distribuição das classes no dataset Dry Bean após o balanceamento por oversampling ($n = 24.822$ amostras).

A Figura 5 mostra a projeção das amostras do Dry Bean balanceado no espaço 2D do PCA, coloridas pelas classes verdadeiras, enquanto a Figura 6 apresenta a projeção das amostras do Adult balanceado, também coloridas pelas classes verdadeiras.




Fig. 5. Projeção das amostras do Dry Bean balanceado no espaço 2D do PCA, coloridas pelas classes verdadeiras.




Fig. 6. Projeção das amostras do Adult balanceado no espaço 2D do PCA, coloridas pelas classes verdadeiras.

B. Seleção do Número de Clusters: Método do Cotovelo

A escolha do número de clusters (k) foi feita pelo **método do cotovelo** [6], que consiste em analisar o gráfico de uma métrica de agrupamento para diferentes valores de k e identificar o ponto onde a redução dessa métrica passa a ser menos acentuada. Esse ponto, chamado de "cotovelo", indica o valor mais adequado de clusters para representar a estrutura dos dados.

No conjunto **Adult**, o cotovelo foi observado em $k = 8$ (Figura 7), sugerindo a presença de subgrupos além das duas classes reais. Para o **Dry Bean**, o cotovelo ocorreu em $k = 7$ (Figura 8), valor alinhado ao número de cultivares.




Fig. 7. Curva do método do cotovelo para o dataset Adult balanceado. O "cotovelo" ocorre em $k = 8$.




Fig. 8. Curva do método do cotovelo para o dataset Dry Bean balanceado. O "cotovelo" ocorre em $k = 7$.

Para garantir robustez estatística e avaliar a estabilidade dos resultados, cada experimento foi repetido 30 vezes, variando a semente aleatória (seed) utilizada tanto na divisão dos dados quanto na inicialização dos algoritmos de agrupamento (KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo). Essa abordagem permite analisar a consistência das métricas obtidas e identificar possíveis variações decorrentes da aleatoriedade do processo de agrupamento e da separação dos conjuntos de treino e teste. Os valores apresentados nas tabelas e gráficos correspondem às médias e desvios padrão dessas repetições, fornecendo uma avaliação mais confiável e comparável do desempenho de cada método.

C. Setup 1 - KMeans: Resultados nos Datasets Adult e Dry Bean

Neste setup, apresentamos os resultados do KMeans supervisionado nos conjuntos Adult e Dry Bean, ambos balanceados e pré-processados. Para cada base, o número de clusters foi definido conforme o método do cotovelo.

1) *Adult (Balanceado)*: No dataset Adult, o KMeans obteve acurácia média de 0.7117 e desvio padrão de 0.2883. A Figura 9 mostra a matriz de confusão média, permitindo analisar o desempenho do agrupamento em cada classe. A separação dos clusters e seus centros pode ser visualizada na Figura 10, que utiliza a projeção PCA dos dados. O gráfico de acurácia por repetição, apresentado na Figura 11, ilustra a variação dos resultados ao longo das execuções.




Fig. 9. Matriz de confusão média (KMeans - Adult Balanceado)




Fig. 10. Visualização PCA dos clusters e centros (KMeans - Adult Balanceado)




Fig. 11. Acurácia por repetição (KMeans - Adult Balanceado)

2) *Dry Bean (Balanceado)*: No conjunto Dry Bean, o KMeans apresentou acurácia média de 0.7537 e desvio padrão de 0.2840. A Figura 12 exibe a matriz de confusão média, enquanto a separação dos clusters e seus centros é ilustrada pela projeção PCA (Figura 13). O gráfico de acurácia por repetição (Figura 14) também está incluído para análise da estabilidade dos resultados.




Fig. 12. Matriz de confusão média (KMeans - Dry Bean Balanceado)




Fig. 13. Visualização PCA dos clusters e centros (KMeans - Dry Bean Balanceado)




Fig. 16. Visualização PCA dos clusters e centros (Fuzzy C-Means - Adult Balanceado)




Fig. 14. Acurácia por repetição (KMeans - Dry Bean Balanceado)




Fig. 17. Acurácia por repetição (Fuzzy C-Means - Adult Balanceado)

D. Setup 2 - Fuzzy C-Means: Resultados nos Datasets Adult e Dry Bean

Neste setup, apresentamos os resultados do Fuzzy C-Means supervisionado nos conjuntos Adult e Dry Bean, ambos balanceados e pré-processados. O número de clusters foi definido conforme o método do cotovelo.

1) *Adult (Balanceado)*: No dataset Adult, o Fuzzy C-Means obteve acurácia média de 0.7259 e desvio padrão de 0.0034. A Figura 15 apresenta a matriz de confusão média, permitindo avaliar o desempenho do agrupamento em cada classe. A separação dos clusters e seus centros pode ser visualizada na Figura 16, baseada em PCA. O gráfico de acurácia por repetição, apresentado na Figura 17, ilustra a variação dos resultados ao longo das execuções.

2) *Dry Bean (Balanceado)*: No conjunto Dry Bean, o Fuzzy C-Means apresentou acurácia média de 0.8424 e desvio padrão de 0.0205. A Figura 18 mostra a matriz de confusão média, enquanto a separação dos clusters e seus centros é ilustrada pela projeção PCA (Figura 19). O gráfico de acurácia por repetição (Figura 20) também está incluído para análise da estabilidade dos resultados.




Fig. 15. Matriz de confusão (Fuzzy C-Means - Adult Balanceado)




Fig. 18. Matriz de confusão (Fuzzy C-Means - Dry Bean Balanceado)




Fig. 19. Visualização PCA dos clusters e centros (Fuzzy C-Means - Dry Bean Balanceado)




Fig. 20. Acurácia por repetição (Fuzzy C-Means - Dry Bean Balanceado)

E. Setup 3 - Agglomerative: Resultados nos Datasets Adult e Dry Bean

Neste setup, apresentamos os resultados do Agglomerative Clustering supervisionado nos conjuntos Adult e Dry Bean, ambos balanceados e pré-processados. O número de clusters foi definido conforme o método do cotovelo.

1) *Adult (Balanceado)*: No dataset Adult, o Agglomerative obteve acurácia média de 0.6932 e desvio padrão de 0.0148. A Figura 21 mostra a matriz de confusão média, permitindo avaliar o desempenho do agrupamento em cada classe. A separação dos clusters e seus centros pode ser visualizada na Figura 22, baseada em PCA. O gráfico de acurácia por repetição (Figura 23) também está incluído para análise da estabilidade dos resultados.




Fig. 21. Matriz de confusão (Agglomerative - Adult Balanceado)




Fig. 22. Visualização PCA dos clusters e centros (Agglomerative - Adult Balanceado)




Fig. 23. Acurácia por repetição (Agglomerative - Adult Balanceado)

2) *Dry Bean (Balanceado)*: No conjunto Dry Bean, o Agglomerative apresentou acurácia média de 0.6125 e desvio padrão de 0.0112. A Figura 24 mostra a matriz de confusão média, enquanto a separação dos clusters e seus centros é ilustrada pela projeção PCA (Figura 25). O gráfico de acurácia por repetição (Figura 26) também está incluído para análise da estabilidade dos resultados.




Fig. 24. Matriz de confusão (Agglomerative - Dry Bean Balanceado)




Fig. 25. Visualização PCA dos clusters e centros (Agglomerative - Dry Bean Balanceado)




Fig. 26. Acurácia por repetição (Agglomerative - Dry Bean Balanceado)

IV. CONCLUSÃO

Este trabalho apresentou uma análise comparativa e padronizada dos algoritmos de agrupamento KMeans, Fuzzy C-Means e Agglomerativo aplicados aos conjuntos de dados Adult e Dry Bean. A padronização do pipeline experimental, com balanceamento das classes, repetição dos experimentos, uso de métricas quantitativas e visualizações, permitiu uma avaliação justa e didática do desempenho de cada método.

Os resultados evidenciaram que:

- O **Fuzzy C-Means** apresentou o melhor desempenho geral, especialmente no conjunto Dry Bean (acurácia média de 0,84), mostrando-se robusto para problemas multiclasse e dados com sobreposição entre grupos.
- O **KMeans** teve desempenho intermediário, com acurácia razoável em ambos os conjuntos (0,71 no Adult e 0,75 no Dry Bean), sendo mais estável no Adult (menor desvio padrão) e eficiente para clusters bem separados.
- O **Agglomerativo** apresentou desempenho inferior, principalmente no Dry Bean (acurácia média de 0,27), indicando limitação para dados com muitas classes ou estrutura complexa. O alto desvio padrão sugere instabilidade e sensibilidade à estrutura dos dados.

De modo geral, a escolha do algoritmo mais adequado depende da natureza dos dados, do número de classes e da necessidade de robustez frente a ruídos e desbalanceamento. O estudo reforça a importância de pipelines padronizados, análise crítica dos resultados e da avaliação quantitativa e visual para a aplicação prática de técnicas de agrupamento em ciência de dados.

A tabela a seguir resume a comparação dos métodos quanto a desempenho médio e robustez (desvio padrão), apresentando lado a lado os resultados quantitativos para Adult e Dry Bean:

A seguir, apresentamos tabelas separadas para cada conjunto de dados, detalhando a acurácia média e o desvio padrão dos algoritmos avaliados.

TABLE I
COMPARAÇÃO DOS ALGORITMOS DE AGRUPAMENTO NO CONJUNTO ADULT

Algoritmo	Acurácia Média	Desvio Padrão
KMeans	0,7117	0,0160
Fuzzy C-Means	0,7259	0,0034
Agglomerativo	0,5812	0,1116

TABLE II
COMPARAÇÃO DOS ALGORITMOS DE AGRUPAMENTO NO CONJUNTO DRY BEAN

Algoritmo	Acurácia Média	Desvio Padrão
KMeans	0,7537	0,2840
Fuzzy C-Means	0,8424	0,0205
Agglomerativo	0,2694	0,1546

De modo geral, a escolha do algoritmo mais adequado depende da natureza dos dados, do objetivo da análise e da necessidade de interpretabilidade ou robustez frente a ruídos e desbalanceamento. O estudo reforça a importância de pipelines padronizados e análise crítica para a aplicação prática de técnicas de agrupamento em ciência de dados.

REFERÊNCIAS

- [1] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "Smote: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [2] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [3] S. Lloyd, "Least squares quantization in pcm," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [4] J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*. Springer, 1981.
- [5] D. Müllner, "Modern hierarchical, agglomerative clustering algorithms," *arXiv preprint arXiv:1109.2378*, 2011.
- [6] R. L. Thorndike, "Who belongs in the family?" *Psychometrika*, vol. 18, no. 4, pp. 267–276, 1953.
- [7] P. J. Rousseeuw, "Silhouettes: a graphical aid to the interpretation and validation of cluster analysis," *Journal of computational and applied mathematics*, vol. 20, pp. 53–65, 1987.