

Sistema Fuzzy Takagi-Sugeno para Aproximação de Funções Não Lineares

*Trabalho prático de Inteligência Computacional

1st Fabrício Silva

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
fabriciosilva1992@hotmail.com

2nd Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
leonardovieiraxy@gmail.com

Resumo—Este trabalho apresenta a implementação, análise e comparação de diferentes algoritmos de agrupamento aplicados aos conjuntos de dados Adult e Dry Bean. Foram avaliados os métodos KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, com o objetivo de investigar sua capacidade de identificar padrões e separar grupos em dados reais e multivariados. A metodologia envolveu o pré-processamento dos dados, aplicação dos algoritmos, avaliação dos resultados por métricas quantitativas (acurácia, precisão, revocação, especificidade, F1-score e matriz de confusão) e visualização dos agrupamentos por meio de PCA em duas dimensões. Os resultados obtidos evidenciam as características, vantagens e limitações de cada abordagem, destacando a importância da escolha do método de agrupamento conforme a natureza dos dados e o objetivo da análise. O estudo contribui de forma didática para a compreensão dos principais algoritmos de clustering e suas aplicações práticas em ciência de dados.

Palavras-chave—Lógica fuzzy, Mamdani, controle de ventilação, sistemas inteligentes, funções de pertinência.

I. INTRODUÇÃO

A análise e classificação de dados complexos são desafios centrais em Inteligência Computacional, especialmente diante de conjuntos de dados reais que apresentam alta dimensionalidade, múltiplas classes e estruturas não triviais. Métodos de agrupamento (clustering) desempenham papel fundamental na descoberta de padrões, segmentação e análise exploratória em diversas áreas, como ciência de dados, engenharia, saúde e ciências sociais.

Neste trabalho, diferentes algoritmos de agrupamento, incluindo KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, são implementados, documentados e comparados utilizando os conjuntos de dados Adult e Dry Bean. Cada método é explorado em notebooks didáticos, com etapas

bem definidas: importação de bibliotecas, carregamento e pré-processamento dos dados, implementação dos modelos, aplicação, visualização dos resultados e análise crítica.

A comparação entre os algoritmos é realizada a partir de métricas como acurácia, precisão, revocação, especificidade, F1-score e análise da matriz de confusão, permitindo avaliar o desempenho de cada abordagem frente aos desafios impostos pelos dados. Para facilitar a interpretação dos agrupamentos e dos centros dos clusters, utiliza-se a técnica de Análise de Componentes Principais (PCA) para projeção dos dados em duas dimensões, possibilitando uma visualização clara da separação entre os grupos encontrados.

A abordagem adotada busca não apenas comparar o desempenho dos algoritmos, mas também fornecer uma base didática sólida para compreensão dos conceitos envolvidos, destacando as vantagens e limitações de cada método no contexto dos dados analisados. Como discutido em [1], sistemas fuzzy são eficazes para aproximação de funções não lineares.

II. METODOLOGIA

III. METODOLOGIA

A metodologia adotada neste trabalho consiste na aplicação e comparação de diferentes algoritmos de agrupamento sobre os conjuntos de dados Adult e Dry Bean, utilizando métricas quantitativas e visualização para análise dos resultados. O objetivo é avaliar, de forma didática e acessível, o comportamento de cada método frente a dados reais e variados.

A. Bases de Dados

Adult: O conjunto de dados Adult contém informações demográficas e socioeconômicas de indivíduos, como idade, escolaridade, ocupação, sexo, raça, horas trabalhadas por semana, entre outros. As principais variáveis de entrada incluem:

- **Idade** (numérica, coluna: age)

- **Escolaridade** (categórica, coluna: `education`, codificada numericamente)
- **Ocupação** (categórica, coluna: `occupation`, codificada numericamente)
- **Sexo** (categórica, coluna: `sex`, codificada numericamente)
- **Raça** (categórica, coluna: `race`, codificada numericamente)
- **Horas por semana** (numérica, coluna: `hours-per-week`)
- **País de origem** (categórica, coluna: `native-country`, codificada numericamente)

As variáveis categóricas foram convertidas para valores numéricos por meio de codificação (Label Encoding), e os dados foram normalizados. O agrupamento é realizado sem utilizar a variável de saída (`income`), que é usada apenas para avaliação das métricas.

Dry Bean: O conjunto Dry Bean reúne características físicas extraídas de imagens de diferentes tipos de feijões. As variáveis de entrada são todas numéricas e descrevem propriedades morfológicas dos grãos, tais como:

- **Área** (número de pixels, coluna: `Area`)
- **Perímetro** (comprimento do contorno, coluna: `Perimeter`)
- **Comprimento principal** (maior eixo, coluna: `MajorAxisLength`)
- **Largura principal** (menor eixo, coluna: `MinorAxisLength`)
- **Coefficiente de assimetria** (coluna: `AsymmetryCoeff`)
- **Comprimento do retângulo delimitador** (coluna: `BoundingRectLength`)
- **Largura do retângulo delimitador** (coluna: `BoundingRectWidth`)
- **Raio equivalente** (coluna: `EquivDiameter`), **Excentricidade** (coluna: `Eccentricity`), **Solidez** (coluna: `Solidity`), entre outros.

A variável de saída (`Class`) indica o tipo de feijão, mas é utilizada apenas para avaliação dos agrupamentos. Todas as variáveis foram normalizadas.

B. Descrição e Pseudocódigo dos Algoritmos de Agrupamento

Foram avaliados quatro algoritmos principais, descritos a seguir juntamente com seus respectivos pseudocódigos para facilitar a compreensão didática do funcionamento de cada método:

KMeans: Algoritmo que particiona os dados em k grupos, alternando entre atribuir cada ponto ao centro mais próximo e recalculando os centros como a média dos pontos atribuídos. É eficiente para clusters esféricos e de tamanho semelhante.

- 1: Escolha o número de clusters k e inicialize aleatoriamente os centros dos clusters.
- 2: **while** os centros mudarem e não atingirem o número máximo de iterações **do**
- 3: Atribua cada ponto de dado ao centro mais próximo (menor distância Euclidiana).

- 4: Atualize os centros dos clusters calculando a média dos pontos atribuídos a cada cluster.
- 5: **end while**

Fuzzy C-Means: Extensão do KMeans que permite que cada ponto pertença a múltiplos clusters, com diferentes graus de pertinência. Útil quando há sobreposição entre os grupos ou incerteza na separação dos dados.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingirem o número máximo de iterações **do**
- 3: Atualize os centros dos clusters considerando os graus de pertinência de cada ponto.
- 4: Atualize a matriz de pertinência U com base nas distâncias dos pontos aos centros.
- 5: **end while**

Gustafson-Kessel: Generalização do Fuzzy C-Means que permite que cada cluster tenha sua própria matriz de covariância, adaptando-se a diferentes formas e orientações. Utiliza distâncias Mahalanobis adaptadas.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingirem o número máximo de iterações **do**
- 3: Para cada cluster, calcule o centro e a matriz de covariância adaptativa.
- 4: Atualize a matriz de pertinência U considerando as distâncias Mahalanobis adaptadas.
- 5: **end while**

Agglomerativo: Método hierárquico que começa considerando cada ponto como um cluster individual e une os clusters mais próximos em cada etapa, formando uma árvore de agrupamentos (dendrograma).

- 1: Considere cada ponto como um cluster individual.
- 2: **while** houver mais de um cluster **do**
- 3: Calcule as distâncias entre todos os pares de clusters.
- 4: Una os dois clusters mais próximos em um novo cluster.
- 5: **end while**

Esses pseudocódigos resumem o funcionamento básico de cada método, facilitando a compreensão dos passos principais de cada algoritmo de agrupamento.

C. Métricas de Avaliação

A avaliação dos agrupamentos foi realizada por meio de métricas clássicas de comparação entre os rótulos verdadeiros e os grupos encontrados:

- **Acurácia:** Proporção de exemplos corretamente agrupados em relação ao total.
- **Precisão:** Proporção de exemplos classificados como pertencentes a um grupo que realmente pertencem a esse grupo.
- **Revocação (Recall):** Proporção de exemplos de um grupo real que foram corretamente identificados pelo algoritmo.

- **Especificidade:** Proporção de exemplos negativos corretamente identificados como não pertencentes a um grupo.
- **F1-score:** Média harmônica entre precisão e revocação, útil para avaliar o equilíbrio entre as duas métricas.
- **Matriz de Confusão:** Tabela que resume os acertos e erros de classificação para cada grupo, permitindo análise detalhada dos padrões de agrupamento.

D. Visualização dos Resultados

Para facilitar a interpretação dos agrupamentos, foi utilizada a Análise de Componentes Principais (PCA) para projetar os dados em duas dimensões. Os resultados foram apresentados em gráficos de dispersão, nos quais cada ponto representa uma amostra e as cores indicam o cluster atribuído pelo algoritmo. Os centros dos clusters também foram destacados, permitindo observar a separação e a compactação dos grupos.

A metodologia apresentada neste trabalho foi cuidadosamente estruturada para garantir uma análise comparativa clara, didática e reproduzível dos principais algoritmos de agrupamento aplicados a bases de dados reais. A escolha dos métodos, das métricas e das técnicas de visualização permite não apenas avaliar o desempenho quantitativo dos algoritmos, mas também compreender suas características, limitações e adequação a diferentes tipos de dados. Essa abordagem fornece uma base sólida para a discussão dos resultados e para a escolha do método mais apropriado em aplicações práticas de agrupamento.

IV. RESULTADOS E DISCUSSÃO

V. CONCLUSÃO

O sistema fuzzy Mamdani desenvolvido mostrou-se robusto, flexível e interpretável, sendo capaz de fornecer recomendações qualitativas de ventilação adequadas ao contexto de conforto térmico e eficiência energética. O método foi fundamentado teoricamente, detalhado em suas etapas e validado por meio de resultados gráficos e quantitativos, demonstrando sua eficácia para tomada de decisão sob incerteza em ambientes reais.

Por exemplo, no cenário 1 (temperatura de 28°C, umidade de 80% e 15 pessoas), o sistema recomendou ventilação **FORTE**, com valor centroide de 62,44, refletindo corretamente a necessidade de maior renovação do ar em ambientes quentes, úmidos e cheios.

A abordagem fuzzy permite fácil adaptação a diferentes contextos e requisitos, além de lidar bem com incertezas e variações das condições ambientais. O estudo reforça a importância da escolha adequada das funções de pertinência, operadores e técnicas de defuzzificação para o desempenho do sistema.

REFERÊNCIAS

- [1] T. Takagi and M. Sugeno, "Fuzzy identification of systems and its applications to modeling and control," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 15, no. 1, pp. 116–132, 1985.