

Sistema Fuzzy Takagi-Sugeno para Aproximação de Funções Não Lineares

*Trabalho prático de Inteligência Computacional

1st Fabrício Silva

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
fabriciosilva1992@hotmail.com

2nd Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
leonardovieiraxy@gmail.com

Resumo—Este trabalho apresenta a implementação, análise e comparação de diferentes algoritmos de agrupamento aplicados aos conjuntos de dados Adult e Dry Bean. Foram avaliados os métodos KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, com o objetivo de investigar sua capacidade de identificar padrões e separar grupos em dados reais e multivariados. A metodologia envolveu o pré-processamento dos dados, aplicação dos algoritmos, avaliação dos resultados por métricas quantitativas (acurácia, precisão, revocação, especificidade, F1-score e matriz de confusão) e visualização dos agrupamentos por meio de PCA em duas dimensões. Os resultados obtidos evidenciam as características, vantagens e limitações de cada abordagem, destacando a importância da escolha do método de agrupamento conforme a natureza dos dados e o objetivo da análise. O estudo contribui de forma didática para a compreensão dos principais algoritmos de clustering e suas aplicações práticas em ciência de dados.

Palavras-chave—Lógica fuzzy, Mamdani, controle de ventilação, sistemas inteligentes, funções de pertinência.

I. INTRODUÇÃO

A análise e classificação de dados complexos são desafios centrais em Inteligência Computacional, especialmente diante de conjuntos de dados reais que apresentam alta dimensionalidade, múltiplas classes e estruturas não triviais. Métodos de agrupamento (clustering) desempenham papel fundamental na descoberta de padrões, segmentação e análise exploratória em diversas áreas, como ciência de dados, engenharia, saúde e ciências sociais.

Neste trabalho, diferentes algoritmos de agrupamento, incluindo KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, são implementados, documentados e comparados utilizando os conjuntos de dados Adult e Dry Bean. Cada método é explorado em notebooks didáticos, com etapas

bem definidas: importação de bibliotecas, carregamento e pré-processamento dos dados, implementação dos modelos, aplicação, visualização dos resultados e análise crítica.

A comparação entre os algoritmos é realizada a partir de métricas como acurácia, precisão, revocação, especificidade, F1-score e análise da matriz de confusão, permitindo avaliar o desempenho de cada abordagem frente aos desafios impostos pelos dados. Para facilitar a interpretação dos agrupamentos e dos centros dos clusters, utiliza-se a técnica de Análise de Componentes Principais (PCA) para projeção dos dados em duas dimensões, possibilitando uma visualização clara da separação entre os grupos encontrados.

A abordagem adotada busca não apenas comparar o desempenho dos algoritmos, mas também fornecer uma base didática sólida para compreensão dos conceitos envolvidos, destacando as vantagens e limitações de cada método no contexto dos dados analisados. Como discutido em [1], sistemas fuzzy são eficazes para aproximação de funções não lineares.

II. METODOLOGIA

A metodologia adotada neste trabalho consiste na aplicação e comparação de diferentes algoritmos de agrupamento sobre os conjuntos de dados Adult e Dry Bean, utilizando métricas quantitativas e visualização para análise dos resultados. O objetivo é avaliar, de forma didática e acessível, o comportamento de cada método frente a dados reais e variados.

A. Bases de Dados

Adult: O conjunto de dados Adult contém informações demográficas e socioeconômicas de indivíduos, como idade, escolaridade, ocupação, sexo, raça, horas trabalhadas por semana, entre outros. As principais variáveis de entrada incluem:

- **Idade** (numérica, coluna: age)

- **Escolaridade** (categórica, coluna: `education`, codificada numericamente)
- **Ocupação** (categórica, coluna: `occupation`, codificada numericamente)
- **Sexo** (categórica, coluna: `sex`, codificada numericamente)
- **Raça** (categórica, coluna: `race`, codificada numericamente)
- **Horas por semana** (numérica, coluna: `hours-per-week`)
- **País de origem** (categórica, coluna: `native-country`, codificada numericamente)

As variáveis categóricas foram convertidas para valores numéricos por meio de codificação (Label Encoding), e os dados foram normalizados. O agrupamento é realizado sem utilizar a variável de saída (`income`), que é usada apenas para avaliação das métricas.

Dry Bean: O conjunto Dry Bean reúne características físicas extraídas de imagens de diferentes tipos de feijões. As variáveis de entrada são todas numéricas e descrevem propriedades morfológicas dos grãos, tais como:

- **Área** (número de pixels, coluna: `Area`)
- **Perímetro** (comprimento do contorno, coluna: `Perimeter`)
- **Comprimento principal** (maior eixo, coluna: `MajorAxisLength`)
- **Largura principal** (menor eixo, coluna: `MinorAxisLength`)
- **Coeficiente de assimetria** (coluna: `AsymmetryCoeff`)
- **Comprimento do retângulo delimitador** (coluna: `BoundingRectLength`)
- **Largura do retângulo delimitador** (coluna: `BoundingRectWidth`)
- **Raio equivalente** (coluna: `EquivDiameter`), **Excentricidade** (coluna: `Eccentricity`), **Solidez** (coluna: `Solidity`), entre outros.

A variável de saída (`Class`) indica o tipo de feijão, mas é utilizada apenas para avaliação dos agrupamentos. Todas as variáveis foram normalizadas.

B. Descrição e Pseudocódigo dos Algoritmos de Agrupamento

Foram avaliados quatro algoritmos principais, descritos a seguir juntamente com seus respectivos pseudocódigos para facilitar a compreensão didática do funcionamento de cada método:

KMeans: Algoritmo que particiona os dados em k grupos, alternando entre atribuir cada ponto ao centro mais próximo e recalculando os centros como a média dos pontos atribuídos. É eficiente para clusters esféricos e de tamanho semelhante.

- 1: Escolha o número de clusters k e inicialize aleatoriamente os centros dos clusters.
- 2: **while** os centros mudarem e não atingirem o número máximo de iterações **do**
- 3: Atribua cada ponto de dado ao centro mais próximo (menor distância Euclidiana).

- 4: Atualize os centros dos clusters calculando a média dos pontos atribuídos a cada cluster.
- 5: **end while**

Fuzzy C-Means: Extensão do KMeans que permite que cada ponto pertença a múltiplos clusters, com diferentes graus de pertinência. Útil quando há sobreposição entre os grupos ou incerteza na separação dos dados.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingirem o número máximo de iterações **do**
- 3: Atualize os centros dos clusters considerando os graus de pertinência de cada ponto.
- 4: Atualize a matriz de pertinência U com base nas distâncias dos pontos aos centros.
- 5: **end while**

Gustafson-Kessel: Generalização do Fuzzy C-Means que permite que cada cluster tenha sua própria matriz de covariância, adaptando-se a diferentes formas e orientações. Utiliza distâncias Mahalanobis adaptadas.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingirem o número máximo de iterações **do**
- 3: Para cada cluster, calcule o centro e a matriz de covariância adaptativa.
- 4: Atualize a matriz de pertinência U considerando as distâncias Mahalanobis adaptadas.
- 5: **end while**

Agglomerativo: Método hierárquico que começa considerando cada ponto como um cluster individual e une os clusters mais próximos em cada etapa, formando uma árvore de agrupamentos (dendrograma).

- 1: Considere cada ponto como um cluster individual.
- 2: **while** houver mais de um cluster **do**
- 3: Calcule as distâncias entre todos os pares de clusters.
- 4: Una os dois clusters mais próximos em um novo cluster.
- 5: **end while**

Esses pseudocódigos resumem o funcionamento básico de cada método, facilitando a compreensão dos passos principais de cada algoritmo de agrupamento.

C. Métricas de Avaliação

A avaliação dos agrupamentos foi realizada por meio de métricas clássicas de comparação entre os rótulos verdadeiros e os grupos encontrados:

- **Acurácia:** Proporção de exemplos corretamente agrupados em relação ao total.
- **Precisão:** Proporção de exemplos classificados como pertencentes a um grupo que realmente pertencem a esse grupo.
- **Revocação (Recall):** Proporção de exemplos de um grupo real que foram corretamente identificados pelo algoritmo.

- **Especificidade:** Proporção de exemplos negativos corretamente identificados como não pertencentes a um grupo.
- **F1-score:** Média harmônica entre precisão e revocação, útil para avaliar o equilíbrio entre as duas métricas.
- **Matriz de Confusão:** Tabela que resume os acertos e erros de classificação para cada grupo, permitindo análise detalhada dos padrões de agrupamento.

D. Visualização dos Resultados

Para facilitar a interpretação dos agrupamentos, foi utilizada a Análise de Componentes Principais (PCA) para projetar os dados em duas dimensões. Os resultados foram apresentados em gráficos de dispersão, nos quais cada ponto representa uma amostra e as cores indicam o cluster atribuído pelo algoritmo. Os centros dos clusters também foram destacados, permitindo observar a separação e a compactação dos grupos.

E. Seleção do Número de Clusters: Método do Cotovelo

Para determinar o número ideal de clusters a ser utilizado nos algoritmos de agrupamento, foi empregado o **método do cotovelo**. Essa técnica consiste em executar o algoritmo KMeans para diferentes valores de k (número de clusters) e calcular, para cada valor, a soma das distâncias quadráticas (inércia) entre os pontos e seus respectivos centros de cluster. O valor de k ideal é identificado no ponto em que a redução da inércia passa a ser menos significativa, formando um "cotovelo" na curva. Esse ponto indica um equilíbrio entre a compactação dos clusters e a complexidade do modelo, evitando tanto o subajuste quanto o sobreajuste.

No contexto deste trabalho, o método do cotovelo foi aplicado separadamente para os conjuntos de dados Adult e Dry Bean, guiando a escolha do número de clusters para cada algoritmo testado. As curvas geradas e a análise visual do cotovelo permitiram definir, de forma objetiva, o valor de k mais apropriado para cada cenário.

A metodologia apresentada neste trabalho foi cuidadosamente estruturada para garantir uma análise comparativa clara, didática e reproduzível dos principais algoritmos de agrupamento aplicados a bases de dados reais. A escolha dos métodos, das métricas e das técnicas de visualização permite não apenas avaliar o desempenho quantitativo dos algoritmos, mas também compreender suas características, limitações e adequação a diferentes tipos de dados. Essa abordagem fornece uma base sólida para a discussão dos resultados e para a escolha do método mais apropriado em aplicações práticas de agrupamento.

III. RESULTADOS E DISCUSSÃO

Nesta seção, apresentamos e discutimos os resultados obtidos com a aplicação dos quatro algoritmos de agrupamento (KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo) nos conjuntos de dados Adult e Dry Bean. São analisadas as métricas quantitativas, as visualizações e as principais observações para cada cenário, destacando as vantagens, limitações e particularidades de cada abordagem em contextos binário e multiclasse.

A. Bases de Dados e Pré-processamento

Neste trabalho, utilizamos os conjuntos de dados **Adult** (Census Income) e **Dry Bean**, ambos amplamente empregados em tarefas de classificação e agrupamento. Para garantir a comparabilidade entre os métodos, em ambos os casos foi realizado o seguinte pré-processamento: todas as variáveis categóricas foram transformadas em representações numéricas, os atributos foram normalizados e os dados foram divididos de forma estratificada em 70% para treinamento e 30% para teste. No caso do conjunto Adult, devido ao desbalanceamento entre as classes, aplicou-se também uma técnica de balanceamento (como oversampling) para garantir uma distribuição mais equitativa entre as categorias de renda.

Adult: O conjunto Adult contém aproximadamente 48 mil amostras de indivíduos adultos dos Estados Unidos, com atributos demográficos e socioeconômicos, distribuídos em duas classes principais (renda $\leq 50K$ e $> 50K$). Os atributos incluem variáveis numéricas e categóricas, exigindo codificação e normalização cuidadosas. O balanceamento foi fundamental para evitar viés nos resultados devido à predominância de uma das classes.

Dry Bean: O conjunto Dry Bean é composto por mais de 13 mil amostras de feijões secos de sete diferentes cultivares, com atributos morfológicos extraídos de imagens. Todos os atributos são numéricos, facilitando a aplicação direta das técnicas de normalização. A distribuição das classes é naturalmente mais equilibrada, não sendo necessário aplicar técnicas adicionais de balanceamento. Essa preparação garante que os métodos de agrupamento possam explorar de forma justa as relações entre as amostras e as classes reais.

B. Seleção do Número de Clusters: Método do Cotovelo

Antes de aplicar os algoritmos de agrupamento, foi utilizado o método do cotovelo para determinar o número ideal de clusters em cada conjunto de dados. O método consiste em executar o KMeans para diferentes valores de k e calcular a soma dos erros quadráticos dentro dos clusters (inertia). O ponto em que a redução do erro começa a diminuir significativamente indica o número adequado de clusters, conhecido como "cotovelo" da curva. Esse valor de k foi então utilizado como referência para todos os algoritmos testados, garantindo uma comparação justa entre os métodos.

No dataset Adult, o método do cotovelo sugeriu a utilização de 2 clusters, alinhando-se ao número de classes reais (renda $\leq 50K$ e $> 50K$). Já no Dry Bean, o cotovelo foi observado em $k = 7$, correspondente ao número de cultivares presentes no conjunto.

As Figuras 1 e 2 ilustram as curvas do método do cotovelo para os dois datasets.

Setup de Teste:

- **Divisão dos dados:** 70% para treinamento e 30% para teste, com estratificação das classes.
- **Pré-processamento:** Codificação numérica das variáveis categóricas (quando presentes) e normalização dos atributos.




Fig. 1. Curva do método do cotovelo para o dataset Adult.




Fig. 2. Curva do método do cotovelo para o dataset Dry Bean.

- **Balanceamento:** No Adult, foi realizado oversampling para igualar as classes; no Dry Bean, não foi necessário devido ao equilíbrio natural das classes.
- **Seleção do número de clusters:** Adult: 2 clusters (duas classes); Dry Bean: 7 clusters (sete classes), conforme sugerido pelo método do cotovelo.
- **Execuções:** 30 repetições com diferentes sementes para garantir robustez estatística dos resultados.
- **Parâmetros do algoritmo:** (Descreva aqui os parâmetros específicos do algoritmo, como grau de fuzzificação para Fuzzy C-Means, matriz de covariância para Gustafson-Kessel, etc.)

C. KMeans

O algoritmo KMeans foi aplicado de forma supervisionada tanto ao conjunto de dados Adult (balanceado) quanto ao Dry Bean, permitindo comparar o desempenho do método em cenários binário e multiclasse.

Resultados:

Adult (balanceado):

- **Acurácia média:** (preencher valor)
- **Precisão média:** (preencher valor)
- **Recall médio:** (preencher valor)
- **Especificidade média:** (preencher valor)
- **F1-score médio:** (preencher valor)

As Figuras 3, 4 e 5 ilustram a estabilidade da acurácia, o erro médio quadrático e a matriz de confusão média, respectivamente.

Dry Bean:

- **Acurácia média:** (preencher valor)
- **Precisão média:** (preencher valor)
- **Recall médio:** (preencher valor)




Fig. 3. Acurácia por repetição do KMeans no Adult balanceado.




Fig. 4. Erro médio quadrático (MSE) por repetição no Adult balanceado.

- **Especificidade média:** (preencher valor)
- **F1-score médio:** (preencher valor)

As Figuras 6, 7 e ?? ilustram a estabilidade da acurácia, o erro médio quadrático e a matriz de confusão média, respectivamente.

Discussão:

Os resultados mostram que o KMeans supervisionado é capaz de identificar padrões relevantes tanto em problemas binários (Adult) quanto multiclasse (Dry Bean), desde que o pré-processamento e a escolha do número de clusters sejam adequados. No Adult, o balanceamento das classes foi fundamental para evitar viés, enquanto no Dry Bean a distribuição natural das classes já era satisfatória. A análise das métricas e das matrizes de confusão revela que o desempenho do KMeans é consistente ao longo das execuções, mas pode ser impactado pela sobreposição entre classes e pela escolha dos parâmetros iniciais. Recomenda-se, para trabalhos futuros, comparar com outros métodos e explorar técnicas de inicialização e ajuste fino dos hiperparâmetros.

D. Fuzzy C-Means

E. Gustafson-Kessel

IV. CONCLUSÃO

O sistema fuzzy Mamdani desenvolvido mostrou-se robusto, flexível e interpretável, sendo capaz de fornecer recomendações qualitativas de ventilação adequadas ao contexto de conforto térmico e eficiência energética. O método




Fig. 5. Matriz de confusão média das execuções no Adult balanceado.




Fig. 6. Acurácia por repetição do KMeans no Dry Bean.

foi fundamentado teoricamente, detalhado em suas etapas e validado por meio de resultados gráficos e quantitativos, demonstrando sua eficácia para tomada de decisão sob incerteza em ambientes reais.

Por exemplo, no cenário 1 (temperatura de 28°C, umidade de 80% e 15 pessoas), o sistema recomendou ventilação **FORTE**, com valor centroide de 62,44, refletindo corretamente a necessidade de maior renovação do ar em ambientes quentes, úmidos e cheios.

A abordagem fuzzy permite fácil adaptação a diferentes contextos e requisitos, além de lidar bem com incertezas e variações das condições ambientais. O estudo reforça a importância da escolha adequada das funções de pertinência, operadores e técnicas de defuzzificação para o desempenho do sistema.

REFERÊNCIAS

- [1] T. Takagi and M. Sugeno, "Fuzzy identification of systems and its applications to modeling and control," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 15, no. 1, pp. 116–132, 1985.




Fig. 7. Erro médio quadrático (MSE) por repetição no Dry Bean.