

Classificação Supervisionada com Algoritmos de Agrupamento

*Trabalho prático de Inteligência Computacional

1st Fabrício Silva

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
fabriciosilva1992@hotmail.com

2nd Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional
CEFET-MG

Belo Horizonte, Brasil
leonardovieiraxy@gmail.com

Resumo—Este trabalho apresenta a implementação, análise e comparação de diferentes algoritmos de agrupamento aplicados aos conjuntos de dados Adult e Dry Bean. Foram avaliados os métodos KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, com o objetivo de investigar sua capacidade de identificar padrões e separar grupos em dados reais e multivariados. A metodologia envolveu o pré-processamento dos dados, aplicação dos algoritmos, avaliação dos resultados por métricas quantitativas (acurácia, precisão, revocação, especificidade, F1-score e matriz de confusão) e visualização dos agrupamentos por meio de PCA em duas dimensões. Os resultados obtidos evidenciam as características, vantagens e limitações de cada abordagem, destacando a importância da escolha do método de agrupamento conforme a natureza dos dados e o objetivo da análise. O estudo contribui de forma didática para a compreensão dos principais algoritmos de clustering e suas aplicações práticas em ciência de dados.

Palavras-chave—Lógica fuzzy, Mamdani, controle de ventilação, sistemas inteligentes, funções de pertinência.

I. INTRODUÇÃO

A análise e classificação de dados complexos são desafios centrais em Inteligência Computacional, especialmente diante de conjuntos de dados reais que apresentam alta dimensionalidade, múltiplas classes e estruturas não triviais. Métodos de agrupamento (clustering) desempenham papel fundamental na descoberta de padrões, segmentação e análise exploratória em diversas áreas, como ciência de dados, engenharia, saúde e ciências sociais.

Neste trabalho, diferentes algoritmos de agrupamento, incluindo KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo, são implementados, documentados e comparados utilizando os conjuntos de dados Adult e Dry Bean. Cada método é explorado em notebooks didáticos, com etapas

bem definidas: importação de bibliotecas, carregamento e pré-processamento dos dados, implementação dos modelos, aplicação, visualização dos resultados e análise crítica.

A comparação entre os algoritmos é realizada a partir de métricas como acurácia, precisão, revocação, especificidade, F1-score e análise da matriz de confusão, permitindo avaliar o desempenho de cada abordagem frente aos desafios impostos pelos dados. Para facilitar a interpretação dos agrupamentos e dos centros dos clusters, utiliza-se a técnica de Análise de Componentes Principais (PCA) para projeção dos dados em duas dimensões, possibilitando uma visualização clara da separação entre os grupos encontrados.

A abordagem adotada busca não apenas comparar o desempenho dos algoritmos, mas também fornecer uma base didática sólida para compreensão dos conceitos envolvidos, destacando as vantagens e limitações de cada método no contexto dos dados analisados.

II. METODOLOGIA

A metodologia adotada neste trabalho consiste na aplicação e comparação de diferentes algoritmos de agrupamento sobre os conjuntos de dados Adult e Dry Bean, utilizando métricas quantitativas e visualização para análise dos resultados. O objetivo é avaliar, de forma didática e acessível, o comportamento de cada método frente a dados reais e variados.

A. Bases de Dados

Adult: O conjunto de dados Adult contém informações demográficas e socioeconômicas de indivíduos, como idade, escolaridade, ocupação, sexo, raça, horas trabalhadas por semana, entre outros. As principais variáveis de entrada incluem:

- **Idade** (numérica, coluna: age)
- **Escolaridade** (categórica, coluna: education, codificada numericamente)

- **Ocupação** (categórica, coluna: `occupation`, codificada numericamente)
- **Sexo** (categórica, coluna: `sex`, codificada numericamente)
- **Raça** (categórica, coluna: `race`, codificada numericamente)
- **Horas por semana** (numérica, coluna: `hours-per-week`)
- **País de origem** (categórica, coluna: `native-country`, codificada numericamente)

As variáveis categóricas foram convertidas para valores numéricos por meio de codificação (Label Encoding), e os dados foram normalizados. O agrupamento é realizado sem utilizar a variável de saída (`income`), que é usada apenas para avaliação das métricas.

Dry Bean: O conjunto Dry Bean reúne características físicas extraídas de imagens de diferentes tipos de feijões. As variáveis de entrada são todas numéricas e descrevem propriedades morfológicas dos grãos, tais como:

- **Área** (número de pixels, coluna: `Area`)
- **Perímetro** (comprimento do contorno, coluna: `Perimeter`)
- **Comprimento principal** (maior eixo, coluna: `MajorAxisLength`)
- **Largura principal** (menor eixo, coluna: `MinorAxisLength`)
- **Coefficiente de assimetria** (coluna: `AsymmetryCoeff`)
- **Comprimento do retângulo delimitador** (coluna: `BoundingRectLength`)
- **Largura do retângulo delimitador** (coluna: `BoundingRectWidth`)
- **Raio equivalente** (coluna: `EquivDiameter`), **Excentricidade** (coluna: `Eccentricity`), **Solidez** (coluna: `Solidity`), entre outros.

A variável de saída (`Class`) indica o tipo de feijão, mas é utilizada apenas para avaliação dos agrupamentos. Todas as variáveis foram normalizadas.

B. Balanceamento das Classes

Em muitos problemas reais, os conjuntos de dados apresentam distribuição desbalanceada entre as classes, ou seja, algumas categorias possuem muito mais exemplos do que outras. Esse desbalanceamento pode prejudicar algoritmos de agrupamento e classificação, pois os métodos tendem a favorecer as classes majoritárias, resultando em baixa sensibilidade para as classes minoritárias.

Para mitigar esse problema, foi aplicado o **balanceamento por oversampling** nos conjuntos de dados utilizados neste trabalho. O oversampling consiste em aumentar artificialmente o número de exemplos das classes minoritárias, por meio da replicação aleatória de amostras dessas classes, até igualar a quantidade de exemplos da classe majoritária. Dessa forma, garante-se que todas as classes tenham o mesmo peso durante o treinamento e avaliação dos algoritmos.

No caso do conjunto Adult, a variável de saída (renda) apresenta forte desbalanceamento entre as classes “ $\leq 50K$ ” e

“ $> 50K$ ”. Para o conjunto Dry Bean, algumas variedades de feijão são muito menos frequentes que outras. O balanceamento foi realizado antes da divisão dos dados em treino e teste, assegurando que a avaliação dos métodos reflita um cenário mais justo e comparável entre as classes.

O balanceamento é fundamental para evitar viés nos resultados e garantir que as métricas de avaliação representem de forma adequada o desempenho dos algoritmos em todas as classes presentes nos dados.

C. Descrição e Pseudocódigo dos Algoritmos de Agrupamento

Foram avaliados quatro algoritmos principais, descritos a seguir juntamente com seus respectivos pseudocódigos para facilitar a compreensão didática do funcionamento de cada método:

KMeans: Algoritmo que particiona os dados em k grupos, alternando entre atribuir cada ponto ao centro mais próximo e recalculando os centros como a média dos pontos atribuídos. É eficiente para clusters esféricos e de tamanho semelhante.

- 1: Escolha o número de clusters k e inicialize aleatoriamente os centros dos clusters.
- 2: **while** os centros mudarem e não atingir o número máximo de iterações **do**
- 3: Atribua cada ponto de dado ao centro mais próximo (menor distância Euclidiana).
- 4: Atualize os centros dos clusters calculando a média dos pontos atribuídos a cada cluster.
- 5: **end while**

Fuzzy C-Means: Extensão do KMeans que permite que cada ponto pertença a múltiplos clusters, com diferentes graus de pertinência. Útil quando há sobreposição entre os grupos ou incerteza na separação dos dados.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingir o número máximo de iterações **do**
- 3: Atualize os centros dos clusters considerando os graus de pertinência de cada ponto.
- 4: Atualize a matriz de pertinência U com base nas distâncias dos pontos aos centros.
- 5: **end while**

Gustafson-Kessel: Generalização do Fuzzy C-Means que permite que cada cluster tenha sua própria matriz de covariância, adaptando-se a diferentes formas e orientações. Utiliza distâncias Mahalanobis adaptadas.

- 1: Escolha o número de clusters c e inicialize aleatoriamente a matriz de pertinência U .
- 2: **while** as mudanças em U forem maiores que um limiar e não atingir o número máximo de iterações **do**
- 3: Para cada cluster, calcule o centro e a matriz de covariância adaptativa.
- 4: Atualize a matriz de pertinência U considerando as distâncias Mahalanobis adaptadas.

5: end while

Agglomerativo: Método hierárquico que começa considerando cada ponto como um cluster individual e une os clusters mais próximos em cada etapa, formando uma árvore de agrupamentos (dendrograma).

- 1: Considere cada ponto como um cluster individual.
- 2: **while** houver mais de um cluster **do**
- 3: Calcule as distâncias entre todos os pares de clusters.
- 4: Una os dois clusters mais próximos em um novo cluster.
- 5: **end while**

Esses pseudocódigos resumem o funcionamento básico de cada método, facilitando a compreensão dos passos principais de cada algoritmo de agrupamento.

D. Métricas de Avaliação

A avaliação dos agrupamentos foi realizada por meio de métricas clássicas de comparação entre os rótulos verdadeiros e os grupos encontrados:

- **Acurácia:** Proporção de exemplos corretamente agrupados em relação ao total.

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

- **Precisão:** Proporção de exemplos classificados como pertencentes a um grupo que realmente pertencem a esse grupo.

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (2)$$

- **Revocação (Recall):** Proporção de exemplos de um grupo real que foram corretamente identificados pelo algoritmo.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

- **Especificidade:** Proporção de exemplos negativos corretamente identificados como não pertencentes a um grupo.

$$\text{Especificidade} = \frac{TN}{TN + FP} \quad (4)$$

- **F1-score:** Média harmônica entre precisão e revocação, útil para avaliar o equilíbrio entre as duas métricas.

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (5)$$

- **Matriz de Confusão:** Tabela que resume os acertos e erros de classificação para cada grupo, permitindo análise detalhada dos padrões de agrupamento.

E. Visualização dos Resultados

Para facilitar a interpretação dos agrupamentos, foi utilizada a Análise de Componentes Principais (PCA) para projetar os dados em duas dimensões. Os resultados foram apresentados em gráficos de dispersão, nos quais cada ponto representa uma amostra e as cores indicam o cluster atribuído pelo algoritmo. Os centros dos clusters também foram destacados, permitindo observar a separação e a compactação dos grupos

F. Seleção do Número de Clusters: Método do Cotovelo

Para determinar o número ideal de clusters a ser utilizado nos algoritmos de agrupamento, foi empregado o **método do cotovelo**. Essa técnica consiste em executar o algoritmo KMeans para diferentes valores de k (número de clusters) e calcular, para cada valor, a soma das distâncias quadráticas (inércia) entre os pontos e seus respectivos centros de cluster. O valor de k ideal é identificado no ponto em que a redução da inércia passa a ser menos significativa, formando um "cotovelo" na curva. Esse ponto indica um equilíbrio entre a compactação dos clusters e a complexidade do modelo, evitando tanto o subajuste quanto o sobreajuste.

No contexto deste trabalho, o método do cotovelo foi aplicado separadamente para os conjuntos de dados Adult e Dry Bean, guiando a escolha do número de clusters para cada algoritmo testado. As curvas geradas e a análise visual do cotovelo permitiram definir, de forma objetiva, o valor de k mais apropriado para cada cenário.

A metodologia apresentada neste trabalho foi cuidadosamente estruturada para garantir uma análise comparativa clara, didática e reproduzível dos principais algoritmos de agrupamento aplicados a bases de dados reais. A escolha dos métodos, das métricas e das técnicas de visualização permite não apenas avaliar o desempenho quantitativo dos algoritmos, mas também compreender suas características, limitações e adequação a diferentes tipos de dados. Essa abordagem fornece uma base sólida para a discussão dos resultados e para a escolha do método mais apropriado em aplicações práticas de agrupamento.

III. RESULTADOS E DISCUSSÃO

Nesta seção, apresentamos e discutimos os resultados obtidos com a aplicação dos quatro algoritmos de agrupamento (KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo) nos conjuntos de dados Adult e Dry Bean. São analisadas as métricas quantitativas, as visualizações e as principais observações para cada cenário, destacando as vantagens, limitações e particularidades de cada abordagem em contextos binário e multiclasse.

Fluxo do Setup de Teste:

O processo experimental seguiu a seguinte sequência para ambos os conjuntos de dados:

- 1) **Pré-processamento:** Codificação numérica das variáveis categóricas (quando presentes) e normalização dos atributos.
- 2) **Balanceamento:** Aplicação de oversampling para igualar a quantidade de exemplos em cada classe (tanto no Adult quanto no Dry Bean).
- 3) **Divisão dos dados:** Separação estratificada em 70% para treinamento e 30% para teste.
- 4) **Seleção do número de clusters:** Definição do número de clusters com base no método do cotovelo (Adult: 2; Dry Bean: 7).
- 5) **Execuções:** Realização de 30 repetições com diferentes sementes para garantir robustez estatística dos resultados.

- 6) **Parâmetros do algoritmo:** (Descrever os parâmetros específicos de cada algoritmo, como grau de fuzzificação para Fuzzy C-Means, matriz de covariância para Gustafson-Kessel, etc.)

A. Bases de Dados e Pré-processamento

Neste trabalho, utilizamos os conjuntos de dados **Adult** (Census Income) e **Dry Bean**, ambos amplamente empregados em tarefas de classificação e agrupamento. Para garantir a comparabilidade entre os métodos, ambos passaram por um pré-processamento padronizado: todas as variáveis categóricas foram transformadas em representações numéricas, os atributos foram normalizados e os dados foram divididos de forma estratificada em 70% para treinamento e 30% para teste. Além disso, em ambos os conjuntos foi aplicado balanceamento por oversampling, igualando a quantidade de exemplos em cada classe antes da divisão em treino e teste. Essa etapa foi fundamental para evitar viés nos resultados e garantir que os métodos de agrupamento pudessem explorar de forma justa as relações entre as amostras e as classes reais.




Fig. 1. Projeção das amostras do Dry Bean balanceado no espaço 2D do PCA, coloridas pelas classes verdadeiras.




Fig. 2. Visualização dos clusters e centros obtidos pelo KMeans no Adult balanceado, no espaço 2D do PCA.

Adult: O conjunto Adult contém aproximadamente 48 mil amostras de indivíduos adultos dos Estados Unidos, com atributos demográficos e socioeconômicos, distribuídos em duas classes principais (renda $\leq 50K$ e $> 50K$). Os atributos incluem variáveis numéricas e categóricas, exigindo codificação

e normalização cuidadosas. O balanceamento foi essencial para evitar a predominância de uma das classes e garantir avaliações justas dos métodos.




Fig. 3. Distribuição das classes no dataset Adult antes do balanceamento.




Fig. 4. Distribuição das classes no dataset Adult após o balanceamento por oversampling.

Dry Bean: O conjunto Dry Bean é composto por mais de 13 mil amostras de feijões secos de sete diferentes cultivares, com atributos morfológicos extraídos de imagens. Todos os atributos são numéricos, facilitando a aplicação direta das técnicas de normalização. Apesar de apresentar uma distribuição de classes mais equilibrada que o Adult, algumas cultivares eram minoritárias, tornando o balanceamento igualmente importante para garantir a imparcialidade das análises. *Tamanho do dataset original:* 13611 amostras, 17 colunas

Tamanho do dataset balanceado: 24822 amostras, 17 colunas




Fig. 5. Distribuição das classes no dataset Dry Bean antes do balanceamento.

B. Seleção do Número de Clusters: Método do Cotovelo

Para definir o número ideal de clusters (k) nos experimentos de agrupamento, utilizamos o **método do cotovelo** aplicado aos dados balanceados e normalizados de cada base. O procedimento foi implementado nos notebooks específicos para cada conjunto:




Fig. 6. Distribuição das classes no dataset Dry Bean após o balanceamento por oversampling.

- **Adult:** O notebook executa o KMeans para k variando de 2 a 24, calculando a soma das distâncias quadráticas (inertia) para cada valor. O gráfico gerado (Figura 7) mostra uma queda acentuada até $k = 2$, indicando o "cotovelo" e sugerindo que dois clusters são suficientes para capturar a estrutura principal dos dados, o que coincide com o número de classes reais ($j=50K$ e $z=50K$).
- **Dry Bean:** Da mesma forma, o método do cotovelo foi aplicado ao dataset balanceado, variando k de 2 a 24. O gráfico correspondente (Figura 8) mostra o cotovelo em $k = 7$, alinhado ao número de cultivares presentes no conjunto. Isso indica que sete clusters são ideais para representar a diversidade das classes reais.

Em ambos os casos, o método do cotovelo foi fundamental para fundamentar a escolha do número de clusters nos experimentos, garantindo que a avaliação dos algoritmos de agrupamento fosse realizada de forma justa e alinhada à estrutura dos dados. Os gráficos a seguir ilustram o comportamento da inércia em função de k para cada base:




Fig. 7. Curva do método do cotovelo para o dataset Adult balanceado. O "cotovelo" ocorre em $k = 2$.




Fig. 8. Curva do método do cotovelo para o dataset Dry Bean balanceado. O "cotovelo" ocorre em $k = 7$.

C. Setup 1 – KMeans: Resultados nos Datasets Adult e Dry Bean

Neste primeiro setup, avaliamos o desempenho do KMeans supervisionado nos conjuntos Adult (balanceado) e Dry Bean (balanceado), ambos após pré-processamento e balanceamento por oversampling. O pipeline seguiu rigorosamente as etapas de normalização, divisão estratificada, definição do número de clusters ($n_{clusters} = 10$), treinamento, repetição dos experimentos (30 execuções) e análise quantitativa detalhada.

1) *Adult (Balanceado):* O KMeans foi executado com $n_{clusters} = 10$. Os resultados médios das 30 repetições estão na Tabela I. O desempenho foi avaliado por métricas macro e matriz de confusão média. Observa-se que o balanceamento das classes foi fundamental para evitar viés para as classes majoritárias, permitindo uma avaliação mais justa do agrupamento.

TABLE I
RESULTADOS QUANTITATIVOS DO KMEANS NO DATASET ADULT
(BALANCEADO, $n_{clusters} = 10$)

Métrica	Média	Desvio Padrão
MSE	0.2824	0.0142
Acurácia	0.7176	0.0142
Precisão (macro)	0.7208	—
Recall (macro)	0.7176	—
F1-score (macro)	0.7166	—

A matriz de confusão média está ilustrada na Figura 9:




Fig. 9. Matriz de confusão média (KMeans - Adult Balanceado)

As principais visualizações estão apresentadas a seguir:

Discussão: O KMeans supervisionado apresentou desempenho consistente após o balanceamento das classes, com acurácia média de 0.7176 e baixo desvio padrão, indicando estabilidade entre as repetições. A matriz de confusão média revela que a maior parte das classes foi corretamente agrupada, embora haja confusões entre algumas classes. O balanceamento contribuiu para uma avaliação mais justa do agrupamento, evitando o viés para classes majoritárias. As métricas macro reforçam a análise quantitativa, mostrando que o método consegue capturar a estrutura binária do conjunto de dados, ainda que com limitações inerentes ao agrupamento não supervisionado.




Fig. 10. Visualização PCA dos clusters e centros (KMeans - Adult Balanceado)




Fig. 11. Acurácia por repetição (KMeans - Adult Balanceado)




Fig. 12. MSE por repetição (KMeans - Adult Balanceado)




Fig. 13. Matriz de confusão média (KMeans - Adult Balanceado)

2) *Dry Bean (Balanceado)*: No dataset Dry Bean, o KMeans também foi executado com $n_{clusters} = 10$ e 30 repetições. Os resultados estão sumarizados na Tabela II. O desempenho foi superior ao observado no Adult, refletindo a maior separabilidade das classes neste conjunto multiclasse.

TABLE II
RESULTADOS QUANTITATIVOS DO KMEANS NO DATASET DRY BEAN
(BALANCEADO, $n_{clusters} = 10$)

Métrica	Média	Desvio Padrão
MSE	1.3198	0.1574
Acurácia	0.8433	0.0246
Precisão (macro)	0.8557	—
Recall (macro)	0.8433	—
F1-score (macro)	0.8449	—

A matriz de confusão média está ilustrada na Figura 14:

As principais visualizações estão apresentadas a seguir:

Discussão: O KMeans supervisionado, mesmo sendo um método originalmente não supervisionado, pode atingir desempenho competitivo em tarefas de classificação quando aliado a uma estratégia de rotulação dos clusters. O desempenho no Dry Bean foi superior ao do Adult, refletindo a maior separabilidade das classes neste conjunto. O balanceamento das classes foi fundamental para evitar viés para as classes majoritárias. Todos os resultados quantitativos e gráficos foram salvos em arquivos para reprodutibilidade e análise posterior.

IV. CONCLUSÃO

O sistema fuzzy Mamdani desenvolvido mostrou-se robusto, flexível e interpretável, sendo capaz de fornecer

recomendações qualitativas de ventilação adequadas ao contexto de conforto térmico e eficiência energética. O método foi fundamentado teoricamente, detalhado em suas etapas e validado por meio de resultados gráficos e quantitativos, demonstrando sua eficácia para tomada de decisão sob incerteza em ambientes reais.

Por exemplo, no cenário 1 (temperatura de 28°C, umidade de 80% e 15 pessoas), o sistema recomendou ventilação **FORTE**, com valor centroide de 62,44, refletindo corretamente a necessidade de maior renovação do ar em ambientes quentes, úmidos e cheios.

A abordagem fuzzy permite fácil adaptação a diferentes contextos e requisitos, além de lidar bem com incertezas e variações das condições ambientais. O estudo reforça a importância da escolha adequada das funções de pertinência, operadores e técnicas de defuzzificação para o desempenho do sistema.

REFERÊNCIAS




Fig. 14. Matriz de confusão média (KMeans - Dry Bean Balanceado)




Fig. 15. Visualização PCA dos clusters e centros (KMeans - Dry Bean Balanceado)




Fig. 18. Matriz de confusão média (KMeans - Dry Bean Balanceado)




Fig. 16. Acurácia por repetição (KMeans - Dry Bean Balanceado)




Fig. 17. MSE por repetição (KMeans - Dry Bean Balanceado)