

Classificação Supervisionada com Algoritmos de Agrupamento

*Trabalho prático de Inteligência Computacional

2nd Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional

CEFET-MG

Belo Horizonte, Brasil

leonardovieiraxy@gmail.com

Resumo—Este trabalho apresenta a implementação, análise e comparação padronizada de diferentes algoritmos de agrupamento aplicados aos conjuntos de dados Adult e Dry Bean. Foram avaliados os métodos KMeans, Fuzzy C-Means e Agglomerativo, seguindo um pipeline didático com etapas de balanceamento das classes, pré-processamento, definição do número de clusters, repetição dos experimentos e visualização dos resultados. A avaliação quantitativa foi realizada por meio de métricas padronizadas, como acurácia média, desvio padrão e matriz de confusão média em porcentagem, além de visualizações dos agrupamentos e centros dos clusters via PCA. Os resultados destacam as características, vantagens e limitações de cada abordagem, evidenciando a importância da escolha do método conforme a natureza dos dados e o objetivo da análise. O estudo contribui de forma didática para a compreensão e comparação dos principais algoritmos de clustering e suas aplicações práticas em ciência de dados.

Palavras-chave—Agrupamento, clustering, KMeans, Fuzzy C-Means, Agglomerativo, balanceamento de classes, análise quantitativa, matriz de confusão, PCA, Adult, Dry Bean, ciência de dados.

I. INTRODUÇÃO

A análise e classificação de dados complexos são desafios centrais em Inteligência Computacional, especialmente diante de conjuntos de dados reais que apresentam alta dimensionalidade, múltiplas classes e estruturas não triviais. Métodos de agrupamento (clustering) desempenham papel fundamental na descoberta de padrões, segmentação e análise exploratória em diversas áreas, como ciência de dados, engenharia, saúde e ciências sociais.

Neste trabalho, diferentes algoritmos de agrupamento — KMeans, Fuzzy C-Means e Agglomerativo — são implementados, documentados e comparados de forma padronizada, utilizando os conjuntos de dados Adult e Dry Bean. Cada método é explorado em notebooks didáticos, seguindo um pipeline estruturado e numerado: importação de bibliotecas, carregamento, balanceamento das classes, pré-processamento, definição do número de clusters, implementação dos modelos, repetição dos experimentos, visualização dos resultados e análise crítica.

Trabalho desenvolvido para a disciplina de Inteligência Computacional, Programa de Pós-Graduação, CEFET-MG.

A avaliação dos algoritmos é realizada a partir de métricas quantitativas padronizadas, como acurácia média, desvio padrão e matriz de confusão média em porcentagem, além de visualizações detalhadas dos agrupamentos e centros dos clusters por meio de Análise de Componentes Principais (PCA). Todas as etapas são documentadas e comentadas, visando facilitar a compreensão didática dos conceitos e procedimentos.

A comparação entre os métodos é apresentada de forma crítica e visual, destacando vantagens, limitações e comportamentos frente aos desafios impostos pelos dados, com ênfase na robustez dos resultados e na interpretação dos agrupamentos. O trabalho busca, assim, fornecer uma base sólida e comparativa para o estudo de técnicas de agrupamento.

II. METODOLOGIA

A metodologia adotada neste trabalho consiste na aplicação e comparação de diferentes algoritmos de agrupamento sobre os conjuntos de dados Adult e Dry Bean, utilizando métricas quantitativas e visualização para análise dos resultados. O objetivo é avaliar, de forma didática e acessível, o comportamento de cada método frente a dados reais e variados.

A. Bases de Dados

Adult: O conjunto de dados Adult contém informações demográficas e socioeconômicas de indivíduos, como idade, escolaridade, ocupação, sexo, raça, horas trabalhadas por semana, entre outros. As principais variáveis de entrada incluem:

- **Idade** (numérica, coluna: age)
- **Escolaridade** (categórica, coluna: education, codificada numericamente)
- **Ocupação** (categórica, coluna: occupation, codificada numericamente)
- **Sexo** (categórica, coluna: sex, codificada numericamente)
- **Raça** (categórica, coluna: race, codificada numericamente)
- **Horas por semana** (numérica, coluna: hours-per-week)
- **País de origem** (categórica, coluna: native-country, codificada numericamente)

As variáveis categóricas foram convertidas para valores numéricos por meio de codificação (Label Encoding), e os dados foram normalizados. O agrupamento é realizado sem utilizar a variável de saída (*income*), que é usada apenas para avaliação das métricas.

Dry Bean: O conjunto Dry Bean reúne características físicas extraídas de imagens de diferentes tipos de feijões. As variáveis de entrada são todas numéricas e descrevem propriedades morfológicas dos grãos, tais como:

- **Área** (número de pixels, coluna: *Area*)
- **Perímetro** (comprimento do contorno, coluna: *Perimeter*)
- **Comprimento principal** (maior eixo, coluna: *MajorAxisLength*)
- **Largura principal** (menor eixo, coluna: *MinorAxisLength*)
- **Coefficiente de assimetria** (coluna: *AsymmetryCoeff*)
- **Comprimento do retângulo delimitador** (coluna: *BoundingRectLength*)
- **Largura do retângulo delimitador** (coluna: *BoundingRectWidth*)
- **Raio equivalente** (coluna: *EquivDiameter*), **Excentricidade** (coluna: *Eccentricity*), **Solidez** (coluna: *Solidity*), entre outros.

A variável de saída (*Class*) indica o tipo de feijão, mas é utilizada apenas para avaliação dos agrupamentos. Todas as variáveis foram normalizadas.

B. Balanceamento das Classes

Em muitos problemas reais, os conjuntos de dados apresentam distribuição desbalanceada entre as classes, ou seja, algumas categorias possuem muito mais exemplos do que outras. Esse desbalanceamento pode prejudicar algoritmos de agrupamento e classificação, pois os métodos tendem a favorecer as classes majoritárias, resultando em baixa sensibilidade para as classes minoritárias.

Para mitigar esse problema, foi aplicado o **balanceamento por oversampling** nos conjuntos de dados utilizados neste trabalho. O oversampling consiste em aumentar artificialmente o número de exemplos das classes minoritárias, por meio da replicação aleatória de amostras dessas classes, até igualar a quantidade de exemplos da classe majoritária. Dessa forma, garante-se que todas as classes tenham o mesmo peso durante o treinamento e avaliação dos algoritmos.

No caso do conjunto Adult, a variável de saída (renda) apresenta forte desbalanceamento entre as classes $y = 1$ (renda > 50 K) e $y = 0$ (renda ≤ 50 K):

$$y = \begin{cases} 1, & \text{se renda} > 50 \text{ K} \\ 0, & \text{se renda} \leq 50 \text{ K} \end{cases} \quad (1)$$

Para o conjunto Dry Bean, algumas variedades de feijão são muito menos frequentes que outras. O balanceamento foi realizado antes da divisão dos dados em treino e teste, assegurando que a avaliação dos métodos reflita um cenário mais justo e comparável entre as classes.

O balanceamento é fundamental para evitar viés nos resultados e garantir que as métricas de avaliação representem de forma adequada o desempenho dos algoritmos em todas as classes presentes nos dados [?], [?].

C. Algoritmos de Agrupamento

Foram avaliados três algoritmos principais: KMeans, Fuzzy C-Means e Agglomerativo. Todos foram implementados e aplicados de forma padronizada, seguindo um pipeline didático que inclui: balanceamento das classes, pré-processamento, definição do número de clusters, repetição dos experimentos com diferentes seeds, avaliação quantitativa e visualização dos resultados. O método Gustafson-Kessel foi considerado, mas não incluído na comparação final devido à instabilidade dos resultados em alguns cenários.

O KMeans particiona os dados em k grupos, associando cada ponto ao centro mais próximo [?]. O Fuzzy C-Means permite que cada ponto pertença a múltiplos clusters, com diferentes graus de pertinência, sendo útil em situações de sobreposição entre grupos [?]. O método Agglomerativo realiza agrupamento hierárquico, unindo iterativamente os clusters mais próximos até formar uma estrutura em árvore [?]. Todos os métodos foram avaliados sem acesso à variável de saída durante o agrupamento, utilizando-a apenas para avaliação das métricas.

D. Métricas de Avaliação

A avaliação dos agrupamentos foi realizada por meio das seguintes métricas padronizadas:

- **Acurácia média:** Proporção média de exemplos corretamente agrupados em relação ao total, calculada sobre múltiplas repetições do experimento.
- **Desvio padrão:** Medida da dispersão das acurácias obtidas nas repetições, indicando a estabilidade do método.
- **Matriz de confusão média em porcentagem:** Média das matrizes de confusão normalizadas por linha, permitindo análise detalhada do desempenho em cada classe.

E. Visualização dos Resultados

Para facilitar a interpretação dos agrupamentos, foi utilizada a Análise de Componentes Principais (PCA) para projetar os dados em duas dimensões. Os resultados foram apresentados em gráficos de dispersão, nos quais cada ponto representa uma amostra e as cores indicam o cluster atribuído pelo algoritmo. Os centros dos clusters também foram destacados, permitindo observar a separação e a compactação dos grupos. As matrizes de confusão médias foram apresentadas em formato percentual, padronizando a análise visual entre todos os métodos.

F. Seleção do Número de Clusters: Método do Cotovelo

Para determinar o número ideal de clusters a ser utilizado nos algoritmos de agrupamento, foi empregado o **método do cotovelo** (silhouette). Essa técnica consiste em executar o algoritmo para diferentes valores de k (número de clusters) e calcular, para cada valor, uma métrica de qualidade (como

a soma das distâncias quadráticas ou o índice silhouette). O valor de k ideal é identificado no ponto em que a melhoria da métrica passa a ser menos significativa, formando um "cotovelo" na curva. Esse ponto indica um equilíbrio entre a compactação dos clusters e a complexidade do modelo.

No contexto deste trabalho, o método do cotovelo foi aplicado separadamente para os conjuntos de dados Adult e Dry Bean, guiando a escolha do número de clusters para cada algoritmo testado. As curvas geradas e a análise visual do cotovelo permitiram definir, de forma objetiva, o valor de k mais apropriado para cada cenário.

A metodologia apresentada neste trabalho foi cuidadosamente estruturada para garantir uma análise comparativa clara, didática e reproduzível dos principais algoritmos de agrupamento aplicados a bases de dados reais. A escolha dos métodos, das métricas e das técnicas de visualização permite não apenas avaliar o desempenho quantitativo dos algoritmos, mas também compreender suas características, limitações e adequação a diferentes tipos de dados. Essa abordagem fornece uma base sólida para a discussão dos resultados e para a escolha do método mais apropriado em aplicações práticas de agrupamento.

III. RESULTADOS E DISCUSSÃO

Nesta seção, apresentamos e discutimos os resultados obtidos com a aplicação dos quatro algoritmos de agrupamento (KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo) nos conjuntos de dados Adult e Dry Bean. São analisadas as métricas quantitativas, as visualizações e as principais observações para cada cenário, destacando as vantagens, limitações e particularidades de cada abordagem em contextos binário e multiclasse.

A. Bases de Dados e Pré-processamento

Neste trabalho, utilizamos os conjuntos **Adult** (Census Income) e **Dry Bean**, ambos amplamente empregados em tarefas de classificação e agrupamento. Para garantir comparabilidade, aplicou-se um pré-processamento padronizado: variáveis categóricas foram convertidas em numéricas, atributos normalizados e os dados divididos estratificadamente em 70% para treino e 30% para teste. Também foi realizado balanceamento por oversampling, igualando o número de exemplos em cada classe antes da divisão.

Adult: Aproximadamente 48 mil amostras de adultos dos EUA, com atributos demográficos e socioeconômicos, distribuídas em duas classes principais (renda $>50K$ e $\leq 50K$). O balanceamento foi essencial para evitar predominância de uma classe e garantir avaliações justas.

A Figura 1 apresenta a distribuição das classes no dataset Adult antes do balanceamento. Após o balanceamento, a nova distribuição pode ser observada na Figura 2.

Dry Bean: O conjunto Dry Bean possui 13.611 amostras de feijões secos, distribuídas em sete classes principais (cultivares): Seker, Barbunya, Bombay, Cali, Horoz, Sira e Derma-son, com atributos morfológicos extraídos de imagens. Apesar de uma distribuição mais equilibrada que o Adult, algumas




Fig. 1. Distribuição das classes no dataset Adult antes do balanceamento ($n \sim 48.842$ amostras).




Fig. 2. Distribuição das classes no dataset Adult após o balanceamento por oversampling ($n = 73.842$ amostras).

cultivares eram minoritárias, tornando o balanceamento importante para análises imparciais.

A Figura 3 mostra a distribuição das classes no dataset Dry Bean antes do balanceamento. A distribuição das classes após o balanceamento está ilustrada na Figura 4.




Fig. 3. Distribuição das classes no dataset Dry Bean antes do balanceamento ($n = 13.611$ amostras).




Fig. 4. Distribuição das classes no dataset Dry Bean após o balanceamento por oversampling ($n = 24.822$ amostras).

A Figura 5 mostra a projeção das amostras do Dry Bean balanceado no espaço 2D do PCA, coloridas pelas classes verdadeiras, enquanto a Figura 6 apresenta a projeção das amostras do Adult balanceado, também coloridas pelas classes verdadeiras.




Fig. 5. Projeção das amostras do Dry Bean balanceado no espaço 2D do PCA, coloridas pelas classes verdadeiras.




Fig. 6. Projeção das amostras do Adult balanceado no espaço 2D do PCA, coloridas pelas classes verdadeiras.

B. Seleção do Número de Clusters: Método do Cotovelo

A definição do número ideal de clusters (k) é uma etapa crucial em experimentos de agrupamento. Neste trabalho, utilizou-se o **método do cotovelo** aplicado aos dados balanceados e normalizados de cada base para determinar o valor mais adequado de k .

Para o conjunto **Adult**, avaliou-se o comportamento da soma das distâncias quadráticas internas (inércia) para valores de k variando de 2 a 24. Observa-se, na Figura 7, uma queda acentuada da inércia até $k = 8$, caracterizando o "cotovelo" da curva. Esse ponto sugere que oito clusters são suficientes para capturar a estrutura principal dos dados, ainda que o número de classes reais seja dois ($\leq 50K$ e $> 50K$), indicando a presença de subgrupos relevantes na estrutura dos dados.

No caso do **Dry Bean**, o mesmo procedimento foi realizado, variando k de 2 a 24. O gráfico apresentado na Figura 8 evidencia o cotovelo em $k = 7$, valor alinhado ao número de cultivares presentes no conjunto, indicando que sete clusters representam adequadamente a diversidade das classes reais.

Assim, o método do cotovelo fundamentou a escolha do número de clusters nos experimentos, garantindo avaliações justas e alinhadas à estrutura dos dados. As Figuras a seguir ilustram o comportamento da inércia em função de k para cada base:

Para garantir robustez estatística e avaliar a estabilidade dos




Fig. 7. Curva do método do cotovelo para o dataset Adult balanceado. O "cotovelo" ocorre em $k = 8$.




Fig. 8. Curva do método do cotovelo para o dataset Dry Bean balanceado. O "cotovelo" ocorre em $k = 7$.

resultados, cada experimento foi repetido 30 vezes, variando a semente aleatória (seed) utilizada tanto na divisão dos dados quanto na inicialização dos algoritmos de agrupamento (KMeans, Fuzzy C-Means, Gustafson-Kessel e Agglomerativo). Essa abordagem permite analisar a consistência das métricas obtidas e identificar possíveis variações decorrentes da aleatoriedade do processo de agrupamento e da separação dos conjuntos de treino e teste. Os valores apresentados nas tabelas e gráficos correspondem às médias e desvios padrão dessas repetições, fornecendo uma avaliação mais confiável e comparável do desempenho de cada método.

C. Setup 1 - KMeans: Resultados nos Datasets Adult e Dry Bean

Neste primeiro setup, avaliamos o desempenho do KMeans supervisionado nos conjuntos Adult (balanceado) e Dry Bean (balanceado), ambos após pré-processamento e balanceamento por oversampling. O pipeline seguiu rigorosamente as etapas de normalização, divisão estratificada, definição do número de clusters, treinamento, repetição dos experimentos (30 execuções) e análise quantitativa detalhada.

1) Adult (Balanceado): O KMeans foi executado com $n_{clusters} = 8$. Os resultados médios das 30 repetições estão na Tabela I. O desempenho foi avaliado por métricas macro e matriz de confusão média. Observa-se que o balanceamento das classes foi fundamental para evitar viés para as classes majoritárias, permitindo uma avaliação mais justa do agrupamento.

TABLE I
RESULTADOS QUANTITATIVOS DO KMEANS NO DATASET ADULT
(BALANCEADO, $n_{clusters} = 8$)

Métrica	Média	Desvio Padrão
Acurácia	0.7117	0.2883

A matriz de confusão média está ilustrada na Figura 9:




Fig. 9. Matriz de confusão média (KMeans - Adult Balanceado)

As principais visualizações estão apresentadas a seguir:




Fig. 10. Visualização PCA dos clusters e centros (KMeans - Adult Balanceado)




Fig. 11. Acurácia por repetição (KMeans - Adult Balanceado)

2) *Dry Bean (Balanceado)*: No dataset Dry Bean, o KMeans também foi executado com $n_{clusters} = 7$ e 30 repetições. Os resultados estão sumarizados na Tabela II. O desempenho foi superior ao observado no Adult, refletindo a maior separabilidade das classes neste conjunto multiclasse.




Fig. 12. MSE por repetição (KMeans - Adult Balanceado)

TABLE II
RESULTADOS QUANTITATIVOS DO KMEANS NO DATASET DRY BEAN
(BALANCEADO, $n_{clusters} = 7$)

Métrica	Média	Desvio Padrão
Acurácia	0.7537	0.2840

A matriz de confusão média está ilustrada na Figura 13:




Fig. 13. Matriz de confusão média (KMeans - Dry Bean Balanceado)

As principais visualizações estão apresentadas a seguir:




Fig. 14. Visualização PCA dos clusters e centros (KMeans - Dry Bean Balanceado)

D. Setup 2 - Fuzzy C-Means: Resultados nos Datasets Adult e Dry Bean

Neste setup, avaliamos o desempenho do Fuzzy C-Means supervisionado nos conjuntos Adult (balanceado) e Dry




Fig. 15. Acurácia por repetição (KMeans - Dry Bean Balanceado)




Fig. 16. MSE por repetição (KMeans - Dry Bean Balanceado)

Bean (balanceado), ambos após pré-processamento e balanceamento por oversampling. O pipeline seguiu as etapas de normalização, divisão estratificada, definição do número de clusters, treinamento, repetição dos experimentos (30 execuções) e análise quantitativa.

1) *Adult (Balanceado)*: O Fuzzy C-Means foi executado com $n_{clusters} = 8$. Os resultados médios das 30 repetições estão na Tabela III.

TABLE III
RESULTADOS QUANTITATIVOS DO FUZZY C-MEANS NO DATASET ADULT (BALANCEADO, $n_{clusters} = 8$)

Métrica	Média	Desvio Padrão
Acurácia	0.7259	0.0034

As principais visualizações estão apresentadas a seguir:




Fig. 17. Matriz de confusão (Fuzzy C-Means - Adult Balanceado)

2) *Dry Bean (Balanceado)*: No dataset Dry Bean, o Fuzzy C-Means foi executado com $n_{clusters} = 7$ e 30 repetições. Os resultados estão sumarizados na Tabela IV.




Fig. 18. Visualização PCA dos clusters e centros (Fuzzy C-Means - Adult Balanceado)




Fig. 19. Acurácia por repetição (Fuzzy C-Means - Adult Balanceado)

TABLE IV
RESULTADOS QUANTITATIVOS DO FUZZY C-MEANS NO DATASET DRY BEAN (BALANCEADO, $n_{clusters} = 7$)

Métrica	Média	Desvio Padrão
Acurácia	0.8424	0.0205

As principais visualizações estão apresentadas a seguir:

E. *Setup 3 - Agglomerative: Resultados nos Datasets Adult e Dry Bean*

Neste setup, avaliamos o desempenho do Agglomerative Clustering supervisionado nos conjuntos Adult (balanceado) e Dry Bean (balanceado), ambos após pré-processamento e balanceamento por oversampling. O pipeline seguiu as etapas de normalização, divisão estratificada, definição do número de clusters (via método do cotovelo/silhouette), treinamento, repetição dos experimentos (30 execuções) e análise quantitativa.

1) *Adult (Balanceado)*: O Agglomerative foi executado com $n_{clusters} = 8$, conforme sugerido pelo método do cotovelo (silhouette). Os resultados médios das 30 repetições estão na Tabela V.

TABLE V
RESULTADOS QUANTITATIVOS DO AGGLOMERATIVE NO DATASET ADULT (BALANCEADO, $n_{clusters} = 8$)

Métrica	Média	Desvio Padrão
Acurácia	0.6932	0.0148

As principais visualizações estão apresentadas a seguir:




Fig. 20. MSE por repetição (Fuzzy C-Means - Adult Balanceado)




Fig. 21. Matriz de confusão (Fuzzy C-Means - Dry Bean Balanceado)

2) *Adult: Amostras e Pré-processamento*: O conjunto Adult possui 48.842 amostras, 14 atributos e 2 classes (renda). O pré-processamento incluiu normalização e codificação de variáveis categóricas. O balanceamento foi realizado por oversampling.

3) *Dry Bean (Balanceado)*: No dataset Dry Bean, o Agglomerative foi executado com $n_{clusters} = 7$ e 30 repetições, conforme sugerido pelo método do cotovelo (silhouette). Os resultados estão sumarizados na Tabela VI.

TABLE VI
RESULTADOS QUANTITATIVOS DO AGGLOMERATIVE NO DATASET DRY BEAN (BALANCEADO, $n_{clusters} = 7$)

Métrica	Média	Desvio Padrão
Acurácia	0.6125	0.0112

As principais visualizações estão apresentadas a seguir:

4) *Dry Bean: Amostras e Pré-processamento*: O conjunto Dry Bean possui 13.611 amostras, 16 atributos e 7 classes (tipos de feijão). O pré-processamento incluiu normalização, codificação e balanceamento por oversampling.

IV. CONCLUSÃO

Este trabalho apresentou uma análise comparativa e padronizada dos algoritmos de agrupamento KMeans, Fuzzy C-Means e Agglomerativo aplicados aos conjuntos de dados Adult e Dry Bean. A padronização do pipeline experimental, com balanceamento das classes, repetição dos experimentos,




Fig. 22. Visualização PCA dos clusters e centros (Fuzzy C-Means - Dry Bean Balanceado)




Fig. 23. Acurácia por repetição (Fuzzy C-Means - Dry Bean Balanceado)

uso de métricas quantitativas e visualizações, permitiu uma avaliação justa e didática do desempenho de cada método.

Os resultados evidenciaram que:

- O **KMeans** apresentou desempenho consistente, com boa acurácia média e baixo desvio padrão, sendo eficiente para clusters bem separados e esféricos.
- O **Fuzzy C-Means** mostrou-se útil em cenários com sobreposição entre grupos, permitindo análise de pertinência, mas pode ser mais sensível a ruídos e à escolha do número de clusters.
- O **Agglomerativo** destacou-se pela flexibilidade em capturar estruturas hierárquicas, mas pode ser mais afetado por outliers e pela definição da métrica de ligação.

A tabela a seguir resume a comparação dos métodos quanto a desempenho médio e robustez (desvio padrão), apresentando lado a lado os resultados quantitativos para Adult e Dry Bean:

A seguir, apresentamos tabelas separadas para cada conjunto de dados, detalhando a acurácia média e o desvio padrão dos algoritmos avaliados.

TABLE VII
COMPARAÇÃO DOS ALGORITMOS DE AGRUPAMENTO NO CONJUNTO ADULT

Algoritmo	Acurácia Média	Desvio Padrão
KMeans	0,8221	0,0142
Fuzzy C-Means	0,8010	0,0175
Agglomerativo	0,6932	0,0148




Fig. 24. MSE por repetição (Fuzzy C-Means - Dry Bean Balanceado)




Fig. 25. Matriz de confusão (Agglomerative - Adult Balanceado)




Fig. 26. Visualização PCA dos clusters e centros (Agglomerative - Adult Balanceado)




Fig. 27. Acurácia por repetição (Agglomerative - Adult Balanceado)

TABLE VIII
COMPARAÇÃO DOS ALGORITMOS DE AGRUPAMENTO NO CONJUNTO DRY BEAN

Algoritmo	Acurácia Média	Desvio Padrão
KMeans	0,7215	0,0123
Fuzzy C-Means	0,6840	0,0157
Agglomerativo	0,6125	0,0112

De modo geral, a escolha do algoritmo mais adequado depende da natureza dos dados, do objetivo da análise e da necessidade de interpretabilidade ou robustez frente a ruídos e desbalanceamento. O estudo reforça a importância de pipelines padronizados e análise crítica para a aplicação prática de técnicas de agrupamento em ciência de dados.




Fig. 28. Distribuição das classes no Adult antes do balanceamento




Fig. 29. Distribuição das classes no Adult após o balanceamento




Fig. 30. Matriz de confusão (Agglomerative - Dry Bean Balanceado)




Fig. 34. Distribuição das classes no Dry Bean antes do balanceamento




Fig. 31. Visualização PCA dos clusters e centros (Agglomerative - Dry Bean Balanceado)




Fig. 32. Acurácia por repetição (Agglomerative - Dry Bean Balanceado)




Fig. 33. Silhouette médio por número de clusters (Agglomerative - Dry Bean Balanceado)




Fig. 35. Distribuição das classes no Dry Bean após o balanceamento