

Classificadores Multiclasse Baseados em Algoritmos de Agrupamento

Inteligência Computacional

[Seu Nome]

CEFET-MG

3 de julho de 2025

Sumário

- 1 Introdução
- 2 Metodologia
- 3 Resultados e Discussão
- 4 Conclusão


- Análise e comparação de algoritmos de agrupamento (KMeans, Fuzzy C-Means, Agglomerativo, Gustafson-Kessel)
- Aplicação nos datasets Adult (binário) e Dry Bean (multiclasse)
- Ênfase em padronização, repetição dos experimentos e análise quantitativa

Pipeline Padronizado


- 1 Importação e balanceamento dos dados
- 2 Pré-processamento (normalização, codificação)
- 3 Definição do número de clusters (método do cotovelo/silhouette)
- 4 Implementação dos algoritmos
- 5 Repetição dos experimentos (30 execuções)
- 6 Avaliação quantitativa (acurácia, desvio padrão, matriz de confusão em porcentagem)
- 7 Visualização dos resultados (PCA, matrizes de confusão)

- 48.842 amostras
- 14 atributos: age, workclass, fnlwgt, education, education-num, marital-status, occupation, relationship, race, sex, capital-gain, capital-loss, hours-per-week, native-country
- 2 classes: renda $\leq 50K$ e $> 50K$
- Desafio: alta proporção de atributos categóricos
- Balanceamento realizado por oversampling

Adult: Distribuição das Classes (Antes do Balanceamento)




Adult: Distribuição das Classes (Após o Balanceamento)




Base de Dados: Dry Bean

- 13.611 amostras
- 16 atributos: Area, Perimeter, MajorAxisLength, MinorAxisLength, AspectRation, Eccentricity, ConvexArea, EquivDiameter, Extent, Solidity, roundness, Compactness, ShapeFactor1, ShapeFactor2, ShapeFactor3, ShapeFactor4
- 7 classes: Barbunya, Bombay, Cali, Dermason, Horoz, Seker, Sira
- Desafio: problema multiclasse e classes desbalanceadas
- Balanceamento realizado por oversampling

Dry Bean: Distribuição das Classes (Antes do Balanceamento)




Dry Bean: Distribuição das Classes (Após o Balanceamento)



Seleção do Número de Clusters


Adult:

Método do Cotovelo para o KMeans - Adult (Balanceado)



Dry Bean:


Método do Cotovelo para o KMeans - Dry Bean (Balanceado)




Repetição dos Experimentos

- 30 repetições para cada algoritmo e dataset
- Avaliação da estabilidade (acurácia/desvio padrão)

Acurácia por repetição - KMeans (Adult Balanceado)





Acurácia por repetição - KMeans (Dry Bean Balanceado)





Setup 1: KMeans – Acurácia e Desvio Padrão



- Pipeline padronizado aplicado ao KMeans
- 30 repetições: acurácia média e desvio padrão



Setup 1: KMeans – Visualização dos Clusters (PCA)




Setup 1: KMeans – Matriz de Confusão Média (%)





Setup 2: Fuzzy C-Means – Acurácia e Desvio Padrão



- Pipeline padronizado aplicado ao Fuzzy C-Means
- 30 repetições: acurácia média e desvio padrão



Setup 2: Fuzzy C-Means – Visualização dos Clusters (PCA)





Setup 2: Fuzzy C-Means – Matriz de Confusão Média (%)





Setup 3: Agglomerativo – Acurácia e Desvio Padrão

- Pipeline padronizado aplicado ao Agglomerativo
- 30 repetições: acurácia média e desvio padrão




Setup 3: Agglomerativo – Visualização dos Clusters (PCA)



Setup 3: Agglomerativo – Matriz de Confusão Média (%)

Matriz de Confusão Média (%) - Agglomerative (Adult Balanceado)



Matriz de Confusão Média (%) - Agglomerative (Dry Bean Balanceado)




Tabela: Comparação dos algoritmos nos conjuntos Adult e Dry Bean

Algoritmo	Adult (Acurácia)	Adult (DP)	Dry Bean (Acurácia)	Dry Bean (DP)
KMeans	0,82	0,02	0,72	0,01
Fuzzy C-Means	0,80	0,03	0,68	0,02
Agglomerativo	0,69	0,01	0,61	0,01

- KMeans apresenta desempenho consistente e robusto, especialmente em dados binários
- Fuzzy C-Means é útil para sobreposição de grupos, mas sensível a ruído
- Agglomerativo destaca-se em cenários hierárquicos, mas é mais sensível a outliers
- A escolha do método depende do contexto dos dados e do objetivo da análise
- Pipelines padronizados e repetição dos experimentos são essenciais para avaliação confiável

Obrigado!

Perguntas?