

Classificadores Multiclasse Baseados em Algoritmos de Agrupamento

Inteligência Computacional

Leonardo Vieira Guimarães

Mestrado em Modelagem Computacional e Sistemas
CEFET-MG

3 de julho de 2025


Introdução

- Análise e comparação de algoritmos de agrupamento (KMeans, Fuzzy C-Means, Agglomerativo)
- Aplicação nos datasets Adult (binário) e Dry Bean (multiclasse)

Metodologia


- Aplicação e comparação de KMeans, Fuzzy C-Means e Agglomerativo
- Datasets: Adult (demográfico) e Dry Bean (morfologia de feijões)
- Pipeline padronizado: balanceamento, pré-processamento, definição de k , repetição dos experimentos, avaliação quantitativa e visualização

- Algoritmo de agrupamento baseado em centroides.
- Inicializa k centroides aleatórios e atribui cada ponto ao centro mais próximo.
- Atualiza os centroides como a média dos pontos atribuídos.
- Repete até convergência (centroides não mudam).
- Simples, eficiente, mas sensível a outliers e à escolha de k .



Fuzzy C-Means


- Variante "fuzzy" do KMeans: cada ponto pertence a todos os clusters com um grau de pertinência.
- Minimiza uma função de custo ponderada pelas pertinências.
- Permite sobreposição entre clusters, útil para dados ambíguos.
- Mais flexível, mas requer ajuste do parâmetro de fuzzificação.



Exemplo de clusters do Fuzzy C-Means

Agglomerativo

- Algoritmo hierárquico: cada ponto começa em seu próprio cluster.
- Une os clusters mais próximos iterativamente até restar k clusters.
- Não requer definição prévia de centroides.
- Gera uma árvore de agrupamento (dendrograma).
- Capaz de capturar estruturas complexas, mas pode ser computacionalmente custoso.



Adult:

- Informações demográficas e socioeconômicas
- Variáveis: idade, escolaridade, ocupação, sexo, raça, horas/semana, país de origem
- Variáveis categóricas codificadas numericamente
- Agrupamento sem uso da variável de saída (income)

Dry Bean:

- Características físicas/morfológicas de feijões
- Todas as variáveis numéricas
- Variável de saída (Class) usada apenas para avaliação

Balanceamento das Classes

- Problema: distribuição desbalanceada entre as classes
- Solução: oversampling das classes minoritárias até igualar a maioria
- Balanceamento feito antes da divisão treino/teste
- Garante avaliação justa e sem viés

Pipeline de Agrupamento

- 1 Balanceamento das classes
- 2 Pré-processamento (normalização, codificação)
- 3 Definição do número de clusters (k)
- 4 Execução dos algoritmos
- 5 Repetição dos experimentos (30 execuções, seeds diferentes)
- 6 Avaliação quantitativa (acurácia média, desvio padrão, matriz de confusão)
- 7 Visualização dos resultados (PCA, matrizes de confusão)

Métricas de Avaliação

- **Acurácia média:** proporção média de exemplos corretamente agrupados
- **Desvio padrão:** dispersão das acurácias nas repetições
- **Matriz de confusão:** mostra acertos e erros por classe

Matriz de confusão binária:

	Predito: 1	Predito: 0
Real: 1	VP	FN
Real: 0	FP	VN

- VP: verdadeiro positivo (classe real e predita são positivas)
- FP: falso positivo (classe real é negativa, mas predita como positiva)
- VN: verdadeiro negativo (classe real e predita são negativas)
- FN: falso negativo (classe real é positiva, mas predita como negativa)

PCA (Análise de Componentes Principais)

Técnica que reduz a dimensionalidade dos dados, projetando-os em 2D para facilitar a visualização de padrões e agrupamentos.

- Gráficos de dispersão mostram os clusters ou classes em duas dimensões.
- Centros dos clusters são destacados para melhor interpretação.
- Matrizes de confusão médias facilitam a comparação entre métodos.


Seleção do Número de Clusters

- Método do cotovelo: avalia métrica de qualidade para diferentes k
- Ponto de inflexão indica o valor mais adequado
- Aplicado separadamente para Adult e Dry Bean

Resultados e Discussão

- 48.842 amostras
- 14 atributos: age, workclass, fnlwgt, education, education-num, marital-status, occupation, relationship, race, sex, capital-gain, capital-loss, hours-per-week, native-country
- 2 classes: renda $\leq$ 50K e $>$ 50K
- Desafio: alta proporção de atributos categóricos
- Balanceamento realizado por oversampling


Adult: Distribuição das Classes (Antes do Balanceamento)



Informações

- Amostras: 48.842
- Atributos: 14
- Classes: 2
≤ 50K, > 50K

Adult: Distribuição das Classes (Após o Balanceamento)




Informações

- Amostras: 97.484 (balanceado)
- Atributos: 14
- Classes: 2
 $\leq 50K$, $> 50K$

Base de Dados: Dry Bean

- 13.611 amostras
- 16 atributos: Area, Perimeter, MajorAxisLength, MinorAxisLength, AspectRation, Eccentricity, ConvexArea, EquivDiameter, Extent, Solidity, roundness, Compactness, ShapeFactor1, ShapeFactor2, ShapeFactor3, ShapeFactor4
- 7 classes: Barbunya, Bombay, Cali, Dermason, Horoz, Seker, Sira
- Desafio: problema multiclasse e classes desbalanceadas
- Balanceamento realizado por oversampling


Dry Bean: Distribuição das Classes (Antes do Balanceamento)



Informações

- Amostras: 13.611
- Atributos: 16
- Classes: 7
Barbunya, Bombay, Cali,
Dermason, Horoz, Seker, Sira

Dry Bean: Distribuição das Classes (Após o Balanceamento)




Informações

- Amostras: 47.096 (balanceado)
- Atributos: 16
- Classes: 7
Barbunya, Bombay, Cali, Dermason, Horoz, Seker, Sira


Visualização PCA das Classes Verdadeiras

Distribuição das Amostras no Espaço PCA (classes verdadeiras) - Dry Bean Balance



Dry Bean (classes verdadeiras)

Distribuição das Amostras no Espaço PCA (classes verdadeiras) - Adult Balancea



Adult (classes verdadeiras)



Seleção do Número de Clusters

- Método do cotovelo: avalia métrica de qualidade para diferentes k
- Ponto de inflexão indica o valor mais adequado
- Aplicado separadamente para Adult e Dry Bean

Repetição dos Experimentos


- Cada experimento foi repetido 30 vezes com diferentes seeds.
- Resultados apresentados como média e desvio padrão.
- Permite avaliar a estabilidade e robustez dos métodos (KMeans, Fuzzy C-Means, Agglomerativo).
- Apresentação dos resultados obtidos com os algoritmos KMeans, Fuzzy C-Means e Agglomerativo.
- Para cada algoritmo: visualização em PCA, matriz de confusão e gráficos de acurácia.

Setup 1: KMeans – Adult (PCA e Matriz de Confusão)





Matriz de Confusão

Setup 1: KMeans – Adult (Acurácia)




Média: 0,82 DP: 0,02

Setup 1: KMeans – Dry Bean (PCA e Matriz de Confusão)





Setup 1: KMeans – Dry Bean (Acurácia)




Média: 0,72 DP: 0,01

Setup 2: Fuzzy C-Means – Adult (PCA e Matriz de Confusão)




Setup 2: Fuzzy C-Means – Adult (Acurácia)



Média: 0,80 DP: 0,03


Setup 2: Fuzzy C-Means – Dry Bean (PCA e Matriz de Confusão)

Visualização dos Clusters e Centros (PCA) - Fuzzy C-Means (Dry Bean Balanceado)




PCA

Matriz de Confusão Média (%) - Fuzzy C-Means (Dry Bean Balanceado)




Matriz de Confusão

Setup 2: Fuzzy C-Means – Dry Bean (Acurácia)




Média: 0,68 DP: 0,02

Setup 3: Agglomerativo – Adult (PCA e Matriz de Confusão)




Matriz de Confusão Média (%) - Agglomerative (Adult Balanceado)




Matriz de Confusão

Setup 3: Agglomerativo – Adult (Acurácia)




Média: 0,69 DP: 0,01


Setup 3: Agglomerativo – Dry Bean (PCA e Matriz de Confusão)



Matriz de Confusão Média (%) - Agglomerative (Dry Bean Balanceado)



Setup 3: Agglomerativo – Dry Bean (Acurácia)



Média: 0,61 DP: 0,01

Tabela: Comparação dos algoritmos de agrupamento no conjunto Adult

Algoritmo	Acurácia Média	Desvio Padrão
KMeans	0,7117	0,0160
Fuzzy C-Means	0,7259	0,0034
Agglomerativo	0,5812	0,1116

Tabela: Comparação dos algoritmos de agrupamento no conjunto Dry Bean

Algoritmo	Acurácia Média	Desvio Padrão
KMeans	0,7537	0,2840
Fuzzy C-Means	0,8424	0,0205
Agglomerativo	0,2694	0,1546

Conclusão

- **Fuzzy C-Means** obteve o melhor desempenho geral, com acurácia média de 0,84 e baixo desvio padrão no Dry Bean, mostrando robustez para problemas multiclasse.
- **KMeans** apresentou desempenho intermediário: acurácia de 0,71 (Adult) e 0,75 (Dry Bean), com maior estabilidade no Adult ($DP = 0,016$).
- **Agglomerativo** teve o pior desempenho, especialmente no Dry Bean (acurácia média de 0,27 e $DP = 0,15$), indicando limitação para dados complexos ou com muitas classes.
- O desvio padrão elevado do Agglomerativo e do KMeans no Dry Bean evidencia instabilidade e sensibilidade à estrutura dos dados.
- A escolha do algoritmo deve considerar a natureza dos dados, número de classes e necessidade de robustez.

Obrigado!

Perguntas?