

Classificação Supervisionada com Algoritmos de Agrupamento

*Trabalho prático de Inteligência Computacional

2nd Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional

CEFET-MG

Belo Horizonte, Brasil

leonardovieiraxy@gmail.com

Resumo—Este trabalho apresenta uma análise comparativa de técnicas de regressão e classificação multiclasse aplicadas aos conjuntos Energy Efficiency, Wine Quality (Red) e Iris. Foram implementados setups de regressão e classificação, com diferentes algoritmos e abordagens de pré-processamento. Os resultados destacam o desempenho dos métodos em diferentes cenários, discutindo robustez, interpretabilidade e recomendações práticas.

Palavras-chave—Regressão, classificação multiclasse, Energy Efficiency, Wine Quality, Iris, Random Forest, MLP, SVC, análise comparativa, pré-processamento, métricas, robustez, interpretabilidade.

I. INTRODUÇÃO

A Inteligência Computacional tem se destacado pela capacidade de resolver problemas complexos em ciência de dados, engenharia e saúde. Este trabalho tem como objetivo comparar técnicas de regressão e classificação multiclasse, utilizando bases públicas e setups experimentais padronizados. A motivação reside na busca por modelos robustos, interpretáveis e com bom desempenho em tarefas reais. Segundo [1], os conjuntos fuzzy são fundamentais para a modelagem de incertezas em ciência de dados.

II. METODOLOGIA

Foram utilizados três conjuntos de dados: Energy Efficiency (regressão), Wine Quality (Red) e Iris (classificação multiclasse). O pré-processamento incluiu normalização dos atributos, codificação de variáveis categóricas e divisão dos dados em treino e teste. A escolha da normalização se justifica pela diferença de escala entre os atributos, impactando algoritmos baseados em distância e gradiente.

Os algoritmos avaliados foram: Regressão Linear, Random Forest, SVR e MLP para regressão; Regressão Logística, Random Forest, SVC e MLP para classificação. Cada setup foi executado com 30 repetições para algoritmos estocásticos, variando a semente de inicialização. As métricas utilizadas foram RMSE, MAE, R^2 para regressão e acurácia, F1-score, Kappa para classificação. O algoritmo KMeans foi proposto por Lloyd [2] e o método Fuzzy C-Means por Bezdek [3].

Trabalho desenvolvido para a disciplina de Inteligência Computacional, Programa de Pós-Graduação, CEFET-MG.

III. RESULTADOS E DISCUSSÃO

Os resultados dos experimentos mostraram que, para regressão (setup Energy Efficiency), o Random Forest obteve o melhor RMSE médio, seguido por MLP e SVR. Na classificação multiclasse (setups Wine Quality e Iris), Random Forest e MLP apresentaram maior acurácia e F1-score, enquanto SVC destacou-se em cenários com classes bem separadas. Modelos lineares foram mais interpretáveis, mas menos robustos em dados não lineares. Boxplots e tabelas comparativas evidenciaram as diferenças de desempenho e robustez entre os algoritmos.

IV. CONCLUSÃO

Este trabalho comparou diferentes técnicas de regressão e classificação multiclasse em três setups distintos. Os resultados evidenciam que não existe um algoritmo universalmente superior, sendo fundamental analisar o contexto e as características dos dados. O uso de pré-processamento adequado e repetição dos experimentos contribui para maior confiabilidade das conclusões. Recomenda-se a escolha do método conforme o objetivo, a interpretabilidade e a robustez desejada. Estudos futuros podem explorar outras bases e técnicas de ensemble.

REFERÊNCIAS

- [1] L. A. Zadeh, "Fuzzy sets," *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965.
- [2] S. Lloyd, "Least squares quantization in pcm," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [3] J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*. Springer, 1981.