

Classificação e Regressão Supervisionadas com Algoritmos de Aprendizado de Máquina

*Trabalho prático de Inteligência Computacional

Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional

CEFET-MG

Belo Horizonte, Brasil

leonardovieiraxy@gmail.com

Resumo—Este trabalho apresenta uma análise comparativa de técnicas de regressão e classificação multiclasse aplicadas a conjuntos de dados públicos de referência. Foram avaliados modelos lineares, ensembles, redes neurais e métodos baseados em margens, considerando diferentes cenários de pré-processamento, incluindo normalização e balanceamento de classes. Os experimentos, conduzidos com múltiplas repetições para garantir robustez estatística, mostraram que o Random Forest foi consistentemente o algoritmo de melhor desempenho em tarefas de regressão e classificação em bases complexas ou desbalanceadas, enquanto MLP e SVM se destacaram em conjuntos bem comportados como o Iris. O Logistic Regression, embora simples e interpretável, apresentou desempenho inferior nos cenários mais desafiadores, mas manteve resultados competitivos em bases balanceadas. O uso de técnicas de balanceamento impactou positivamente métricas como F1-score e Kappa, especialmente em bases desbalanceadas. Os resultados reforçam a importância de uma avaliação criteriosa e contextualizada na escolha de modelos para aplicações reais.

Palavras-chave—Inteligência Computacional; Regressão; Classificação Multiclasse.

I. INTRODUÇÃO

A Inteligência Computacional tem se consolidado como área estratégica para a solução de problemas complexos em ciência de dados, engenharia e saúde, impulsionada pela crescente disponibilidade de dados e pela demanda por modelos preditivos robustos e confiáveis. Nesse cenário, a seleção criteriosa de algoritmos e estratégias de pré-processamento torna-se fundamental para garantir desempenho, interpretabilidade e reprodutibilidade dos resultados.

Este trabalho tem como objetivo realizar uma análise comparativa do desempenho de diferentes técnicas de regressão e classificação multiclasse, utilizando bases públicas de referência — Energy Efficiency, California Housing, Wine Quality (Red) e Iris — e protocolos experimentais padronizados. Foram avaliados modelos lineares, ensembles, redes neurais e métodos baseados em margens, tanto em cenários originais quanto com aplicação de técnicas de balanceamento de classes.

O estudo envolveu etapas rigorosas de pré-processamento, incluindo normalização dos atributos, codificação de variáveis

categóricas e divisão estratificada dos dados em treino e teste. Para garantir robustez estatística, cada experimento foi repetido múltiplas vezes com diferentes sementes de inicialização. As métricas de avaliação adotadas — RMSE, MAE e R^2 para regressão; acurácia, F1-score e Kappa para classificação — permitiram uma análise abrangente e comparativa do desempenho dos algoritmos.

Os resultados demonstram que o Random Forest foi o algoritmo mais robusto e eficiente em cenários complexos ou desbalanceados, enquanto MLP e SVM se destacaram em bases bem comportadas como a Iris. O Logistic Regression, embora simples e interpretável, apresentou desempenho inferior nos cenários mais desafiadores, mas manteve resultados competitivos em bases balanceadas. O uso de técnicas de balanceamento impactou positivamente métricas como F1-score e Kappa, especialmente em bases desbalanceadas. Assim, este trabalho reforça a importância de uma avaliação criteriosa e contextualizada na escolha de modelos para aplicações reais.

II. METODOLOGIA

Esta seção apresenta detalhadamente os procedimentos metodológicos adotados para a realização dos experimentos deste trabalho. São descritos os critérios de seleção e as principais características dos conjuntos de dados utilizados, as etapas de pré-processamento aplicadas, os modelos de aprendizado de máquina avaliados e suas configurações, bem como as estratégias de balanceamento de classes empregadas nos cenários de classificação. Além disso, são abordadas as ferramentas de análise exploratória, como gráficos de dispersão e matriz de confusão, e as métricas de avaliação utilizadas para mensurar o desempenho dos algoritmos em tarefas de regressão e classificação. O objetivo é garantir transparência, reprodutibilidade e rigor científico na condução dos experimentos e na análise dos resultados.

A. Conjuntos de Dados e Pré-processamento

Foram utilizados quatro conjuntos de dados: Energy Efficiency (regressão) [1], California Housing (regressão) [2], Wine Quality (Red) [3] e Iris (classificação multiclasse) [4]. O pré-processamento incluiu normalização dos atributos,

codificação de variáveis categóricas e divisão dos dados em treino e teste, sendo a normalização fundamental devido à diferença de escala entre os atributos, o que impacta algoritmos baseados em distância e gradiente.

Nos experimentos de regressão, os dados foram divididos em 80% para treinamento e 20% para teste. Para classificação, utilizou-se 70% para treinamento e 30% para teste. O balanceamento das classes por oversampling foi fundamental para avaliar o impacto dessa técnica nos resultados, especialmente em conjuntos desbalanceados como Wine Quality. Todos os experimentos foram repetidos com diferentes sementes para garantir robustez estatística e confiabilidade dos resultados.

Para os experimentos de classificação, foram realizados testes tanto com os conjuntos de dados originais (desbalanceados) quanto com versões balanceadas. O balanceamento foi feito por meio de oversampling das classes minoritárias, igualando a quantidade de amostras de cada classe à da classe mais frequente. Isso foi implementado na função de pré-processamento, utilizando a técnica de amostragem com reposição (upsampling) para as classes menos representadas, conforme discutido em estudos recentes sobre o impacto de técnicas de amostragem em cenários desbalanceados [5]. O objetivo foi avaliar o impacto do desbalanceamento nas métricas de desempenho dos algoritmos.

B. Descrição dos Conjuntos de Dados

Energy Efficiency: Este dataset é utilizado para tarefas de regressão e contém 768 amostras de edifícios residenciais. O objetivo é prever dois parâmetros de eficiência energética: carga de aquecimento (Y1) e carga de resfriamento (Y2). Os atributos são:

- **X1:** Relative Compactness
- **X2:** Surface Area
- **X3:** Wall Area
- **X4:** Roof Area
- **X5:** Overall Height
- **X6:** Orientation (1 a 4)
- **X7:** Glazing Area
- **X8:** Glazing Area Distribution (0 a 5)
- **Y1:** Heating Load (alvo)
- **Y2:** Cooling Load (alvo)

California Housing: Este conjunto de dados contém 20.640 amostras de distritos habitacionais da Califórnia, com o objetivo de prever o valor mediano das casas (MedHouseVal). Os atributos são:

- **MedInc:** Renda média dos moradores do distrito
- **HouseAge:** Idade média das casas
- **AveRooms:** Média de cômodos por residência
- **AveBedrms:** Média de quartos por residência
- **Population:** População do distrito
- **AveOccup:** Média de ocupantes por residência
- **Latitude:** Latitude geográfica
- **Longitude:** Longitude geográfica
- **MedHouseVal:** Valor mediano das casas (alvo)

Wine Quality (Red): Utilizado para classificação multi-classe, este dataset reúne 1.599 amostras de vinhos tintos

portugueses. O objetivo é prever a qualidade do vinho (nota de 0 a 10). Os atributos são:

- **fixed acidity** (acidez fixa)
- **volatile acidity** (acidez volátil)
- **citric acid** (ácido cítrico)
- **residual sugar** (açúcar residual)
- **chlorides** (cloretos)
- **free sulfur dioxide** (SO₂ livre)
- **total sulfur dioxide** (SO₂ total)
- **density** (densidade)
- **pH**
- **sulphates** (sulfatos)
- **alcohol** (teor alcoólico)
- **quality** (qualidade, alvo)

Iris: Clássico para classificação multiclasse, o conjunto de dados Iris possui 150 amostras de flores de três espécies diferentes (setosa, versicolor e virginica). Os atributos são:

- **sepal length (cm):** comprimento da sépala
- **sepal width (cm):** largura da sépala
- **petal length (cm):** comprimento da pétala
- **petal width (cm):** largura da pétala
- **target:** espécie da flor (setosa, versicolor, virginica)

C. Modelos e Configuração Experimental

Os experimentos de regressão e classificação foram realizados com diferentes abordagens de aprendizado de máquina, abrangendo modelos lineares, ensembles, redes neurais e métodos baseados em margens. Para regressão, foram empregados: Regressão Linear (modelo linear simples, utilizado como baseline) [6], Random Forest Regressor (ensemble de árvores, robusto a outliers e apto a capturar relações não-lineares) [7], MLPRegressor (rede neural multicamadas, capaz de modelar relações complexas) [8] e SVR (Support Vector Regressor, eficiente em espaços de alta dimensão e robusto a outliers) [9]. Para classificação, utilizaram-se: Regressão Logística (modelo linear para problemas binários e multi-classe) [10], [11], Random Forest Classifier [7], MLPClassifier [8] e SVM Classifier (Support Vector Machine, que maximiza a margem entre as classes em espaços de alta dimensão) [9].

Regressão Linear: Trata-se de um modelo linear simples, que busca ajustar uma reta (ou hiperplano) aos dados, assumindo relação linear entre as variáveis preditoras e a variável alvo. É utilizado como baseline devido à sua simplicidade e interpretabilidade.

Random Forest: Algoritmo de ensemble baseado em múltiplas árvores de decisão. Para regressão, combina previsões de várias árvores para reduzir variância e melhorar a robustez, sendo eficiente para capturar relações não-lineares e lidar com outliers. Para classificação, segue o mesmo princípio, agregando o voto das árvores para definir a classe final, sendo robusto a ruídos e variáveis categóricas.

MLP (Perceptron Multicamadas): Rede neural artificial composta por múltiplas camadas de neurônios. O MLPRegressor é utilizado para tarefas de regressão e o MLPClassifier para classificação. Ambos são capazes de modelar relações

complexas e não-lineares, aprendendo representações internas dos dados por meio de camadas ocultas.

SVM/SVR (Support Vector Machine/Regressor): O SVM é um método de classificação que busca encontrar o hiperplano que maximiza a margem entre as classes, sendo eficiente em espaços de alta dimensão. O SVR é a versão para regressão, que busca ajustar uma função dentro de uma margem de tolerância, sendo robusto a outliers e eficiente para dados complexos.

Regressão Logística: Modelo linear para classificação, especialmente útil para problemas binários e multiclasse. Calcula a probabilidade de pertencimento a uma classe por meio da função logística, sendo simples, eficiente e interpretável.

D. Avaliação dos Experimentos

Cada configuração experimental foi executada com 30 repetições para garantir robustez estatística, variando a semente de inicialização dos algoritmos estocásticos. As métricas de avaliação adotadas foram: RMSE, MAE e R^2 para regressão; acurácia, F1-score e Kappa para classificação.

A análise exploratória de dados é uma etapa essencial no processo de construção de modelos de aprendizado de máquina, pois permite compreender a estrutura, padrões e possíveis anomalias presentes nos dados. Entre as principais ferramentas utilizadas nessa fase estão os gráficos de dispersão (scatter plots), que possibilitam visualizar a relação entre variáveis, identificar tendências, padrões lineares ou não lineares, outliers e colinearidades. No contexto de regressão, os scatter plots auxiliam na avaliação da relação entre a variável alvo e os preditores, enquanto em problemas de classificação, facilitam a inspeção da separabilidade das classes e a identificação de agrupamentos ou sobreposições, contribuindo para a escolha de algoritmos e estratégias de pré-processamento [12].

Além disso, para tarefas de classificação, a matriz de confusão é uma ferramenta fundamental para avaliar o desempenho dos modelos. Embora não seja uma métrica propriamente dita, ela organiza os resultados das previsões em uma tabela que evidencia acertos e erros para cada classe, permitindo visualizar quais classes são mais confundidas pelo modelo. A matriz de confusão serve de base para o cálculo de métricas como acurácia, precisão, revocação e F1-score, sendo indispensável para uma análise detalhada dos resultados [13].

Real / Previsto	Classe 1	Classe 2	Classe 3
Classe 1	a	b	c
Classe 2	d	e	f
Classe 3	g	h	i

Onde:

- Os elementos da diagonal (a, e, i) representam acertos do modelo para cada classe.
- Os elementos fora da diagonal representam erros de classificação (ex: b = Classe 1 classificada como Classe 2).

Para avaliar o desempenho dos modelos, foram adotadas métricas consagradas na literatura para tarefas de regressão e classificação, conforme discutido em [14]. Essas métricas permitem comparar diferentes algoritmos de forma objetiva e identificar pontos fortes e limitações de cada abordagem.

Regressão:

- **RMSE (Root Mean Squared Error):** Mede o erro quadrático médio entre os valores previstos e os valores reais. Valores menores indicam melhor desempenho, pois penalizam mais fortemente grandes desvios.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **MAE (Mean Absolute Error):** Representa o erro absoluto médio, sendo menos sensível a outliers do que o RMSE. Quanto menor, melhor.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **R^2 (Coeficiente de Determinação):** Indica a proporção da variância dos dados explicada pelo modelo, variando de $-\infty$ a 1. Valores próximos de 1 indicam bom ajuste, enquanto valores negativos sugerem desempenho inferior ao de uma média simples.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Classificação:

- **Acurácia:** Proporção de previsões corretas sobre o total de amostras. É uma métrica intuitiva, mas pode ser enganosa em cenários desbalanceados.

$$\text{Acurácia} = \frac{\text{número de acertos}}{\text{total de amostras}}$$

- **F1-score:** Média harmônica entre precisão e revocação, sendo especialmente útil para bases desbalanceadas. No caso multiclasse, utiliza-se a média ponderada.

$$F1_k = 2 \cdot \frac{\text{precisão}_k \cdot \text{revocação}_k}{\text{precisão}_k + \text{revocação}_k}$$

- **Kappa de Cohen:** Mede o grau de concordância entre as previsões do modelo e os valores reais, corrigindo o acaso. Varia de -1 (discordância total) a 1 (concordância perfeita), sendo útil para avaliar a robustez do classificador.

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

onde p_o é a proporção de concordância observada e p_e é a concordância esperada pelo acaso.

III. RESULTADOS E DISCUSSÃO

Esta seção apresenta e discute de forma detalhada os resultados obtidos nos experimentos de regressão e classificação realizados com os diferentes conjuntos de dados. São analisados o desempenho dos algoritmos avaliados em cada base, o efeito das etapas de pré-processamento e das estratégias de balanceamento de classes, bem como as diferenças observadas entre os métodos em relação às métricas adotadas. As análises comparativas destacam os pontos fortes e limitações de cada abordagem, permitindo extrair conclusões relevantes sobre a aplicabilidade e eficiência dos modelos em diferentes cenários.

A. Etapas dos Experimentos

- **Energy Efficiency e California Housing:** Utilizados para regressão. O primeiro visa prever os alvos Y1 e Y2 (consumo de aquecimento e resfriamento), enquanto o segundo busca estimar o valor médio das casas na Califórnia. Para ambos, foram aplicados os métodos Linear Regression, Random Forest Regressor, MLPRegressor e SVR, com normalização dos dados. As métricas avaliadas foram RMSE, MAE e R^2 .
- **Wine Quality (Red) e Iris:** Utilizados para classificação multiclasse. Ambos os conjuntos foram avaliados com Logistic Regression, Random Forest, MLPClassifier e SVC, nos cenários original (desbalanceado) e balanceado por oversampling. As métricas analisadas foram acurácia, F1-score e Kappa.

A seguir, os resultados e discussões são apresentados individualmente para cada dataset, destacando as relações entre métodos, métricas e características dos dados.

B. Resultados para Energy Efficiency

O dataset Energy Efficiency foi utilizado para tarefas de regressão, com predição dos alvos Y1 (aquecimento) e Y2 (resfriamento). Os resultados mostram que métodos mais complexos, como Random Forest e MLPRegressor, superam a Linear Regression em todas as métricas, especialmente em R^2 e RMSE, indicando melhor ajuste e menor erro. O SVR apresentou desempenho intermediário, sensível à escolha dos hiperparâmetros. As Figuras 1, 2, 3, 4, 5, 6, 7 e 8 ilustram os boxplots dos resíduos para cada método e alvo.

1) *Linear Regression:* O modelo Linear Regression serve como baseline para comparação. Apesar de simples e interpretável, apresenta limitações em capturar relações não lineares, o que se reflete nos maiores valores de RMSE e menores de R^2 em relação aos demais métodos. A Figura 1 apresenta o boxplot dos resíduos de RMSE para Y1, enquanto a Figura 2 mostra o mesmo para Y2.

Y1:




Fig. 1. Boxplot dos resíduos de RMSE para Y1 utilizando Linear Regression no dataset Energy Efficiency.

Resultados para Y1:

- **RMSE:** 2.9708
- **MAE:** 2.1091
- **R^2 :** 0.9128

Y2:




Fig. 2. Boxplot dos resíduos de RMSE para Y2 utilizando Linear Regression no dataset Energy Efficiency.

Resultados para Y2:

- **RMSE:** 3.2059
- **MAE:** 2.2713
- **R^2 :** 0.8849

2) *Random Forest Regressor:* O Random Forest apresentou desempenho superior ao modelo linear, especialmente em termos de RMSE e R^2 , mostrando robustez a outliers e excelente capacidade de generalização. Os resultados para Y1 e Y2 destacam a vantagem desse método em capturar relações não lineares e reduzir o erro de predição. A Figura 3 apresenta o boxplot dos resíduos de RMSE para Y1, enquanto a Figura 4 mostra o mesmo para Y2.

Y1:




Fig. 3. Boxplot dos resíduos de RMSE para Y1 utilizando Random Forest Regressor no dataset Energy Efficiency.

Resultados para Y1:

- **RMSE:** 0.5171
- **MAE:** 0.3450
- **R^2 :** 0.9973

Y2:




Fig. 4. Boxplot dos resíduos de RMSE para Y2 utilizando Random Forest Regressor no dataset Energy Efficiency.

Resultados para Y2:

- **RMSE:** 1.7317
- **MAE:** 1.0485
- **R^2 :** 0.9663

3) *MLPRegressor*: O *MLPRegressor*, por ser uma rede neural, conseguiu capturar padrões mais complexos, apresentando desempenho competitivo com o Random Forest, embora com maior variabilidade nos resultados. Isso sugere que redes neurais podem ser vantajosas em cenários com relações

não lineares, mas exigem ajuste fino dos hiperparâmetros. A Figura 5 apresenta o boxplot dos resíduos de RMSE para Y1, enquanto a Figura 6 mostra o mesmo para Y2.

Y1:




Fig. 5. Boxplot dos resíduos de RMSE para Y1 utilizando MLPRegressor no dataset Energy Efficiency.

Resultados para Y1:

- **RMSE:** 2.6173
- **MAE:** 1.8412
- **R^2 :** 0.9322

Y2:




Fig. 6. Boxplot dos resíduos de RMSE para Y2 utilizando MLPRegressor no dataset Energy Efficiency.

Resultados para Y2:

- **RMSE:** 2.9967
- **MAE:** 2.1238
- **R^2 :** 0.8993

4) *SVR*: O *SVR* apresentou desempenho intermediário, sendo sensível à escolha dos hiperparâmetros e à escala dos

dados. Embora tenha superado a Linear Regression em alguns cenários, não atingiu o desempenho dos métodos baseados em árvores ou redes neurais. A Figura 7 apresenta o boxplot dos resíduos de RMSE para Y1, enquanto a Figura 8 mostra o mesmo para Y2.

Y1:




Fig. 7. Boxplot dos resíduos de RMSE para Y1 utilizando SVR no dataset Energy Efficiency.

Resultados para Y1:

- **RMSE:** 2.8290
- **MAE:** 1.9028
- **R^2 :** 0.9210

Y2:




Fig. 8. Boxplot dos resíduos de RMSE para Y2 utilizando SVR no dataset Energy Efficiency.

Resultados para Y2:

- **RMSE:** 3.1696
- **MAE:** 2.1104
- **R^2 :** 0.8875

C. Resultados para California Housing

O dataset California Housing foi utilizado para regressão, visando prever o valor médio das casas em diferentes regiões da Califórnia. Os resultados mostram que Random Forest e MLPRegressor superam a Linear Regression e o SVR, especialmente em R^2 e RMSE. O Random Forest, em particular, apresentou o melhor desempenho, evidenciando sua robustez para dados tabulares. As Figuras 9, 10, 11 e 12 ilustram os boxplots dos resíduos para cada método.

1) *Linear Regression*: O modelo Linear Regression apresentou desempenho razoável, servindo como baseline, mas com limitações para capturar relações não lineares presentes nos dados. Isso se reflete nos valores mais altos de RMSE e menores de R^2 em comparação aos métodos mais avançados. O boxplot dos resíduos está na Figura 9.




Fig. 9. Boxplot dos resíduos de RMSE utilizando Linear Regression no dataset California Housing.

Resultados:

- **RMSE:** 0.7361
- **MAE:** 0.5327
- **R^2 :** 0.5918

2) *Random Forest Regressor*: O Random Forest Regressor obteve os melhores resultados em termos de RMSE e R^2 , mostrando-se robusto e eficiente para esse tipo de dado. Sua capacidade de modelar relações complexas e lidar com outliers foi determinante para o bom desempenho. O boxplot dos resíduos está na Figura 10.




Fig. 10. Boxplot dos resíduos de RMSE utilizando Random Forest Regressor no dataset California Housing.

Resultados:

- **RMSE:** 0.5071
- **MAE:** 0.3312
- **R^2 :** 0.8069

3) *MLPRegressor*: O *MLPRegressor* apresentou desempenho competitivo, conseguindo capturar padrões complexos, mas com maior variabilidade nos resultados. Isso indica que, embora redes neurais possam ser eficazes, são mais sensíveis à configuração dos hiperparâmetros. O boxplot dos resíduos está na Figura 11.




Fig. 11. Boxplot dos resíduos de RMSE utilizando MLPRegressor no dataset California Housing.

Resultados:

- **RMSE:** 0.5463
- **MAE:** 0.3729
- **R^2 :** 0.7757

4) *SVR*: O *SVR* teve desempenho inferior aos métodos anteriores, sendo mais sensível à escolha dos hiperparâmetros

e à escala dos dados. Sua limitação em capturar relações não lineares complexas ficou evidente nos resultados. O boxplot dos resíduos está na Figura 12.




Fig. 12. Boxplot dos resíduos de RMSE utilizando SVR no dataset California Housing.

Resultados:

- **RMSE:** 0.5925
- **MAE:** 0.3955
- **R^2 :** 0.7363

D. Resultados para Wine Quality (Red)

O dataset Wine Quality (Red) foi utilizado para classificação multiclasse, avaliando os métodos Logistic Regression, Random Forest, MLPClassifier e SVC. Os resultados são apresentados separadamente para os cenários sem e com balanceamento das classes. Observa-se que o balanceamento das classes impactou significativamente as métricas, principalmente para Random Forest e MLPClassifier, que apresentaram ganhos expressivos em acurácia e F1-score. As Figuras 13, 14, 15 e 16 ilustram os boxplots dos resultados para cada método.

Sem balanceamento: A Figura 13 mostra o boxplot dos resultados para Logistic Regression, 14 para Random Forest, 15 para MLPClassifier e 16 para SVC, todos sem balanceamento.

Logistic Regression




Fig. 13. Boxplot dos resultados para Logistic Regression sem balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.5893
- **F1-score:** 0.5544
- **Kappa:** 0.3096

Random Forest




Fig. 14. Boxplot dos resultados para Random Forest sem balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.6995
- **F1-score:** 0.6821
- **Kappa:** 0.5096

MLPClassifier




Fig. 15. Boxplot dos resultados para MLPClassifier sem balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.6120
- **F1-score:** 0.5935
- **Kappa:** 0.3646

SVC




Fig. 16. Boxplot dos resultados para SVC sem balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.6088
- **F1-score:** 0.5805
- **Kappa:** 0.3452

Com balanceamento: A Figura 17 mostra o boxplot dos resultados para Logistic Regression, 18 para Random Forest, 19 para MLPClassifier e 20 para SVC, todos com balanceamento.

Logistic Regression




Fig. 17. Boxplot dos resultados para Logistic Regression com balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.5174
- **F1-score:** 0.5055
- **Kappa:** 0.4210

Random Forest




Fig. 18. Boxplot dos resultados para Random Forest com balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.9480
- **F1-score:** 0.9474
- **Kappa:** 0.9375

MLPClassifier




Fig. 19. Boxplot dos resultados para MLPClassifier com balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.7515
- **F1-score:** 0.7443
- **Kappa:** 0.7017

SVC




Fig. 20. Boxplot dos resultados para SVC com balanceamento no dataset Wine Quality.

Resultados:

- **Acurácia:** 0.6088
- **F1-score:** 0.5805
- **Kappa:** 0.3452

E. Resultados para Iris

O dataset Iris foi utilizado para classificação multiclasse, avaliando os métodos Logistic Regression, Random Forest, MLPClassifier e SVC. Os resultados mostram que todos os métodos apresentaram desempenho elevado, com acurácia e F1-score acima de 0.91 mesmo sem balanceamento, refletindo a natureza bem comportada e balanceada do dataset. O balanceamento não trouxe ganhos significativos, indicando que o conjunto já era adequado para as tarefas propostas. As Figuras 21, 22, 23 e 24 ilustram os boxplots dos resultados para cada método.

A Figura 21 mostra o boxplot dos resultados para Logistic Regression, 22 para Random Forest, 23 para MLPClassifier e 24 para SVC, todos sem balanceamento.

A Figura 25 mostra o boxplot dos resultados para Logistic Regression, 26 para Random Forest, 27 para MLPClassifier e 28 para SVC, todos com balanceamento.

Sem balanceamento: **Logistic Regression**




Fig. 21. Boxplot dos resultados para Logistic Regression sem balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9189
- **F1-score:** 0.9188
- **Kappa:** 0.8761

Random Forest




Fig. 22. Boxplot dos resultados para Random Forest sem balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9467
- **F1-score:** 0.9465
- **Kappa:** 0.9180

MLPClassifier




Fig. 23. Boxplot dos resultados para MLPClassifier sem balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9522
- **F1-score:** 0.9521
- **Kappa:** 0.9259

SVC




Fig. 24. Boxplot dos resultados para SVC sem balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9522
- **F1-score:** 0.9521
- **Kappa:** 0.9265

Com balanceamento: **Logistic Regression**




Fig. 25. Boxplot dos resultados para Logistic Regression com balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9189
- **F1-score:** 0.9188
- **Kappa:** 0.8761

Random Forest




Fig. 26. Boxplot dos resultados para Random Forest com balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9467
- **F1-score:** 0.9465
- **Kappa:** 0.9180

MLPClassifier




Fig. 27. Boxplot dos resultados para MLPClassifier com balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9533
- **F1-score:** 0.9532
- **Kappa:** 0.9274

SVC




Fig. 28. Boxplot dos resultados para SVC com balanceamento no dataset Iris.

Resultados:

- **Acurácia:** 0.9522
- **F1-score:** 0.9521
- **Kappa:** 0.9265

IV. CONCLUSÃO

Os experimentos realizados permitiram comparar o desempenho de diferentes algoritmos de regressão e classificação multiclasse em cenários distintos, utilizando métricas médias ao longo de múltiplas execuções. A seguir, os principais resultados comparativos para cada base de dados e cenário são discutidos, com referência direta a cada figura para facilitar a análise visual.

A. Análise dos Resultados de Regressão

No conjunto Energy Efficiency, observa-se que alguns modelos apresentam menor erro médio (RMSE e MAE), enquanto outros se destacam pelo maior poder explicativo (R^2). As Figuras 29, 30 e 31 ilustram essas diferenças, permitindo identificar visualmente qual modelo apresenta menor erro e qual possui maior capacidade explicativa, auxiliando na escolha do algoritmo mais adequado conforme a métrica de interesse.




Fig. 29. Boxplot do RMSE médio entre algoritmos de regressão para Energy Efficiency.




Fig. 30. Boxplot do MAE médio entre algoritmos de regressão para Energy Efficiency.




Fig. 31. Boxplot do R^2 médio entre algoritmos de regressão para Energy Efficiency.

No caso do California Housing, o comportamento dos algoritmos também varia, reforçando a importância de uma análise contextualizada. As Figuras 32, 33 e 34 apresentam, respectivamente, os boxplots de RMSE, MAE e R^2 para cada modelo. Essa visualização permite comparar rapidamente o desempenho dos algoritmos e identificar quais apresentam menor erro ou maior explicabilidade para essa base específica.




Fig. 32. Boxplot do RMSE médio entre algoritmos de regressão para California Housing.




Fig. 33. Boxplot do MAE médio entre algoritmos de regressão para California Housing.




Fig. 34. Boxplot do R^2 médio entre algoritmos de regressão para California Housing.

B. Análise dos Resultados de Classificação

Na base Wine Quality sem balanceamento, nota-se diferenças relevantes entre os métodos, especialmente em métricas que consideram o equilíbrio entre as classes, como F1-score e Kappa. As Figuras 35, 36 e 37 apresentam, respectivamente, os boxplots de acurácia, F1-score e Kappa para cada algoritmo. Isso permite comparar não só o desempenho geral, mas também a robustez dos modelos frente ao desbalanceamento das classes.




Fig. 35. Boxplot da acurácia média entre algoritmos de classificação para Wine Quality (sem balanceamento).




Fig. 36. Boxplot do F1-score médio entre algoritmos de classificação para Wine Quality (sem balanceamento).




Fig. 37. Boxplot do Kappa médio entre algoritmos de classificação para Wine Quality (sem balanceamento).

Mesmo em bases mais equilibradas, como a Iris, há variação entre os algoritmos, o que reforça a necessidade de avaliar múltiplas métricas. As Figuras 38, 39 e 40 mostram, respectivamente, os boxplots de acurácia, F1-score e Kappa para os modelos testados na base Iris sem balanceamento, evidenciando diferenças de desempenho e estabilidade entre eles.




Fig. 38. Boxplot da acurácia média entre algoritmos de classificação para Iris (sem balanceamento).




Fig. 39. Boxplot do F1-score médio entre algoritmos de classificação para Iris (sem balanceamento).




Fig. 40. Boxplot do Kappa médio entre algoritmos de classificação para Iris (sem balanceamento).

Ao aplicar o balanceamento nas bases, nota-se mudanças no desempenho dos algoritmos, principalmente em métricas

como F1-score e Kappa, tornando a comparação mais justa. As Figuras 41, 42 e 43 apresentam os boxplots de acurácia, F1-score e Kappa para a base Wine Quality com balanceamento, enquanto as Figuras 44, 45 e 46 mostram os mesmos indicadores para a base Iris balanceada. Essas visualizações evidenciam os ganhos proporcionados pelo balanceamento, especialmente na redução da variabilidade e no aumento da robustez dos modelos.




Fig. 41. Boxplot da acurácia média entre algoritmos de classificação para Wine Quality (com balanceamento).




Fig. 42. Boxplot do F1-score médio entre algoritmos de classificação para Wine Quality (com balanceamento).




Fig. 43. Boxplot do Kappa médio entre algoritmos de classificação para Wine Quality (com balanceamento).




Fig. 44. Boxplot da acurácia média entre algoritmos de classificação para Iris (com balanceamento).




Fig. 45. Boxplot do F1-score médio entre algoritmos de classificação para Iris (com balanceamento).




Fig. 46. Boxplot do Kappa médio entre algoritmos de classificação para Iris (com balanceamento).

Síntese dos Resultados

A análise dos resultados permite identificar, de forma clara e objetiva, quais algoritmos se destacaram positiva ou negativamente em cada cenário avaliado:

- **Energy Efficiency (Regressão):** O Random Forest foi o modelo mais eficiente para ambos os alvos (Y1 e Y2), apresentando os menores valores de RMSE e MAE, além do maior R^2 , o que indica excelente ajuste e

baixa margem de erro. O Linear Regression, por sua vez, obteve os maiores erros e menor poder explicativo, especialmente para Y2.

- **California Housing (Regressão):** O Random Forest novamente se destacou, alcançando o menor RMSE, menor MAE e maior R^2 . O Linear Regression apresentou o pior desempenho, com os maiores valores de erro e menor capacidade explicativa.
- **Wine Quality (Classificação, sem balanceamento):** O Random Forest foi o algoritmo mais eficaz, obtendo os maiores valores de acurácia, F1-score e Kappa. O Logistic Regression apresentou o pior desempenho geral, com os menores valores nessas métricas.
- **Wine Quality (Classificação, com balanceamento):** O Random Forest manteve o melhor desempenho, superando os demais algoritmos em acurácia, F1-score e Kappa. O Logistic Regression continuou com os piores resultados, especialmente em acurácia e F1-score.
- **Iris (Classificação, sem balanceamento):** Todos os métodos apresentaram desempenho elevado, mas MLP e SVM obtiveram os melhores resultados, com acurácia e F1-score de 0.9522 e Kappa acima de 0.925. O Logistic Regression, embora com desempenho um pouco inferior, ainda apresentou resultados satisfatórios.
- **Iris (Classificação, com balanceamento):** O MLP foi o destaque, com acurácia, F1-score e Kappa ligeiramente superiores aos demais. O Logistic Regression novamente apresentou os menores valores, mas a diferença entre os métodos foi pequena devido ao bom balanceamento e à simplicidade do dataset.

De maneira geral, o Random Forest mostrou-se o algoritmo mais robusto e eficiente para tarefas de regressão e classificação em cenários complexos ou desbalanceados. Já o MLP e o SVM se destacaram em bases bem comportadas, como a Iris. O Logistic Regression, apesar de sua simplicidade e interpretabilidade, apresentou desempenho inferior nos cenários mais desafiadores, mas ainda assim foi competitivo em bases balanceadas e de menor complexidade.

REFERÊNCIAS

- [1] U. M. L. Repository, “Energy efficiency data set,” 2017, conjunto de dados para previsão de carga térmica de edifícios. [Online]. Available: <https://archive.ics.uci.edu/ml/datasets/Energy+efficiency>
- [2] R. K. Pace and R. Barry, “California housing data set,” 1997, dados derivados do censo de 1990 para regressão de preços de imóveis. [Online]. Available: https://inria.github.io/scikit-learn-mooc/python_scripts/datasets_california_housing.html
- [3] U. M. L. Repository, “Wine quality data set (red wine),” 2009, dados físico-químicos de vinhos tintos da região Vinho Verde, Portugal. [Online]. Available: <https://archive.ics.uci.edu/ml/datasets/Wine+Quality>
- [4] R. A. Fisher, “Iris data set,” 1936, conjunto clássico para classificação multiclasse de espécies de flores. [Online]. Available: <https://archive.ics.uci.edu/ml/datasets/Iris>
- [5] J. C. da Silva Dantas and C. T. de Sousa, “Impacto de técnicas de amostragem na performance de modelos de predição de desempenho de alunos em pensamento computacional,” *Contradição – Revista Interdisciplinar de Ciências Humanas e Sociais*, vol. 5, no. 2, p. e067, 2024, estudo sobre o uso de SMOTE e oversampling para melhorar métricas de classificação em cenários desbalanceados. [Online]. Available: [https://www.academia.edu/126800866/IMPACTO_DE_T%](https://www.academia.edu/126800866/IMPACTO_DE_T%C3%89CNICAS_DE_AMOSTRAGEM_NA_PERFORMANCE_DE_)

MODELOS_DE_PREDI%C3%87%C3%83O_DE_DESEMPENHO_DE_ALUNOS_EM_PENSAMENTO_COMPUTACIONAL

- [6] J. P. B. C. da Silva, *Modelos de regressão linear e logística utilizando o software R*, 2016.
- [7] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [8] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Pearson, 2009.
- [9] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [10] D. W. Hosmer, S. Lemeshow, and R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. Wiley, 2013.
- [11] L. A. Gonzalez, “Regressão logística e suas aplicações,” <https://monografias.ufma.br/jspui/handle/123456789/3572>, 2018, universidade Federal do Maranhão – Monografia de Graduação.
- [12] R. Honório, “Análise exploratória de dados: descobrindo padrões e tendências,” 2024, artigo introdutório sobre técnicas de visualização, incluindo scatter plots, para análise exploratória. [Online]. Available: <https://hub.asimov.academy/blog/analise-exploratoria-de-dados/>
- [13] D. Mariano, “Métricas de avaliação em machine learning: acurácia, sensibilidade, precisão, especificidade e f-score,” *BIOINFO – Revista Brasileira de Bioinformática*, vol. 1, no. 1, 2021, artigo introdutório sobre matriz de confusão e métricas de classificação. [Online]. Available: <https://bioinfo.com.br/metricas-de-avaliacao-em-machine-learning-acuracia-sensibilidade-precisao-especificidade>
- [14] F. da Silva, “Mae, rmse, acc, f1, roc, r²? avaliação de desempenho de modelos preditivos,” 2023, artigo técnico sobre métricas de regressão e classificação em modelos de machine learning. [Online]. Available: <https://analisemacro.com.br/econometria-e-machine-learning/mae-rmse-acc-f1-roc-r2-avaliacao-de-desempenho-de-modelos-preditivos/>