

Classificação e Regressão Supervisionadas

com Algoritmos de Aprendizado de Máquina

Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional,
CEFET-MG

29 de julho de 2025

Motivação e Objetivo

- Inteligência Computacional é fundamental para resolver problemas complexos em ciência de dados, engenharia e saúde.
- Necessidade de modelos preditivos robustos e confiáveis diante do aumento de dados.
- Objetivo: comparar técnicas de regressão e classificação multiclasse em bases públicas (Energy Efficiency, California Housing, Wine Quality, Iris).
- Avaliar modelos lineares, ensembles, redes neurais e métodos baseados em margens, considerando diferentes estratégias de pré-processamento.

Processamento dos Dados

- Datasets utilizados:
 - **Regressão:** Energy Efficiency, California Housing
 - **Classificação:** Wine Quality (Red), Iris
- Pré-processamento:
 - Normalização dos atributos (para regressão e classificação)
 - Codificação de variáveis categóricas (quando necessário)
 - Divisão dos dados em treino e teste:
 - Regressão: divisão aleatória (80% treino, 20% teste)
 - Classificação: divisão estratificada (70% treino, 30% teste) para preservar a proporção das classes
 - Balanceamento de classes para classificação: aplicado em Wine Quality e Iris para melhorar a acurácia e F1-score

Energy Efficiency Dataset

- **Tipo:** Regressão
- **Amostras:** 768
- **Atributos:** 8 variáveis de entrada (ex: área, orientação, compactação, etc.)
- **Alvos:** Y1 (Heating Load), Y2 (Cooling Load)
- **Descrição:** Dados de edifícios simulados para prever consumo de energia para aquecimento e resfriamento.
- **Fonte:** UCI Machine Learning Repository

- **Tipo:** Regressão
- **Amostras:** 20.640
- **Atributos:** 8 variáveis de entrada (ex: média de quartos, população, latitude, longitude, etc.)
- **Alvo:** MedHouseVal (valor mediano das casas em milhares de dólares)
- **Descrição:** Dados do censo da Califórnia para prever o valor das casas por região.
- **Fonte:** StatLib, UCI Machine Learning Repository

Wine Quality (Red) Dataset

- **Tipo:** Classificação multiclasse
- **Amostras:** 1.599
- **Atributos:** 11 variáveis físico-químicas (ex: acidez, açúcar, pH, álcool, etc.)
- **Alvo:** Qualidade do vinho (nota de 3 a 8)
- **Descrição:** Avaliação da qualidade de vinhos tintos portugueses com base em características químicas.
- **Fonte:** UCI Machine Learning Repository

- **Tipo:** Classificação multiclasse
- **Amostras:** 150
- **Atributos:** 4 variáveis (comprimento e largura das sépalas e pétalas)
- **Alvo:** Espécie da flor (Setosa, Versicolor, Virginica)
- **Descrição:** Clássico conjunto de dados para classificação de espécies de íris.
- **Fonte:** UCI Machine Learning Repository

- Modelos avaliados:
 - **Regressão:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR (Support Vector Regressor)
 - **Classificação:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM (Support Vector Machine)
- Cada experimento foi repetido 30 vezes para garantir robustez estatística dos resultados.

- **O que são?** Modelos que assumem uma relação linear entre as variáveis de entrada e a saída.
- **Exemplos:** Regressão Linear (para prever valores contínuos) e Regressão Logística (para classificação).
- **Características:**
 - Simples, rápidos e fáceis de interpretar.
 - Funcionam bem quando a relação entre as variáveis é aproximadamente linear.
 - Limitados para problemas com relações não-lineares complexas.

Ensembles: Random Forest

- **O que são?** Técnicas que combinam vários modelos simples (como árvores de decisão) para formar um modelo mais robusto.
- **Exemplo:** Random Forest, que constrói diversas árvores de decisão e faz a média (regressão) ou votação (classificação) dos resultados.
- **Características:**
 - Reduzem o risco de overfitting.
 - Lidam bem com dados ruidosos e desbalanceados.
 - Geralmente apresentam alta precisão em problemas reais.

- **O que são?** Modelos inspirados no cérebro humano, compostos por camadas de neurônios artificiais.
- **Exemplo:** MLP (Perceptron Multicamadas), com múltiplas camadas ocultas entre entrada e saída.
- **Características:**
 - Capazes de aprender relações não-lineares complexas.
 - Requerem mais dados e processamento.
 - Muito flexíveis, mas podem ser difíceis de interpretar.

Métodos Baseados em Margens: SVM/SVR

- **O que são?** Algoritmos que buscam separar as classes (ou ajustar uma faixa para regressão) maximizando a margem entre os dados.
- **Exemplo:** SVM (Support Vector Machine) para classificação e SVR (Support Vector Regressor) para regressão.
- **Características:**
 - Eficazes para dados com fronteiras complexas.
 - Sensíveis à escolha dos parâmetros e à normalização dos dados.
 - Podem alcançar alta precisão em problemas bem definidos.

Métricas de Avaliação: Classificação

- **Acurácia:**

- Proporção de acertos sobre o total de previsões.
- Fórmula: $Acurácia = \frac{TP+TN}{TP+TN+FP+FN}$

- **F1-score:**

- Média harmônica entre precisão e revocação.
- Fórmula: $F_1 = 2 \cdot \frac{Precisão \cdot Revocação}{Precisão + Revocação}$
- Útil para bases desbalanceadas.

- **Kappa:**

- Mede o acordo entre as previsões do modelo e os valores reais, corrigido pelo acaso.
- Fórmula: $Kappa = \frac{p_o - p_e}{1 - p_e}$
- p_o = acurácia observada, p_e = acurácia esperada pelo acaso.

Matriz de Confusão

- Mostra acertos e erros do modelo para cada classe.
- Permite identificar:
 - **TP**: Verdadeiro Positivo
 - **TN**: Verdadeiro Negativo
 - **FP**: Falso Positivo
 - **FN**: Falso Negativo
- Base para métricas como acurácia, precisão, revocação, F1-score, entre outras.

	P	N
P	TP	FN
N	FP	TN

Métricas de Avaliação: Regressão

- **RMSE (Root Mean Squared Error):**

- Mede o erro quadrático médio entre valores previstos e reais.
- Fórmula: $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$
- Valores menores indicam melhor desempenho.

- **MAE (Mean Absolute Error):**


- Média dos valores absolutos dos erros.
- Fórmula: $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$
- Fácil de interpretar, menos sensível a outliers que o RMSE.

- **R^2 (Coeficiente de Determinação):**

- Mede a proporção da variância explicada pelo modelo.
- Fórmula: $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$
- Valores próximos de 1 indicam bom ajuste.

Gráfico de Dispersão (Scatter Plot)


- Utilizado para comparar visualmente os valores reais e previstos em problemas de regressão.
- Pontos próximos da linha $y = x$ indicam boas previsões.




- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR
- **Resultados para Y1:**
 - **Linear Regression:** $RMSE = 2.9708$, $MAE = 2.1091$, $R^2 = 0.9128$
 - **Random Forest:** $RMSE = 0.5171$, $MAE = 0.3450$, $R^2 = 0.9973$
 - **MLPRegressor:** $RMSE = 2.6173$, $MAE = 1.8412$, $R^2 = 0.9322$
 - **SVR:** $RMSE = 2.8290$, $MAE = 1.9028$, $R^2 = 0.9210$

Energy Efficiency: Regressão (Y1) - Gráficos de Dispersão


- **Análise:** Modelos com pontos mais próximos da diagonal indicam melhores previsões. Random Forest apresenta maior aderência à linha ideal, enquanto Linear Regression e SVR mostram maior dispersão.




Linear Regression



Random Forest



MLPRegressor




SVR


- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR
- **Resultados para Y2:**
 - **Linear Regression:** $RMSE = 3.2059$, $MAE = 2.2713$, $R^2 = 0.8849$
 - **Random Forest:** $RMSE = 1.7317$, $MAE = 1.0485$, $R^2 = 0.9663$
 - **MLPRegressor:** $RMSE = 2.9967$, $MAE = 2.1238$, $R^2 = 0.8993$
 - **SVR:** $RMSE = 3.1696$, $MAE = 2.1104$, $R^2 = 0.8875$

Energy Efficiency: Regressão (Y2) - Gráficos de Dispersão


- **Análise:** Random Forest novamente apresenta maior aderência à linha ideal, indicando melhor desempenho. Linear Regression e SVR mostram maior dispersão dos pontos, sugerindo maior erro nas previsões.




Linear Regression



Random Forest



MLPRegressor




SVR


- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR
- **Resultados:**
 - **Linear Regression:** $RMSE = 0.7361$, $MAE = 0.5327$, $R^2 = 0.5918$
 - **Random Forest:** $RMSE = 0.5071$, $MAE = 0.3312$, $R^2 = 0.8069$
 - **MLPRegressor:** $RMSE = 0.5463$, $MAE = 0.3729$, $R^2 = 0.7757$
 - **SVR:** $RMSE = 0.5925$, $MAE = 0.3955$, $R^2 = 0.7363$

California Housing: Regressão - Gráficos de Dispersão


- **Análise:** Random Forest apresenta melhor aderência à linha ideal, indicando maior precisão. Linear Regression e SVR mostram maior dispersão dos pontos, sugerindo maior erro nas previsões.




Linear Regression



Random Forest



MLPRegressor




SVR

Wine Quality (Red): Classificação - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados:**
 - **Logistic Regression:** Acurácia = 0.62, F1-score = 0.59, Kappa = 0.47
 - **Random Forest:** Acurácia = 0.71, F1-score = 0.70, Kappa = 0.60
 - **MLPClassifier:** Acurácia = 0.66, F1-score = 0.64, Kappa = 0.53
 - **SVM:** Acurácia = 0.64, F1-score = 0.62, Kappa = 0.50
- **Análise:** Random Forest apresentou o melhor desempenho geral.

Wine Quality (Red): Matrizes de Confusão


- Análise:** As matrizes de confusão mostram que Random Forest teve maior acerto nas classes principais, enquanto Logistic Regression e SVM apresentaram mais confusões entre as classes intermediárias.




Logistic Regression



Random Forest



MLPClassifier




SVM

Wine Quality (Red): Classificação (Com Balanceamento) - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados após balanceamento:**
 - **Logistic Regression:** Acurácia = 0.66, F1-score = 0.64, Kappa = 0.54
 - **Random Forest:** Acurácia = 0.74, F1-score = 0.73, Kappa = 0.65
 - **MLPClassifier:** Acurácia = 0.69, F1-score = 0.68, Kappa = 0.58
 - **SVM:** Acurácia = 0.67, F1-score = 0.66, Kappa = 0.56
- **Análise:** O balanceamento das classes melhorou o desempenho de todos os modelos, especialmente Random Forest.

Wine Quality (Red): Matrizes de Confusão (Com Balanceamento)


- Análise:** As matrizes de confusão mostram que, após o balanceamento, todos os modelos tiveram melhor desempenho nas classes minoritárias, com Random Forest mantendo o melhor acerto geral.




Logistic Regression



Random Forest



MLPClassifier




SVM


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados:**
 - **Logistic Regression:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **Random Forest:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **MLPClassifier:** Acurácia = 0.96, F1-score = 0.96, Kappa = 0.94
 - **SVM:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
- **Análise:** Todos os modelos apresentaram desempenho excelente, com destaque para Random Forest e SVM.

Iris: Matrizes de Confusão


- **Análise:** As matrizes de confusão mostram que todos os modelos classificaram corretamente quase todas as amostras, com pouquíssimos erros, evidenciando a facilidade do problema para esses algoritmos.




Logistic Regression



Random Forest



MLPClassifier




SVM

Iris: Classificação (Com Balanceamento) - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados após balanceamento:**
 - **Logistic Regression:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **Random Forest:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **MLPClassifier:** Acurácia = 0.96, F1-score = 0.96, Kappa = 0.94
 - **SVM:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
- **Análise:** O balanceamento manteve o excelente desempenho dos modelos, com todos apresentando alta acurácia e F1-score.

Iris: Matrizes de Confusão (Com Balanceamento)


- **Análise:** As matrizes de confusão mostram que todos os modelos continuam classificando corretamente quase todas as amostras, mesmo após o balanceamento das classes.




Logistic Regression



Random Forest



MLPClassifier



SVM

Síntese dos Resultados: Regressão (Tabela)

Resultados dos algoritmos de regressão

Dataset	Algoritmo	RMSE	MAE	R ²
Energy (Y1)	Linear Regression	2.9708	2.1091	0.9128
Energy (Y1)	Random Forest	0.5187	0.3462	0.9973
Energy (Y1)	MLP	2.6125	1.8421	0.9324
Energy (Y1)	SVR	2.8290	1.9028	0.9210
Energy (Y2)	Linear Regression	3.2059	2.2713	0.8849
Energy (Y2)	Random Forest	1.7285	1.0459	0.9664
Energy (Y2)	MLP	3.0091	2.1409	0.8985
Energy (Y2)	SVR	3.1696	2.1104	0.8875
California	Linear Regression	0.7361	0.5327	0.5918
California	Random Forest	0.5062	0.3309	0.8075
California	MLP	0.5447	0.3728	0.7771
California	SVR	0.5925	0.3955	0.7363

Síntese dos Resultados: Regressão (Análise)

- O Random Forest foi o modelo mais eficiente para ambos os conjuntos de regressão, apresentando os menores valores de RMSE e MAE, além do maior R^2 .
- Linear Regression obteve os maiores erros e menor poder explicativo, especialmente para Y2 no Energy Efficiency.
- MLP e SVR tiveram desempenho intermediário, com MLP superando o modelo linear em ambos os conjuntos.

Síntese dos Resultados: Classificação (Sem Balanceamento)

Resultados dos algoritmos de classificação (sem balanceamento)

Dataset	Algoritmo	Acurácia	F1-score	Kappa
Wine	Logistic Regression	0.5893	0.5544	0.3096
Wine	Random Forest	0.6948	0.6769	0.5014
Wine	MLP	0.6139	0.5950	0.3676
Wine	SVM	0.6088	0.5805	0.3452
Iris	Logistic Regression	0.9189	0.9188	0.8761
Iris	Random Forest	0.9500	0.9497	0.9230
Iris	MLP	0.9522	0.9521	0.9256
Iris	SVM	0.9522	0.9521	0.9265

Síntese dos Resultados: Classificação (Com Balanceamento)

Resultados dos algoritmos de classificação (com balanceamento)

Dataset	Algoritmo	Acurácia	F1-score	Kappa
Wine	Logistic Regression	0.5167	0.5045	0.4201
Wine	Random Forest	0.9478	0.9473	0.9374
Wine	MLP	0.7583	0.7507	0.7098
Wine	SVM	0.6088	0.5805	0.3452
Iris	Logistic Regression	0.9189	0.9188	0.8761
Iris	Random Forest	0.9456	0.9454	0.9161
Iris	MLP	0.9544	0.9543	0.9294
Iris	SVM	0.9522	0.9521	0.9265

Síntese dos Resultados: Classificação (Análise)

- O Random Forest foi o algoritmo mais robusto e eficiente, especialmente em cenários complexos ou desbalanceados.
- MLP e SVM se destacaram em bases bem comportadas, como a Iris.
- Logistic Regression, apesar de simples e interpretável, teve desempenho inferior nos cenários mais desafiadores, mas foi competitivo em bases balanceadas.

- O Random Forest demonstrou ser o algoritmo mais robusto e eficiente para tarefas de regressão e classificação, especialmente em cenários complexos ou desbalanceados.
- MLP e SVM também apresentaram excelente desempenho, principalmente em bases bem comportadas, como a Iris.
- Logistic Regression, apesar de sua simplicidade e interpretabilidade, mostrou desempenho inferior nos cenários mais desafiadores, mas manteve-se competitivo em conjuntos de dados balanceados e de menor complexidade.

Obrigado!

Perguntas?