

Classificação e Regressão Supervisionadas

com Algoritmos de Aprendizado de Máquina

Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional,
CEFET-MG

29 de julho de 2025

Motivação e Objetivo

- Inteligência Computacional é fundamental para resolver problemas complexos em ciência de dados, engenharia e saúde.
- Necessidade de modelos preditivos robustos e confiáveis diante do aumento de dados.
- Objetivo: comparar técnicas de regressão e classificação multiclasse em bases públicas (Energy Efficiency, California Housing, Wine Quality, Iris).
- Avaliar modelos lineares, ensembles, redes neurais e métodos baseados em margens, considerando diferentes estratégias de pré-processamento.

Processamento dos Dados

- Datasets utilizados:
 - **Regressão:** Energy Efficiency, California Housing
 - **Classificação:** Wine Quality (Red), Iris
- Pré-processamento:
 - Normalização dos atributos (para regressão e classificação)
 - Codificação de variáveis categóricas (quando necessário)
 - Divisão dos dados em treino e teste:
 - Regressão: divisão aleatória (70% treino, 30% teste)
 - Classificação: divisão estratificada (70% treino, 30% teste) para preservar a proporção das classes
 - Balanceamento de classes para classificação: aplicado em Wine Quality e Iris para melhorar a acurácia e F1-score

Energy Efficiency Dataset

- **Tipo:** Regressão
- **Amostras:** 768
- **Atributos:** 8 variáveis de entrada (ex: área, orientação, compactação, etc.)
- **Alvos:** Y1 (Heating Load), Y2 (Cooling Load)
- **Descrição:** Dados de edifícios simulados para prever consumo de energia para aquecimento e resfriamento.
- **Fonte:** UCI Machine Learning Repository

- **Tipo:** Regressão
- **Amostras:** 20.640
- **Atributos:** 8 variáveis de entrada (ex: média de quartos, população, latitude, longitude, etc.)
- **Alvo:** MedHouseVal (valor mediano das casas em milhares de dólares)
- **Descrição:** Dados do censo da Califórnia para prever o valor das casas por região.
- **Fonte:** StatLib, UCI Machine Learning Repository

Wine Quality (Red) Dataset

- **Tipo:** Classificação multiclasse
- **Amostras:** 1.599
- **Atributos:** 11 variáveis físico-químicas (ex: acidez, açúcar, pH, álcool, etc.)
- **Alvo:** Qualidade do vinho (nota de 3 a 8)
- **Descrição:** Avaliação da qualidade de vinhos tintos portugueses com base em características químicas.
- **Fonte:** UCI Machine Learning Repository

- **Tipo:** Classificação multiclasse
- **Amostras:** 150
- **Atributos:** 4 variáveis (comprimento e largura das sépalas e pétalas)
- **Alvo:** Espécie da flor (Setosa, Versicolor, Virginica)
- **Descrição:** Clássico conjunto de dados para classificação de espécies de íris.
- **Fonte:** UCI Machine Learning Repository

- Modelos avaliados:
 - **Regressão:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR (Support Vector Regressor)
 - **Classificação:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM (Support Vector Machine)
- Cada experimento foi repetido 30 vezes para garantir robustez estatística dos resultados.

- **O que são?** Modelos que assumem uma relação linear entre as variáveis de entrada e a saída.
- **Exemplos:** Regressão Linear (para prever valores contínuos) e Regressão Logística (para classificação).
- **Características:**
 - Simples, rápidos e fáceis de interpretar.
 - Funcionam bem quando a relação entre as variáveis é aproximadamente linear.
 - Limitados para problemas com relações não-lineares complexas.

Ensembles: Random Forest

- **O que são?** Técnicas que combinam vários modelos simples (como árvores de decisão) para formar um modelo mais robusto.
- **Exemplo:** Random Forest, que constrói diversas árvores de decisão e faz a média (regressão) ou votação (classificação) dos resultados.
- **Características:**
 - Reduzem o risco de overfitting.
 - Lidam bem com dados ruidosos e desbalanceados.
 - Geralmente apresentam alta precisão em problemas reais.

- **O que são?** Modelos inspirados no cérebro humano, compostos por camadas de neurônios artificiais.
- **Exemplo:** MLP (Perceptron Multicamadas), com múltiplas camadas ocultas entre entrada e saída.
- **Características:**
 - Capazes de aprender relações não-lineares complexas.
 - Requerem mais dados e processamento.
 - Muito flexíveis, mas podem ser difíceis de interpretar.

Métodos Baseados em Margens: SVM/SVR

- **O que são?** Algoritmos que buscam separar as classes (ou ajustar uma faixa para regressão) maximizando a margem entre os dados.
- **Exemplo:** SVM (Support Vector Machine) para classificação e SVR (Support Vector Regressor) para regressão.
- **Características:**
 - Eficazes para dados com fronteiras complexas.
 - Sensíveis à escolha dos parâmetros e à normalização dos dados.
 - Podem alcançar alta precisão em problemas bem definidos.

Métricas de Avaliação: Classificação

- **Acurácia:**

- Proporção de acertos sobre o total de previsões.
- Fórmula: $Acurácia = \frac{TP+TN}{TP+TN+FP+FN}$

- **F1-score:**

- Média harmônica entre precisão e revocação.
- Fórmula: $F_1 = 2 \cdot \frac{Precisão \cdot Revocação}{Precisão + Revocação}$
- Útil para bases desbalanceadas.

- **Kappa:**

- Mede o acordo entre as previsões do modelo e os valores reais, corrigido pelo acaso.
- Fórmula: $Kappa = \frac{p_o - p_e}{1 - p_e}$
- p_o = acurácia observada, p_e = acurácia esperada pelo acaso.

Matriz de Confusão

- Mostra acertos e erros do modelo para cada classe.
- Permite identificar:
 - **TP**: Verdadeiro Positivo
 - **TN**: Verdadeiro Negativo
 - **FP**: Falso Positivo
 - **FN**: Falso Negativo
- Base para métricas como acurácia, precisão, revocação, F1-score, entre outras.

	P	N
P	TP	FN
N	FP	TN

- **RMSE (Root Mean Squared Error):**

- Mede o erro quadrático médio entre valores previstos e reais.
- Fórmula: $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$
- Valores menores indicam melhor desempenho.

- **MAE (Mean Absolute Error):**


- Média dos valores absolutos dos erros.
- Fórmula: $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$
- Fácil de interpretar, menos sensível a outliers que o RMSE.

- **R^2 (Coeficiente de Determinação):**

- Mede a proporção da variância explicada pelo modelo.
- Fórmula: $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$
- Valores próximos de 1 indicam bom ajuste.

Gráfico de Dispersão (Scatter Plot)


- Utilizado para comparar visualmente os valores reais e previstos em problemas de regressão.
- Pontos próximos da linha $y = x$ indicam boas previsões.




- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR
- **Resultados para Y1:**
 - **Linear Regression:** $RMSE = 2.9708$, $MAE = 2.1091$, $R^2 = 0.9128$
 - **Random Forest:** $RMSE = 0.5171$, $MAE = 0.3450$, $R^2 = 0.9973$
 - **MLPRegressor:** $RMSE = 2.6173$, $MAE = 1.8412$, $R^2 = 0.9322$
 - **SVR:** $RMSE = 2.8290$, $MAE = 1.9028$, $R^2 = 0.9210$

Energy Efficiency: Regressão (Y1) - Gráficos de Dispersão


- **Análise:** Modelos com pontos mais próximos da diagonal indicam melhores previsões. Random Forest apresenta maior aderência à linha ideal, enquanto Linear Regression e SVR mostram maior dispersão.




Linear Regression



Random Forest



MLPRegressor




SVR


- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR
- **Resultados para Y2:**
 - **Linear Regression:** $RMSE = 3.2059$, $MAE = 2.2713$, $R^2 = 0.8849$
 - **Random Forest:** $RMSE = 1.7317$, $MAE = 1.0485$, $R^2 = 0.9663$
 - **MLPRegressor:** $RMSE = 2.9967$, $MAE = 2.1238$, $R^2 = 0.8993$
 - **SVR:** $RMSE = 3.1696$, $MAE = 2.1104$, $R^2 = 0.8875$

Energy Efficiency: Regressão (Y2) - Gráficos de Dispersão


- **Análise:** Random Forest novamente apresenta maior aderência à linha ideal, indicando melhor desempenho. Linear Regression e SVR mostram maior dispersão dos pontos, sugerindo maior erro nas previsões.




Linear Regression



Random Forest



MLPRegressor




SVR


- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR
- **Resultados:**
 - **Linear Regression:** $RMSE = 0.7361$, $MAE = 0.5327$, $R^2 = 0.5918$
 - **Random Forest:** $RMSE = 0.5071$, $MAE = 0.3312$, $R^2 = 0.8069$
 - **MLPRegressor:** $RMSE = 0.5463$, $MAE = 0.3729$, $R^2 = 0.7757$
 - **SVR:** $RMSE = 0.5925$, $MAE = 0.3955$, $R^2 = 0.7363$

California Housing: Regressão - Gráficos de Dispersão


- **Análise:** Random Forest apresenta melhor aderência à linha ideal, indicando maior precisão. Linear Regression e SVR mostram maior dispersão dos pontos, sugerindo maior erro nas previsões.




Linear Regression



Random Forest



MLPRegressor




SVR

Wine Quality (Red): Classificação - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados:**
 - **Logistic Regression:** Acurácia = 0.62, F1-score = 0.59, Kappa = 0.47
 - **Random Forest:** Acurácia = 0.71, F1-score = 0.70, Kappa = 0.60
 - **MLPClassifier:** Acurácia = 0.66, F1-score = 0.64, Kappa = 0.53
 - **SVM:** Acurácia = 0.64, F1-score = 0.62, Kappa = 0.50
- **Análise:** Random Forest apresentou o melhor desempenho geral.

Wine Quality (Red): Matrizes de Confusão


- Análise:** As matrizes de confusão mostram que Random Forest teve maior acerto nas classes principais, enquanto Logistic Regression e SVM apresentaram mais confusões entre as classes intermediárias.




Logistic Regression



Random Forest



MLPClassifier




SVM

Wine Quality (Red): Classificação (Com Balanceamento) - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados após balanceamento:**
 - **Logistic Regression:** Acurácia = 0.66, F1-score = 0.64, Kappa = 0.54
 - **Random Forest:** Acurácia = 0.74, F1-score = 0.73, Kappa = 0.65
 - **MLPClassifier:** Acurácia = 0.69, F1-score = 0.68, Kappa = 0.58
 - **SVM:** Acurácia = 0.67, F1-score = 0.66, Kappa = 0.56
- **Análise:** O balanceamento das classes melhorou o desempenho de todos os modelos, especialmente Random Forest.

Wine Quality (Red): Matrizes de Confusão (Com Balanceamento)


- Análise:** As matrizes de confusão mostram que, após o balanceamento, todos os modelos tiveram melhor desempenho nas classes minoritárias, com Random Forest mantendo o melhor acerto geral.




Logistic Regression



Random Forest



MLPClassifier




SVM


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados:**
 - **Logistic Regression:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **Random Forest:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **MLPClassifier:** Acurácia = 0.96, F1-score = 0.96, Kappa = 0.94
 - **SVM:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
- **Análise:** Todos os modelos apresentaram desempenho excelente, com destaque para Random Forest e SVM.

Iris: Matrizes de Confusão


- **Análise:** As matrizes de confusão mostram que todos os modelos classificaram corretamente quase todas as amostras, com pouquíssimos erros, evidenciando a facilidade do problema para esses algoritmos.




Logistic Regression



Random Forest



MLPClassifier




SVM

Iris: Classificação (Com Balanceamento) - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM
- **Resultados após balanceamento:**
 - **Logistic Regression:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **Random Forest:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
 - **MLPClassifier:** Acurácia = 0.96, F1-score = 0.96, Kappa = 0.94
 - **SVM:** Acurácia = 0.97, F1-score = 0.97, Kappa = 0.95
- **Análise:** O balanceamento manteve o excelente desempenho dos modelos, com todos apresentando alta acurácia e F1-score.

Iris: Matrizes de Confusão (Com Balanceamento)


- **Análise:** As matrizes de confusão mostram que todos os modelos continuam classificando corretamente quase todas as amostras, mesmo após o balanceamento das classes.




Logistic Regression



Random Forest



MLPClassifier





SVM

- Comparação de métricas entre modelos.
- Análise de desempenho em diferentes bases de dados.
- Visualização com boxplots e gráficos de barras.


Principais Resultados

- Random Forest foi o melhor em cenários complexos ou desbalanceados.
- MLP e SVM se destacaram em bases bem comportadas (Iris).
- Logistic Regression teve desempenho inferior em cenários desafiadores, mas competitivo em bases balanceadas.
- Técnicas de balanceamento melhoraram F1-score e Kappa em bases desbalanceadas.




Energy Efficiency: RMSE por Algoritmo

- O Random Forest apresentou o menor RMSE, indicando maior precisão na predição dos alvos Y1 e Y2.
- Modelos lineares tiveram desempenho inferior, com maiores erros médios.



Wine Quality (Balanceado): Acurácia por Algoritmo

- O Random Forest obteve a maior acurácia após o balanceamento das classes.
- O balanceamento impactou positivamente o desempenho dos modelos, especialmente em cenários originalmente desbalanceados.



- Não existe algoritmo universalmente superior: desempenho depende do contexto e das características dos dados.
- O uso de múltiplas métricas é essencial para avaliação completa.
- Balanceamento de classes é fundamental para cenários desbalanceados.
- Importância de experimentação rigorosa e análise contextualizada.

- Random Forest mostrou-se robusto e eficiente na maioria dos cenários.
- MLP e SVM são boas opções para bases bem comportadas.
- Logistic Regression é simples e interpretável, mas menos eficaz em cenários complexos.
- A escolha do modelo deve considerar o objetivo, a natureza dos dados e as métricas de interesse.