

Classificação e Regressão Supervisionadas

com Algoritmos de Aprendizado de Máquina

Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional,
CEFET-MG

29 de julho de 2025



Motivação e Objetivo

- Inteligência Computacional é fundamental para resolver problemas complexos em ciência de dados, engenharia e saúde.
- Necessidade de modelos preditivos robustos e confiáveis diante do aumento de dados.
- Objetivo: comparar técnicas de regressão e classificação multiclasse em bases públicas (Energy Efficiency, California Housing, Wine Quality, Iris).
- Avaliar modelos lineares, ensembles, redes neurais e métodos baseados em margens, considerando diferentes estratégias de pré-processamento.

- Bases utilizadas: Energy Efficiency, California Housing, Wine Quality (Red), Iris.
- Pré-processamento: normalização, codificação de variáveis categóricas, divisão estratificada em treino e teste.
- Modelos avaliados: Linear Regression, Random Forest, MLP, SVM/SVR, Logistic Regression.
- Técnicas de balanceamento aplicadas em bases desbalanceadas.
- Métricas: RMSE, MAE, R^2 (regressão); acurácia, F1-score, Kappa (classificação).
- 30 execuções para robustez estatística.


Principais Resultados

- Random Forest foi o melhor em cenários complexos ou desbalanceados.
- MLP e SVM se destacaram em bases bem comportadas (Iris).
- Logistic Regression teve desempenho inferior em cenários desafiadores, mas competitivo em bases balanceadas.
- Técnicas de balanceamento melhoraram F1-score e Kappa em bases desbalanceadas.




Energy Efficiency: RMSE por Algoritmo

- O Random Forest apresentou o menor RMSE, indicando maior precisão na predição dos alvos Y1 e Y2.
- Modelos lineares tiveram desempenho inferior, com maiores erros médios.



Wine Quality (Balanceado): Acurácia por Algoritmo

- O Random Forest obteve a maior acurácia após o balanceamento das classes.
- O balanceamento impactou positivamente o desempenho dos modelos, especialmente em cenários originalmente desbalanceados.



- Não existe algoritmo universalmente superior: desempenho depende do contexto e das características dos dados.
- O uso de múltiplas métricas é essencial para avaliação completa.
- Balanceamento de classes é fundamental para cenários desbalanceados.
- Importância de experimentação rigorosa e análise contextualizada.

- Random Forest mostrou-se robusto e eficiente na maioria dos cenários.
- MLP e SVM são boas opções para bases bem comportadas.
- Logistic Regression é simples e interpretável, mas menos eficaz em cenários complexos.
- A escolha do modelo deve considerar o objetivo, a natureza dos dados e as métricas de interesse.