

Classificação e Regressão Supervisionadas

com Algoritmos de Aprendizado de Máquina

Leonardo Vieira Guimarães

Programa de Pós-Graduação em Modelagem Matemática e Computacional,
CEFET-MG

29 de julho de 2025

Motivação e Objetivo

- Inteligência Computacional é fundamental para resolver problemas complexos em ciência de dados, engenharia e saúde.
- Necessidade de modelos preditivos robustos e confiáveis diante do aumento de dados.
- Objetivo: comparar técnicas de regressão e classificação multiclasse em bases públicas (Energy Efficiency, California Housing, Wine Quality, Iris).
- Avaliar modelos lineares, ensembles, redes neurais e métodos baseados em margens, considerando diferentes estratégias de pré-processamento.

Processamento dos Dados

- Datasets utilizados:
 - **Regressão:** Energy Efficiency, California Housing
 - **Classificação:** Wine Quality (Red), Iris
- Pré-processamento:
 - Normalização dos atributos (para regressão e classificação)
 - Codificação de variáveis categóricas (quando necessário)
 - Divisão dos dados em treino e teste:
 - Regressão: divisão aleatória (80% treino, 20% teste)
 - Classificação: divisão estratificada (70% treino, 30% teste) para preservar a proporção das classes
 - Balanceamento de classes para classificação: aplicado em Wine Quality e Iris para melhorar a acurácia e F1-score

- **Amostras:** 768
- **Atributos:** 8 variáveis de entrada: área relativa, compacidade, razão de área de superfície, área total de paredes, área total de telhado, orientação, superfície de envidraçamento, área de envidraçamento distribuída.
- **Alvos:** Y1 (Heating Load), Y2 (Cooling Load)
- **Descrição:** Dados de edifícios simulados para prever consumo de energia para aquecimento e resfriamento.
- **Fonte:** UCI Machine Learning Repository

- **Amostras:** 20.640
- **Atributos:** 8 variáveis de entrada: longitude, latitude, número médio de quartos, número médio de dormitórios, população, número médio de ocupantes por residência, renda mediana, idade mediana das casas.
- **Alvo:** MedHouseVal (valor mediano das casas em milhares de dólares)
- **Descrição:** Dados do censo da Califórnia para prever o valor das casas por região.
- **Fonte:** StatLib, UCI Machine Learning Repository

Wine Quality (Red) Dataset

- **Amostras:** 1.599
- **Atributos:** 11 variáveis físico-químicas: acidez fixa, acidez volátil, ácido cítrico, açúcares residuais, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos, álcool.
- **Alvo:** Qualidade do vinho (nota de 3 a 8)
- **Descrição:** Avaliação da qualidade de vinhos tintos portugueses com base em características químicas.
- **Fonte:** UCI Machine Learning Repository

- **Amostras:** 150
- **Atributos:** 4 variáveis: comprimento da sépala, largura da sépala, comprimento da pétala, largura da pétala.
- **Alvo:** Espécie da flor (Setosa, Versicolor, Virginica)
- **Descrição:** Clássico conjunto de dados para classificação de espécies de íris.
- **Fonte:** UCI Machine Learning Repository

- Modelos avaliados:
 - **Regressão:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR (Support Vector Regressor)
 - **Classificação:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM (Support Vector Machine)
- Cada experimento foi repetido 30 vezes para garantir robustez estatística dos resultados.

- Modelos que assumem uma relação linear entre as variáveis de entrada e a saída.
- Regressão Linear: método que busca uma relação linear entre as variáveis de entrada e a saída, ajustando uma reta para prever valores contínuos.
- Regressão Logística: usada para classificação, estima a probabilidade de uma amostra pertencer a uma classe.
- São métodos simples, rápidos e interpretáveis, mas não capturam padrões não-lineares complexos.

Ensembles: Random Forest

- Técnicas que combinam vários modelos simples (como árvores de decisão) para formar um modelo mais robusto.
- Random Forest: método de ensemble que constrói várias árvores de decisão independentes e combina seus resultados para melhorar a precisão e reduzir o risco de overfitting.
- É robusto a ruídos e desbalanceamento, mas pode ser menos interpretável que modelos lineares.

- Modelos inspirados no cérebro humano, compostos por camadas de neurônios artificiais.
- MLP (Perceptron Multicamadas): rede neural artificial composta por camadas de neurônios conectados, capaz de aprender padrões não-lineares complexos.
- Muito flexível, mas exige mais dados, processamento e pode ser difícil de interpretar.

Métodos Baseados em Margens: SVM/SVR

- Algoritmos que buscam separar as classes (ou ajustar uma faixa para regressão) maximizando a margem entre os dados.
- SVM (Support Vector Machine): método que busca o hiperplano que melhor separa as classes, maximizando a margem entre elas. SVR (Support Vector Regressor) aplica o mesmo princípio para regressão.
- São eficazes para dados com fronteiras complexas, mas sensíveis à escolha de parâmetros e à normalização.

Métricas de Avaliação: Classificação

- **Acurácia:** Mede a proporção de acertos totais (positivos e negativos). Próxima de 1 indica ótimo desempenho geral, mas pode mascarar erros em classes minoritárias. Útil para bases balanceadas.
- **F1-score:** Resume o equilíbrio entre precisão (acertos entre os positivos previstos) e revocação (acertos entre os positivos reais). Valor alto mostra que o modelo acerta bem ambas as classes, sendo ideal para bases desbalanceadas.
- **Kappa:** Mede o quanto o modelo supera o acaso, considerando a distribuição das classes. Próximo de 1: excelente concordância; próximo de 0: desempenho similar ao acaso. Importante para cenários com desbalanceamento.

Fórmulas

$$\text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN} \quad F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad Kappa = \frac{p_o - p_e}{1 - p_e}$$

Matriz de Confusão

- Mostra acertos e erros do modelo para cada classe.
- Permite identificar:
 - **TP**: Verdadeiro Positivo
 - **TN**: Verdadeiro Negativo
 - **FP**: Falso Positivo
 - **FN**: Falso Negativo
- Base para métricas como acurácia, precisão, revocação, F1-score, entre outras.

	P	N
P	TP	FN
N	FP	TN

Métricas de Avaliação: Regressão


- **RMSE:** Erro quadrático médio. Valores menores indicam previsões mais próximas dos reais. Sensível a grandes erros.
- **MAE:** Média dos erros absolutos. Fácil de interpretar, menos afetado por outliers que o RMSE.
- R^2 : Mede quanto da variação dos dados é explicada pelo modelo. Próximo de 1 indica ótimo ajuste.

Fórmulas

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Gráfico de Dispersão (Scatter Plot)

- Utilizado para comparar visualmente os valores reais e previstos em problemas de regressão.
- Pontos próximos da linha $y = x$ indicam boas previsões.



Energy Efficiency: Regressão (Y1) - Resultados


- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR

Modelo	RMSE	MAE	R^2
Random Forest	0.5171	0.3450	0.9973
MLPRegressor	2.6173	1.8412	0.9322
SVR	2.8290	1.9028	0.9210
Linear Regression	2.9708	2.1091	0.9128


Análise: Random Forest apresentou o melhor desempenho geral, com menor RMSE e MAE, e maior R^2 .

Energy Efficiency: Regressão (Y1) - Gráficos de Dispersão


- **Análise:** Modelos com pontos mais próximos da diagonal indicam melhores previsões. Random Forest apresenta maior aderência à linha ideal, enquanto Linear Regression e SVR mostram maior dispersão.




Linear Regression



Random Forest



MLPRegressor



SVR

Energy Efficiency: Regressão (Y2) - Resultados


- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR

Modelo	RMSE	MAE	R^2
Random Forest	1.7317	1.0485	0.9663
MLPRegressor	2.9967	2.1238	0.8993
SVR	3.1696	2.1104	0.8875
Linear Regression	3.2059	2.2713	0.8849


Análise: Random Forest novamente apresentou o melhor desempenho, com menor RMSE e MAE, e maior R^2 .

Energy Efficiency: Regressão (Y2) - Gráficos de Dispersão


- **Análise:** Random Forest novamente apresenta maior aderência à linha ideal, indicando melhor desempenho. Linear Regression e SVR mostram maior dispersão dos pontos, sugerindo maior erro nas previsões.




Linear Regression



Random Forest



MLPRegressor



SVR

California Housing: Regressão - Resultados


- **Modelos avaliados:** Linear Regression, Random Forest Regressor, MLPRegressor, SVR

Modelo	RMSE	MAE	R^2
Random Forest	0.5071	0.3312	0.8069
MLPRegressor	0.5463	0.3729	0.7757
SVR	0.5925	0.3955	0.7363
Linear Regression	0.7361	0.5327	0.5918


Análise: Random Forest apresentou o melhor desempenho geral, com menor RMSE e MAE, e maior R^2 .

California Housing: Regressão - Gráficos de Dispersão


- **Análise:** Random Forest apresenta melhor aderência à linha ideal, indicando maior precisão. Linear Regression e SVR mostram maior dispersão dos pontos, sugerindo maior erro nas previsões.




Linear Regression



Random Forest



MLPRegressor



SVR

Wine Quality (Red): Classificação - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM

Modelo	Acurácia	F1-score	Kappa
Random Forest	0.71	0.70	0.60
MLPClassifier	0.66	0.64	0.53
SVM	0.64	0.62	0.50
Logistic Regression	0.62	0.59	0.47


Análise: Random Forest apresentou o melhor desempenho geral.

Wine Quality (Red): Matrizes de Confusão


- Análise:** As matrizes de confusão mostram que Random Forest teve maior acerto nas classes principais, enquanto Logistic Regression e SVM apresentaram mais confusões entre as classes intermediárias.




Logistic Regression



Random Forest



MLPClassifier



SVM

Wine Quality (Red): Classificação (Com Balanceamento) - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM

Modelo	Acurácia	F1-score	Kappa
Random Forest	0.74	0.73	0.65
MLPClassifier	0.69	0.68	0.58
SVM	0.67	0.66	0.56
Logistic Regression	0.66	0.64	0.54


Análise: O balanceamento das classes melhorou o desempenho de todos os modelos, especialmente Random Forest.

Wine Quality (Red): Matrizes de Confusão (Com Balanceamento)


- Análise:** As matrizes de confusão mostram que, após o balanceamento, todos os modelos tiveram melhor desempenho nas classes minoritárias, com Random Forest mantendo o melhor acerto geral.




Logistic Regression



Random Forest



MLPClassifier



SVM

Iris: Classificação - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM

Modelo	Acurácia	F1-score	Kappa
Random Forest	0.97	0.97	0.95
SVM	0.97	0.97	0.95
Logistic Regression	0.97	0.97	0.95
MLPClassifier	0.96	0.96	0.94


Análise: Todos os modelos apresentaram desempenho excelente, com destaque para Random Forest e SVM.

Iris: Matrizes de Confusão


- **Análise:** As matrizes de confusão mostram que todos os modelos classificaram corretamente quase todas as amostras, com pouquíssimos erros, evidenciando a facilidade do problema para esses algoritmos.




Logistic Regression



Random Forest



MLPClassifier



SVM

Iris: Classificação (Com Balanceamento) - Resultados


- **Modelos avaliados:** Logistic Regression, Random Forest Classifier, MLPClassifier, SVM

Modelo	Acurácia	F1-score	Kappa
Random Forest	0.97	0.97	0.95
SVM	0.97	0.97	0.95
Logistic Regression	0.97	0.97	0.95
MLPClassifier	0.96	0.96	0.94


Análise: O balanceamento manteve o excelente desempenho dos modelos, com todos apresentando alta acurácia e F1-score.

Iris: Matrizes de Confusão (Com Balanceamento)


- **Análise:** As matrizes de confusão mostram que todos os modelos continuam classificando corretamente quase todas as amostras, mesmo após o balanceamento das classes.




Logistic Regression



Random Forest



MLPClassifier



SVM

Síntese dos Resultados: Regressão (Tabela)

Resultados dos algoritmos de regressão

Dataset	Algoritmo	RMSE	MAE	R ²
Energy (Y1)	Random Forest	0.5187	0.3462	0.9973
Energy (Y1)	MLP	2.6125	1.8421	0.9324
Energy (Y1)	SVR	2.8290	1.9028	0.9210
Energy (Y1)	Linear Regression	2.9708	2.1091	0.9128
Energy (Y2)	Random Forest	1.7285	1.0459	0.9664
Energy (Y2)	MLP	3.0091	2.1409	0.8985
Energy (Y2)	SVR	3.1696	2.1104	0.8875
Energy (Y2)	Linear Regression	3.2059	2.2713	0.8849
California	Random Forest	0.5062	0.3309	0.8075
California	MLP	0.5447	0.3728	0.7771
California	SVR	0.5925	0.3955	0.7363
California	Linear Regression	0.7361	0.5327	0.5918

Síntese dos Resultados: Regressão (Análise)

- O Random Forest foi o modelo mais eficiente para ambos os conjuntos de regressão, apresentando os menores valores de RMSE e MAE, além do maior R^2 .
- Linear Regression obteve os maiores erros e menor poder explicativo, especialmente para Y2 no Energy Efficiency.
- MLP e SVR tiveram desempenho intermediário, com MLP superando o modelo linear em ambos os conjuntos.

Síntese dos Resultados: Classificação (Sem Balanceamento)

Resultados dos algoritmos de classificação (sem balanceamento)

Dataset	Algoritmo	Acurácia	F1-score	Kappa
Wine	Random Forest	0.6948	0.6769	0.5014
Wine	MLP	0.6139	0.5950	0.3676
Wine	SVM	0.6088	0.5805	0.3452
Wine	Logistic Regression	0.5893	0.5544	0.3096
Iris	MLP	0.9522	0.9521	0.9256
Iris	SVM	0.9522	0.9521	0.9265
Iris	Random Forest	0.9500	0.9497	0.9230
Iris	Logistic Regression	0.9189	0.9188	0.8761

Síntese dos Resultados: Classificação (Com Balanceamento)

Resultados dos algoritmos de classificação (com balanceamento)

Dataset	Algoritmo	Acurácia	F1-score	Kappa
Wine	Random Forest	0.9478	0.9473	0.9374
Wine	MLP	0.7583	0.7507	0.7098
Wine	Logistic Regression	0.5167	0.5045	0.4201
Wine	SVM	0.6088	0.5805	0.3452
Iris	MLP	0.9544	0.9543	0.9294
Iris	SVM	0.9522	0.9521	0.9265
Iris	Random Forest	0.9456	0.9454	0.9161
Iris	Logistic Regression	0.9189	0.9188	0.8761

Síntese dos Resultados: Classificação (Análise)

- O Random Forest foi o algoritmo mais robusto e eficiente, especialmente em cenários complexos ou desbalanceados.
- MLP e SVM se destacaram em bases bem comportadas, como a Iris.
- Logistic Regression, apesar de simples e interpretável, teve desempenho inferior nos cenários mais desafiadores, mas foi competitivo em bases balanceadas.

- O Random Forest demonstrou ser o algoritmo mais robusto e eficiente para tarefas de regressão e classificação, especialmente em cenários complexos ou desbalanceados.
- MLP e SVM também apresentaram excelente desempenho, principalmente em bases bem comportadas, como a Iris.
- Logistic Regression, apesar de sua simplicidade e interpretabilidade, mostrou desempenho inferior nos cenários mais desafiadores, mas manteve-se competitivo em conjuntos de dados balanceados e de menor complexidade.

Obrigado!

Perguntas?



leoproti.com.br



github.com/LeonardoVieiraGuimaraes